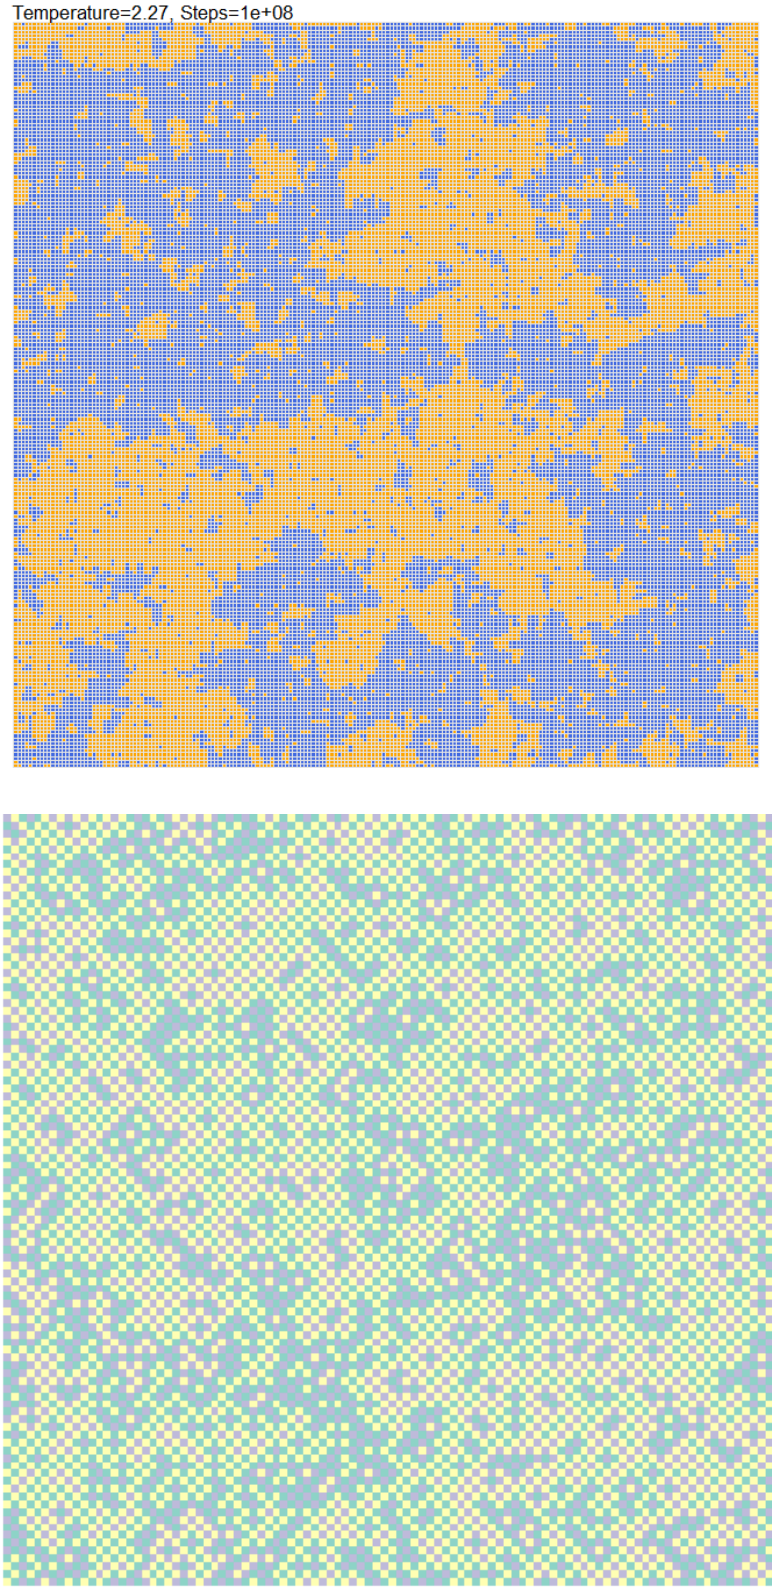
Markovljevi lanci

Bilješke s predavanja

Hrvoje Planinić

Prirodoslovno matematički fakultet – Matematički odsjek
Sveučilište u Zagrebu

E-mail adresa: planinic@math.hr



Realizacija jednog MCMC (Markov Chain Monte Carlo) algoritma za Isingov model (gore) te 3-bojanja (dolje) na konačnoj cjelobrojnoj rešetci.

Sadržaj

Predgovor v

Poglavlje 1. Definicija i osnovna svojstva Markovljevih lanaca 1
1.1. Motivacija 1
1.2. Definicija Markovljevog lanca 2
1.3. Primjeri i tipična konstrukcija Markovljevog lanca 4
1.4. Markovljevo svojstvo 8
1.5. n-koračne prijelazne vjerojatnosti 10

Poglavlje 2. Dekompozicija prostora stanja 12

Poglavlje 3. Apsorpcijske vjerojatnosti 14

Poglavlje 4. Jako Markovljevo svojstvo 21

Poglavlje 5. Povratnost i prolaznost 24
5.1. Definicija i karakterizacije 24
5.2. Zatvorenost i klase komuniciranja 26
5.3. Povratnost slučajne šetnje na $\mathbb{Z}^d$ 28

Poglavlje 6. Stacionarna distribucija 32
6.1. Definicija i osnovna svojstva 32
6.2. Egzistencija invarijantne mjere/distribucije 37
6.3. Jedinstvenost invarijantne mjere/distribucije 40

Poglavlje 7. Granična distribucija 45
7.1. Aperiodičnost 45
7.2. Teorem o graničnoj distribuciji i tehnika sparivanja 47
7.3. Periodičan lanac 52
7.4. Prolazan/nul-povratan slučaj 55
7.5. Diskretna teorija obnavljanja 55

Poglavlje 8. Ergodski teorem 60
8.1. Regenerativni ciklusi 60
8.2. Ergodski teorem 62

Poglavlje 9. Reverzibilnost i uvjeti detaljne ravnoteže 66
9.1. Okretanje vremena 71

Poglavlje 10. Markov Chain Monte Carlo (MCMC) 73
10.1. Bojanja grafa 73
10.2. Glauberova dinamika 77
10.3. Metropolis-Hastingsov algoritam 79
10.4. Isingov model 82

Bibliografija 85

Dodatak A. Nezavisnost 86
A.1. Uvjetna nezavisnost 87

Dodatak B. Teoremi o zamjeni limesa, sume i očekivanja 88

Predgovor

Ove bilješke su napisane kao nadopuna (a ne zamjena) predavanjima – tako da neke stvari mogu ostaviti studentima da sami pogledaju te da studenti mogu pogledati nešto što na predavanjima nisu stigli napisati (ili nisu uspjeli pročitati). Stvari koje se nalaze u uglatim zagradama su nešto što tipično samo ispričam. *Uglavnom* koristim **podebljani** font za stvari koje definiramo, a *kurziv* ili podcrtam stvari koje želim samo naglasiti.

Postoji veliki broj materijala (knjiga i *lecture notesa*) koji se mogu koristiti za kolegij o diskretnim Markovljevim lancima – klasična referenca je [**Nor98**], a [**LP17**] je modernija i naprednija verzija koja u uvodnim poglavljima daje kompaktan uvod u teoriju Markovljevih lanaca na konačnom skupu stanja. Ipak, preporučio bi studentima da pogledaju jako dobre materijale sa sličnih kolegija – [**Web**] i [**Kon**].

Mnoštvo primjera, dokaza te ideja u ovim bilješkama preuzeto je iz gore navedenih referenci, ali kao bazu koristio sam odličnu skriptu prof. Vondračeka [**Von**] koja je dugi niz godina bila glavna literatura za ovaj kolegij.

Posljednja izmjena napravljena je 28.9.2026.

Izmjene tokom 25./26.

- 28.9.2026. – popravljene greške u primjerima 1.3 i 1.4

POGLAVLJE 1

Definicija i osnovna svojstva Markovljevih lanaca

1.1. Motivacija

[Markovljevi lanci su jedna od najjednostavnijih (i najvažnijih) klasa slučajnih procesa u kojima postoji **zavisnost**.]

PRIMJER (**Slučajna šetnja na** $\mathbb{Z}^d$). [Nacrtati slike u dimenzijama 1 i 2.]

Neka je

- $T :=$ vrijeme prvog povratka u 0; dakle $T \in \{2, 3, \dots\} \cup \{+\infty\}$
- $\nu_i :=$ broj posjeta stanju $i \in \mathbb{Z}^d$ prije trenutka T; dakle $\nu_i \in \{0, 1, 2, \dots\} \cup \{+\infty\}$

U sklopu kolegija pokazat ćemo iduće tvrdnje.

1. $\mathbb{P}(T < \infty) = 1$ ako $d \leqslant 2$, te strogo manja od 1 ako je $d \geqslant 3$;
2. $\mathbb{E}[T] = +\infty$ za sve $d \in \mathbb{N}$;
3. za $d = 1$, $\mathbb{E}[\nu_5] = 1 = \mathbb{E}[\nu_{10^6}]$ (?!).

□

PRIMJER (**Google PageRank**). [Kojim redoslijedom tražilica poreda stranice, tj. kako odredi koje su važnije od drugih?]

Neka je $V = \{1, 2, \dots, m\}$ skup svih web-stranica. Nad V napravimo usmjereni graf tako da dvije web stranice $i, j \in V$ spojimo usmjerenim bridom od i prema j ("$(i, j) \in E$"), ako i sadrži link prema j [nacrtati sliku]. Neka je $L(i) = \{j \in V : (i, j) \in E\}$ skup svih "susjednih" stranica od i.

Slučajni surfer: iz stranice i u sljedećem koraku

(a) s vjerojatnošću $\alpha \in (0, 1)$ [npr. $\alpha = 0.85$] skoči u slučajno odabranu stranicu $j \in L(i)$;
(b) s vjerojatnošću $1 - \alpha$ skoči u slučajno odabranu stranicu $j \in V$.

Neka je π_i asimptotski postotak vremena koje će surfer provesti na stanici i.

Originalni PageRank $\longrightarrow$ "važnost" stranice $i \in V := \pi_i$

[Intutivno, stranica će biti "važna" (tj. više posjećena) ako puno "važnih" stranica ima link na nju; uočite da je ovo kružna tvrdnja.]

[(b) dio nam je potreban kako npr. surfer ne bi zaglavio u stranici koja nema linkova.]

U sklopu ovog kolegija ćemo povezati distribuciju $(\pi_i : i \in V)$ s tzv. *stacionarnom* distribucijom pripradnog Markovljevog lanca. [Ključan problem je kako efikasno odrediti (π_i).] □

PRIMJER (**Markov Chain Monte Carlo (MCMC)**). Često je potrebno simulirati slučajni element X na nekom konačnom (ali jako velikom!) skupu S, pri čemu je

$$\pi_x := \mathbb{P}(X = x) = \frac{w_x}{c}\,, \quad x \in S\,,$$

za poznate *težine* w_x te konstantu $c > 0$ koju je preteško za odrediti numerički. Neki od poznatijih primjera ovog problema su (a) Isingov model, te (b) k-bojanja grafa. Ovdje je S (pod)skup svih *konfiguracija* $x : V \to \{1, 2, \dots, k\}$, pri čemu su V vrhovi zadanog konačnog grafa $G = (V, E)$.

[Standardne metode za simuliranje ovdje ne funkcioniraju jer je (1) c nepoznata, i (2) vjerojatnosti π_i za svaki fiksni i iznimno male.]

MCMC metoda: moguće je naći Markovljev lanac kojemu je distribucija $\pi = (\pi_i : i \in S)$ tzv. *granična* razdioba, što omogućuje simuliranje iz π [vidi slike s početka bilješki].

1.2. Definicija Markovljevog lanca

Neka je $(\Omega, \mathcal{F}, \mathbb{P})$ vjerojatnosni prostor, a S (najviše) prebrojiv skup ("skup stanja").[1]

Slučajan proces s prostorom stanja S (i diskretnim vremenom) je niz slučajnih varijabli

$$(X_n)_{n\geqslant 0} = (X_0, X_1, \dots)$$

na $(\Omega, \mathcal{F}, \mathbb{P})$ s vrijednostima u S; dakle, $\forall n \geqslant 0$, X_n je (izmjeriva) funkcija sa Ω u S.[2] **Distribucija** (ili **razdioba**) na S je svaki vektor $\lambda = (\lambda_i : i \in S)$ t.d. je $\lambda_i \geqslant 0$, $\forall i \in S$ te vrijedi $\sum_{i\in S} \lambda_i = 1$. **Stohastička matrica** (na S) je svaka matrica $P = (p_{ij} : i.j \in S)$ t.d. je $p_{ij} \geqslant 0$, $\forall i, j \in S$, te $\sum_{j\in S} p_{ij} = 1$, $\forall i \in S$, tj. i-ti redak $(p_{ij} : j \in S)$ je distribucija na S, za sve i.

DEFINICIJA 1.1. Neka je $\lambda = (\lambda_i : i \in S)$ distribucija, a $P = (p_{ij} : i.j \in S)$ stohastička matrica. Slučajni proces $(X_n)_{n\geqslant 0}$ s vrijednostima u S je **Markovljev lanac** (ML) s **početnom distribucijom** λ i **prijelaznom matricom** P ako vrijedi

(i) $\mathbb{P}(X_0 = i) = \lambda_i$, $\forall i \in S$;

(ii)

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = p_{ij}\,, \tag{1.1}$$

za sve $n \geqslant 0$ i sve $i_0, \dots, i_{n-1}, i, j \in S$ za koje je lijeva strana dobro definirana (tj. događaj na koji uvjetujemo ima pozitivnu vjerojatnost).[3] U tom slučaju kraće kažemo da je $(X_n)_{n\geqslant 0}$ (λ, P)-ML.

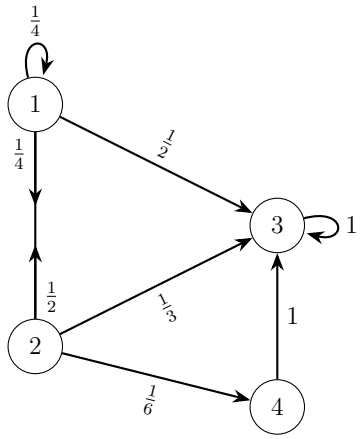
[1] Dakle, ako se eksplicitno ne kaže suprotno, dopuštamo da je S konačan skup.
[2] Formalno se X_n zove slučajni **element** u S.
[3] Ovaj dio "za koje je ..." kad god imamo uvjetne vjerojatnosti, u nastavku radi jednostavnosti često nećemo eksplicitno navoditi, ali treba ga imati na umu.

INTERPRETACIJA. Uvjet (1.1) znači da vjerojatnost na lijevoj strani *ne ovisi* ni o n, ni o stanjima $i_0, \ldots, i_{n-1}$ [tj. kako smo došli do $X_n = i$], a p_{ij} zovemo **prijelazna vjerojatnost** iz stanja i u stanje j.

PRIMJER. Neka je $S = \{1, 2, 3, 4\}$ te matrica prijelaza

$$P = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \end{array} \begin{array}{c} \begin{array}{cccc} 1 & 2 & 3 & 4 \end{array} \\ \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & \frac{1}{2} & 0 \\ \frac{1}{2} & 0 & \frac{1}{3} & \frac{1}{6} \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \end{array}.$$

Kretanje pripadnog Markovljevog lanca najčešće zamišljamo preko *usmjerenog težinskog grafa* pridruženog matrici prijelaza P:



Uočite da zapravo matrice prijelaza (tj. pripadne Markovljeve lance) možemo (i često hoćemo) zadavati preko usmjerenih težinskih grafova. □

[Sljedeći teorem daje karakterizaciju Markovljevih lanaca u terminima tzv. konačno dimenzionalnih distribucija procesa.]

TEOREM 1.2. *Neka je $(X_n)_{n\geqslant 0}$ slučajni proces u S, λ distribucija, a P stohastička matrica na S. Tada je $(X_n)_{n\geqslant 0}$ (λ, P)-ML* ***akko***

$$\mathbb{P}(X_0 = i_0, \ldots, X_n = i_n) = \lambda_{i_0} p_{i_0,i_1} \cdots p_{i_{n-1} i_n} \tag{1.2}$$

vrijedi za sve $n \geqslant 0$ i sve $i_0, \ldots, i_n \in S$.[4]

[4] Vjerojatnosti na lijevoj strani zovemo **konačnodimenzionalne distribucije** slučajnog procesa $(X_n)_{n\geqslant 0}$; one određuju distribuciju općenitog slučajnog procesa (na S).

Dokaz. "⇒" Pretpostavimo da je $\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) > 0$. tada je i za svaki $k \leqslant n$, $\mathbb{P}(X_0 = i_0, \dots, X_k = i_k) > 0$, pa imamo

$$\begin{aligned}\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) &= \mathbb{P}(X_0 = i_0)\mathbb{P}(X_1 = i_1 \mid X_0 = i_0)\mathbb{P}(X_2 = i_2 \mid X_1 = i_1, X_0 = i_0) \\ &\quad \dots \mathbb{P}(X_n = i_n \mid X_{n-1} = i_{n-1}, \dots, X_0 = i_0) \\ &\overset{(1.1)}{=} \lambda_{i_0} p_{i_0,i_1} p_{i_1,i_2} \cdots p_{i_{n-1}i_n}\,,\end{aligned}$$

pri čemu smo dakle iskoristili da je $(X_n)_{n\geqslant 0}$ (λ, P)-ML te da su sve gornje uvjetne vjerojatnosti dobro definirane. Ako je $\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) = 0$, lako se pokaže da je onda nužno i desna strana u (1.2) također jednaka 0 (DZ).

[Ako je $\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) = 0$, nužno je

- $\mathbb{P}(X_0 = i_0) = \lambda_{i_0} = 0$, ili
- $\exists k \in \{1, \dots, n\}$ t.d. je $\mathbb{P}(X_0 = i_0, \dots, X_k = i_k) = 0$, ali $\mathbb{P}(X_0 = i_0, \dots, X_{k-1} = i_{k-1}) > 0$, što dalje povlači da je

$$0 = \mathbb{P}(X_k = i_k \mid X_{k-1} = i_{k-1}, \dots, X_0 = i_0) \overset{(1.1)}{=} p_{i_{k-1}i_k}\,.$$

Dakle, u oba slučaja je i desna strana u (1.2) jednaka 0.]

"⇐"

(i) (1.2) za $n = 0$ daje $\mathbb{P}(X_0 = i_0) = \lambda_{i_0}$, $\forall i_0 \in S$;

(ii) Imamo

$$\begin{aligned}\mathbb{P}(X_{n+1} = j \mid X_n = i, \dots, X_0 = i_0) &= \frac{\mathbb{P}(X_{n+1} = j, X_n = i, \dots, X_0 = i_0)}{\mathbb{P}(X_n = i, \dots, X_0 = i_0)} \\ &\overset{(1.2)}{=} \frac{\lambda_{i_0} p_{i_0,i_1} \cdots p_{i_{n-1}i} p_{ij}}{\lambda_{i_0} p_{i_0,i_1} \cdots p_{i_{n-1}i}} = p_{ij}\,,\end{aligned}$$

za sve $n \geqslant 0$ i sve $i_0, \dots, i_{n-1}, i, j \in S$ [za koje ...].

□

[Često promatramo lance koji kreću iz nekog fiksnog stanja.]

Za sve $i \in S$ definiramo distribuciju $\delta^i = (\delta^i_j : j \in S)$ na S sa

$$\delta^i_j = \begin{cases} 1\,, & \text{ako } j = i\,, \\ 0\,, & \text{ako } j \neq i\,. \end{cases}$$

tj. slučajna varijabla X_0 u S ima distribuciju δ^i (oznaka $X_0 \sim \delta^i$) akko je $\mathbb{P}(X_0 = i) = 1$.

1.3. Primjeri i tipična konstrukcija Markovljevog lanca

Primjer 1.3 (**Njd niz**). Neka je $(Y_n)_{n\geqslant 0}$ niz nezavisnih i jednako distribuiranih ("njd") slučajnih varijabli u prebrojivom skupu S, te neka je $\lambda_i := \mathbb{P}(Y_0 = i) = \mathbb{P}(Y_n = i), i \in S$, zajednička distribucija niza. Je li $(Y_n)_n$ ML? DA!

Zaista, za sve $n \geqslant 0$ i $i, j, i_0, i_1, \ldots, i_{n-1} \in S$,

$$\begin{aligned}\mathbb{P}(Y_{n+1} = j \mid Y_n = i, Y_{n-1} = i_{n-1}, \ldots, Y_0 = i_0) &= [Y_{n+1} \text{ nezavisna od } Y_0, Y_1, \ldots, Y_n] \\ &= \mathbb{P}(Y_{n+1} = j) = [(Y_k)_{k\geqslant 0} \text{ su jednako distribuirane}] = \mathbb{P}(Y_0 = j) = \lambda_j \,.\end{aligned}$$

Dakle, $(Y_n)_{n\geqslant 0}$ je (λ, P)-ML uz

$$p_{ij} := \lambda_j \,,\ \forall i, j \in S \,,$$

tj. svi retci matrice P su isti i jednaki $\lambda = (\lambda_i : i \in S)$. Uočimo da, kao posljedica nezavisnosti između Y_n-ova, prijelazna vjerojatnost p_{ij} *ne ovisi* o trenutnom stanju i. □

Primjer 1.4 (**Slučajna šetnja**). Neka je $(Y_n)_{n\geqslant 1}$ niz njd slučajnih vektora u $\mathbb{Z}^d$, pri čemu je $d \geqslant 1$. Proces $(S_n)_{n\geqslant 0}$ definiran sa $S_0 := 0$ te

$$S_n := S_{n-1} + Y_n = \sum_{i=1}^{n} Y_i \,,\ n \geqslant 1 \,, \tag{1.3}$$

zove se **slučajna šetnja** na $\mathbb{Z}^d$ (s **koracima** $Y_1, Y_2, \ldots$) [nacrtati sliku za $d = 2$]. Je li $(S_n)_n$ ML? DA!

Za sve $n \geqslant 0$ i $i, j, i_0, i_1, \ldots, i_{n-1} \in \mathbb{Z}^d$ imamo

$$\begin{aligned}&\mathbb{P}(S_{n+1} = j \mid S_n = i, S_{n-1} = i_{n-1}, \ldots, S_0 = i_0) \\ &\quad = \mathbb{P}(\underbrace{S_n}_{=i} + Y_{n+1} = j \mid \underbrace{S_n = i, S_{n-1} = i_{n-1}, \ldots, S_0 = i_0}_{\text{ovisi samo o } Y_0, Y_1, \ldots, Y_n \text{ i } S_0 \equiv 0}) \\ &\quad = [Y_{n+1} \text{ nezavisna od } Y_0, Y_1, \ldots, Y_n \text{ i } S_0 \equiv 0] = \mathbb{P}(i + Y_{n+1} = j) \\ &\quad = [(Y_k)_{k\geqslant 1} \text{ su jednako distribuirane}] = \mathbb{P}(Y_1 = j - i) \,.\end{aligned}$$

Dakle, $(S_n)_{n\geqslant 0}$ je (δ^0, P)-ML na $\mathbb{Z}^d$ pri čemu je

$$p_{ij} := \mathbb{P}(Y_1 = j - i) \,,\ \forall i, j \in \mathbb{Z}^d \,.$$

Uočimo da ovdje p_{ij} ovisi o i, ali da s druge strane ovisi samo od razlici $j - i$ [to nekad zovemo *prostorna homogenost*].

Jednostavne šetnje. Za sve $i \in \{1, \ldots, d\}$ definiramo jedinični vektor $e_i \in \mathbb{Z}^d$ koji ima 1 na i-toj koordinati, a na ostalim mjestima 0, te neka je $N_0 := \{\pm e_1, \ldots, \pm e_d\} \subseteq \mathbb{Z}^d$ skup svih "susjeda" od $0 \in \mathbb{Z}^d$.

Ako je $Y_1 \in N_0$ [tj. koraci poprimaju vrijednosti samo u skupu N_0], kažemo da je šetnja **jednostavna** [nacrtati slike za $d = 1, 2$].

Ako je $Y_1 \in N_0$ te $\mathbb{P}(Y_1 = e_i) = \mathbb{P}(Y_1 = -e_i) = \frac{1}{2d}$, za sve $i = 1, \ldots, d$, [tj. korak Y_1 ima uniformnu razdiobu na N_0] proces $(S_n)_{n\geqslant 0}$ zovemo jednostavna, **simetrična** slučajna šetnja na $\mathbb{Z}^d$; npr. u $d = 1$ imamo $\mathbb{P}(Y_1 = 1) = \mathbb{P}(Y_1 = -1) = \frac{1}{2}$. □

Konstrukciju iz prethodna dva primjera možemo generalizirati te ML-e često (direktno ili indirektno) zadajemo na sljedeći način.

PROPOZICIJA 1.5. *Neka je*

- $(Y_n)_{n\geqslant 1}$ *niz njd slučajnih elemenata u nekom skupu* E *(*E *ne mora nužno biti prebrojiv),*
- $f : S \times E \to S$ *funkcija, te*
- X_0 *slučajna varijabla u* S *nezavisna od* $(Y_n)_{n\geqslant 1}$*, s distribucijom* λ*.*

Ako je za $n \geqslant 1$*,*

$$X_n = f(X_{n-1}, Y_n)\,, \tag{1.4}$$

tada je $(X_n)_{n\geqslant 0}$ (λ, P)*-ML pri čemu je*

$$p_{ij} = \mathbb{P}(f(i, Y_1) = j)\,, \tag{1.5}$$

za sve $i, j \in S$*.*

Uočimo da su slučajni procesi u prethodna dva primjera specijalni slučajevi konstrukcije (1.4):

- za njd niz $(Y_n)_{n\geqslant 0}$ imamo $Y_n = f(Y_{n-1}, Y_n)$ za $f(i, j) = j$, te je
$$p_{ij} = \mathbb{P}(f(i, Y_1) = j) = \mathbb{P}(Y_1 = j) = \lambda_j\,,$$
- za slučajnu šetnju $(S_n)_{n\geqslant 0}$ imamo $S_n = f(S_{n-1}, Y_n)$ za $f(i, j) = i + j$, te je
$$p_{ij} = \mathbb{P}(i + Y_1 = j) = \mathbb{P}(Y_1 = j - i)\,.$$

[Dakle, u oba slučaja bismo se za provjeru je li proces Markovljev lanac mogli direktno pozvati na gornju propoziciju. Uočimo da je kod slučajne šetnje konstanta $S_0 \equiv 0$ automatski nezavisna od niza $(Y_n)_{n\geqslant 1}$ pa su zaista ispunjeni svi uvjeti propozicije.]

Dokaz propozicije ostavljamo za vježbu budući da je vrlo sličan dokazu u primjeru sa slučajnom šetnjom.

[DOKAZ. Za $n \geqslant 0$ imamo

$$\begin{aligned}
&\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) \\
&\qquad = \mathbb{P}(f(\underbrace{X_n}_{=i}, Y_{n+1}) = j \mid \underbrace{X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0}_{\text{zbog (1.4) ovisi samo o } X_0, Y_1, \dots, Y_n}) \\
&\qquad = [Y_{n+1} \text{ nezavisna od } X_0, Y_1, \dots, Y_n] = \mathbb{P}(f(i, Y_{n+1}) = j) \\
&\qquad = [(Y_k)_{k\geqslant 1} \text{ su jednako distribuirane}] = \mathbb{P}(f(i, Y_1) = j)\,. \qquad \square]
\end{aligned}$$

PRIMJER 1.6 (**Proces grananja**). Neka su $(Z_{n,k} : n, k \geqslant 1)$ njd slučajne varijable s vrijednostima u $\mathbb{N}_0 = \{0, 1, 2, \dots\}$. Neka je $X_0 := 1$ te

$$X_n := \sum_{k=1}^{X_{n-1}} Z_{n,k}\,,\ n \geqslant 1\,,$$

uz $\sum_{k=1}^{0} Z_{n,k} := 0$. Proces $(X_n)_{n\geqslant 0}$ nazivamo **(jednostavni) proces grananja** [nacrtati skicu procesa]. $\rightsquigarrow$ Je li $(X_n)_{n\geqslant 0}$ ML? DA.

Ako stavimo $Y_n := (Z_{n,1}, Z_{n,2}, \dots) \in \mathbb{N}_0^{\mathbb{N}} =: E$, $n \geqslant 1$, iz činjenice da su $(Z_{n,k})_{n,k\geqslant 1}$ njd [ovdje je korisno zapisati elemente $Z_{n,k}$ u matricu te primijetiti da Y_n odgovara n-tom retku te matrice] slijedi da je $(Y_n)_{n\geqslant 1}$ niz njd slučajnih elemenata u E [dakle, svaki Y_k je jedan cijeli niz]. Nadalje, vrijedi $X_n = f(X_{n-1}, Y_n)$ za sve $n \geqslant 1$ uz

$$f(i, (z_1, z_2, \dots)) := \sum_{k=1}^{i} z_k \,,$$

za sve $i \in \mathbb{N}_0$, $(z_1, z_2, \dots) \in E$.

Iz Propozicije 1.5 slijedi da je $(X_n)_{n\geqslant 0}$ (δ^1, P)-ML na $\mathbb{N}_0$ (tj. moguće na nekom podskupu $S \subseteq \mathbb{N}_0$) uz

$$p_{ij} = \mathbb{P}\left(\sum_{k=1}^{i} Z_{1,k} = j\right) \,, \forall i, j \in \mathbb{N}_0 \,.$$

Na primjer, ako je "distribucija grananja"

$$Z_{1,1} \sim \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$$

onda je $S = \{0, 1\}$ te

$$P = \begin{array}{c} \\ 0 \\ 1 \end{array} \begin{array}{c} \begin{array}{cc} 0 & 1 \end{array} \\ \begin{bmatrix} 1 & 0 \\ q & p \end{bmatrix} \end{array}$$

□

Teorem 1.7. *Za proizvoljnu stohastičku matricu P i distribuciju λ na S, postoje $(Y_n)_{n\geqslant 1}$, f i X_0 kao u Propoziciji 1.5 takvi da je proces $(X_n)_{n\geqslant 0}$ definiran s (1.4) točno (λ, P)-ML.*

Dokaz. **Glavna ideja:** ako je $X_n = i$, X_{n+1} generiramo tako da ima distribuciju $(p_{i,j} : j \in S)$ (nezavisno od $X_0, \dots, X_{n-1}$). BSMOP da je $S = \{1, 2, \dots\}$ (elemente od S proizvoljno poredamo u konačan ili beskonačan niz).

- Uočimo, ako je
  - $\nu = (\nu_i : i \in S)$ proizvoljna distribucija na S,
  - $U \sim \text{Unif}[0, 1]$,
  - $s_k := \sum_{l=1}^{k} \nu_l$, $k \geqslant 0$ (specijalno, $s_0 = 0$, $\lim_{k\to\infty} s_k = 1$),

  te ako stavimo

  $$Z := k \quad \text{ako} \quad s_{k-1} < U \leqslant s_k \,, \; k \geqslant 1,$$

  vrijedi

  $$\mathbb{P}(Z = k) = \mathbb{P}(s_{k-1} < U \leqslant s_k) = [U \sim \text{Unif}[0, 1]] = s_k - s_{k-1} = \nu_k \,, k \geqslant 1.$$

Dakle, ovako generirana slučajna varijabla Z ima točno distribuciju ν [nacrtati skicu konstrukcije]. [Ovu konstrukciju sada trebamo ponoviti u svakom koraku ML-a, i to ovisno o trenutnom stanju $i \in S$.]

- Neka je sada $(Y_n)_{n\geqslant 1}$ niz njd Unif$[0,1]$ slučajnih varijabli, X_0 slučajna varijabla nezavisna od $(Y_n)_{n\geqslant 1}$ s distribucijom λ, te **za sve** $i \in S$,

$$s_k^{(i)} := \sum_{l=1}^{k} p_{il}\,,\ k \geqslant 0\,.$$

Neka je nadalje $f : S \times [0,1] \to S$ definirana s

$$f(i,y) = k \quad \text{ako} \quad s_{k-1}^{(i)} < y \leqslant s_k^{(i)}\,,\ k \geqslant 1,$$

te $X_n := f(X_{n-1}, Y_n)$, $n \geqslant 1$. Iz Propozicije 1.5 slijedi da je $(X_n)_{n\geqslant 0}$ $(\lambda, \widetilde{P})$-ML uz

$$\widetilde{p}_{ij} \overset{(1.5)}{=} \mathbb{P}(f(i,Y_1) = j) = s_j^{(i)} - s_{j-1}^{(i)} = p_{i,j}\,,\ \forall i,j \in S\,,$$

tj. $\widetilde{P} = P$.

□

[Dakle, ako nas zanima nešto što ovisi samo o distribuciju ML-a $(X_n)_{n\geqslant 0}$ (tj. o njegovim konačnodimenzionalnim distribucijama), možemo pretpostaviti da je $(X_n)_{n\geqslant 0}$ oblika $X_n = f(X_{n-1}, Y_n)$, što često olakšava rješavanje problema.]

1.4. Markovljevo svojstvo

[Sljedeću karakterizaciju uvjetne nezavisnosti ćemo često koristiti; pogledati Dodatak A za definiciju i svojstva nezavisnosti slučajnih varijabli, vektora i procesa (u diskretnom slučaju).]

Lema A.3. Neka su $A, B, C \in \mathcal{F}$ takvi da je $\mathbb{P}(A) > 0$. Ako je $\mathbb{P}(A \cap C) > 0$, B i C su uvjetno nezavisni uz dano A, tj. $\mathbb{P}(B \cap C \mid A) = \mathbb{P}(B \mid A)\mathbb{P}(C \mid A)$, ako i samo ako vrijedi

$$\mathbb{P}(B \mid A \cap C) = \mathbb{P}(B \mid A)\,.$$

Ako je $\mathbb{P}(A \cap C) = 0$, B i C su uvjetno nezavisni uz dano A za sve $B \in \mathcal{F}$. □

[Sada pokazujemo da uvjet (1.1) iz definicije ML-a zapravo povlači puno više.]

Teorem 1.8. *Neka je $(X_n)_{n\geqslant 0}$ (λ, P)-ML na S, $n \geqslant 0$ fiksan te $i \in S$ takav da vrijedi $\mathbb{P}(X_n = i) > 0$. Tada je uvjetno na $X_n = i$, slučajni proces*

$$(X_{n+m})_{m\geqslant 0} = (X_n, X_{n+1}, \dots)\,,$$

(i) (δ^i, P)-ML, i to
(ii) nezavisan od $X_0, \dots, X_n$.

[Interpretacija: Uvjetno na $X_n = i$, "lanac zaboravlja prošlost i kreće ispočetka".]

DOKAZ. Pokazat ćemo da za sve $m \geqslant 0$ i sve $i_0, \ldots, i_{n+m} \in S$, vrijedi

$$\begin{aligned}\mathbb{P}(X_{n+m} = i_{n+m}, \ldots, X_n = i_n \mid X_n = i, X_{n-1} = i_{n-1}, \ldots, X_0 = i_0) \\ = \mathbb{P}(X_{n+m} = i_{n+m}, \ldots, X_n = i_n \mid X_n = i) = \delta^i_{i_n} p_{i_n i_{n+1}} \cdots p_{i_{n+m-1} i_{n+m}} \,. \quad (1.6)\end{aligned}$$

Tada druga jednakost u (1.6) i obrat Teorema 1.2 povlače (i), a prva jednakost i Lema A.3 daju (ii). Pokažimo drugu jednakost u (1.6).

Ako je $i \neq i_n$ jednakost trivijalno vrijedi, a ako je $i = i_n$,

$$\begin{aligned}\mathbb{P}(X_{n+m} = i_{n+m}, \ldots, X_n = i_n \mid X_n = i) &= \frac{\mathbb{P}(X_{n+m} = i_{n+m}, \ldots, X_n = i)}{\mathbb{P}(X_n = i)} \\ &= \frac{\mathbb{P}(X_{n+m} = i_{n+m}, \ldots, X_n = i, X_{n-1} \in S, \ldots, X_0 \in S)}{\mathbb{P}(X_n = i, X_{n-1} \in S, \ldots, X_0 \in S)} \\ &= \frac{\sum_{i_0 \in S} \cdots \sum_{i_{n-1} \in S} \mathbb{P}(X_{n+m} = i_{n+m}, \ldots, X_n = i, X_{n-1} = i_{n-1}, \ldots, X_0 = i_0)}{\sum_{i_0 \in S} \cdots \sum_{i_{n-1} \in S} \mathbb{P}(X_n = i, X_{n-1} = i_{n-1}, \ldots, X_0 = i_0)} \\ &\overset{(1.2)}{=} \frac{\sum_{i_0 \in S} \cdots \sum_{i_{n-1} \in S} \lambda_{i_0} p_{i_0 i_1} \cdots p_{i_{n-1} i} \cdot \overbrace{p_{i i_{n+1}} \cdots p_{i_{n+m-1} i_{n+m}}}^{\text{ne ovisi o } i_0, \ldots, i_{n-1}}}{\sum_{i_0 \in S} \cdots \sum_{i_{n-1} \in S} \lambda_{i_0} p_{i_0 i_1} \cdots p_{i_{n-1} i}} \\ &= [\delta^i_{i_n} = 1] = \delta^i_{i_n} p_{i i_{n+1}} \cdots p_{i_{n+m-1} i_{n+m}} \,.\end{aligned}$$

Analogno se pokaže da je i prvi izraz u (1.6) jednak trećem (DZ).

□

ŠTO NAM SVE DAJE TEOREM 1.8? Neka je $(X_n)_{n \geqslant 0}$ (λ, P)-ML.

- Ako je $\mathbb{P}(X_0 = i) > 0$, definiramo vjerojatnost $\mathbb{P}_i$ na $(\Omega, \mathcal{F})$ sa

  $$\mathbb{P}_i(A) := \mathbb{P}(A \mid X_0 = i) \,, \ \forall A \in \mathcal{F} \,.$$

  Dio (i) za $n = 0$ povlači da je u odnosu na $\mathbb{P}_i$, $(X_n)_{n \geqslant 0}$ (δ^i, P)-ML [ovdje je dakle netrivijalno da je to opet ML sa istom prijelaznom matricom].
- Dio (ii) (ili jednostavno (1.6) za $m = 1$) povlači

  $$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \ldots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i) \,, \quad (1.7)$$

  za sve $n \geqslant 0$ i $i_0, \ldots, i_{n-1}, i, j \in S$ [za koje ...].

  → (1.7) se tipično naziva *Markovljevo svojstvo*;

  → Općenito, kažemo da je slučajni proces $(X_n)_{n \geqslant 0}$ Markovljev lanac ako zadovoljava (1.7) [za sve ...], te nadalje da je **vremenski homogen** ako $\forall i, j \in S$, $\mathbb{P}(X_{n+1} = j \mid X_n = i)$ *ne ovisi* o n (t.d. $\mathbb{P}(X_n = i) > 0$).

  → Lako se pokaže da je slučajni proces $(X_n)_{n \geqslant 0}$ vremenski homogen ML akko je (λ, P)-ML u smislu Definicije 1.1 (za neke λ i P) [$\Rightarrow$ očito, $\Leftarrow$ Teorem 1.8]. Samo takvima ćemo se baviti u ovom kolegiju te ćemo ih jednostavno zvati "Markovljevi lanci". Također, kad god koristimo Teorem 1.8 ćemo jednostavno reći da koristimo Markovljevo svojstvo (MS) lanca.

- Tipična primjena prethodnog teorema je npr.

$$\mathbb{P}(\underbrace{X_k = i \text{ za neki } k \geqslant n+1}_{\text{ovisi o } X_{n+1}, X_{n+2}, \ldots,} \mid X_n = i, (X_0, \ldots, X_{n-1}) \in A)$$
$$\overset{(ii)}{=} \mathbb{P}(X_k = i \text{ za neki } k \geqslant n+1 \mid X_n = i)$$
$$\overset{(i)}{=} \mathbb{P}_i(X_k = i \text{ za neki } k \geqslant 1)\,, \tag{1.8}$$

pri čemu je $A \subseteq S^{n-1}$.
[Formalno, Teorem 1.8 povlači (vidi (A.1) i Lemu A.3)

$$\mathbb{P}((X_{n+1}, \ldots, X_{n+m}) \in B \mid X_n = i, (X_0, \ldots, X_{n-1}) \in A)$$
$$\overset{(ii)}{=} \mathbb{P}((X_{n+1}, \ldots, X_{n+m}) \in B \mid X_n = i) \overset{(i)}{=} \mathbb{P}_i((X_1, \ldots, X_m) \in B)$$

za sve $n \geqslant 0, m \geqslant 1, B \subseteq S^m, A \subseteq S^{n-1}$, te $i \in S$ [za koje ...], pri čemu se gornja jednakost može proširiti i na slučaj $m = \infty$ (bez detalja) – u gornjem računu smo imali događaj

$$\{X_k = i \text{ za neki } k \geqslant n+1\} = \{(X_{n+1}, X_{n+2}, \ldots) \in B\}$$

za

$$B = \{(x_1, x_2, \ldots,) \in S^{\mathbb{N}} : x_k = i \text{ za neki } k \geqslant 1\}\,.]$$

1.5. n-koračne prijelazne vjerojatnosti

Za dvije stohastičke matrice $P = (p_{ij} : i, j \in S)$ i $Q = (q_{ij} : i, j \in S)$ definiramo njihov produkt kao (stohastičku) matricu $PQ = (r_{ij} : i, j \in S)$ sa

$$r_{ij} := \sum_{k \in S} p_{ik} q_{kj}\,.$$

[Matrica PQ je ponovno stohastička matrica jer su svi r_{ij}-ovi nenegativni, a Fubinijev teorem (vidi Dodatak B) za sve $i \in S$ daje

$$\sum_{j \in S} r_{ij} = \sum_{k \in S} p_{ik} \underbrace{\sum_{j \in S} q_{kj}}_{=1,\, \forall k \in S} = \sum_{k \in S} p_{ik} = 1\,.]$$

Označimo s $P^n = (p_{ij}^{(n)} : i, j \in S)$ n-tu potencija matrice P, tj. $P^0 := I$, $P^n := P^{n-1}P$ za $n \geqslant 1$; uočimo da je općenito $p_{ij}^{(n)} \neq p_{ij}^n$.

Distribucije λ na S shvaćamo kao *vektor-retke* te također definiramo λP kao vektor-redak na S s elementima

$$(\lambda P)_j := \sum_{i \in S} \lambda_i p_{ij}\,,\ j \in S\,.$$

LEMA 1.9. *Neka je $(X_n)_{n\geqslant 0}$ (λ, P)-ML na S. Tada vrijedi*

$$\mathbb{P}(X_n = j) = (\lambda P^n)_j = \sum_{i\in S} \lambda_i p_{ij}^{(n)}\,,\ \forall j \in S\,, \tag{1.9}$$

tj. $X_n \sim \lambda P^n$, te specijalno

$$\mathbb{P}_i(X_n = j) = p_{ij}^{(n)}\,,\ \forall i, j \in S\,. \tag{1.10}$$

Zbog (1.10) brojeve $p_{ij}^{(n)}$, $i, j \in S$, nazivamo **n-koračne prijelazne vjerojatnosti**.

DOKAZ. Za sve $n \geqslant 0$, označimo s $\lambda^{(n)}$ distribuciju od X_n, tj. $\lambda_j^{(n)} := \mathbb{P}(X_n = j)$, za sve $j \in S$. Dakle, $\lambda^{(0)} = \lambda$, a po formuli potpune vjerojatnosti (FPV) za sve $n \geqslant 1$ imamo

$$\begin{aligned}\lambda_j^{(n)} = \mathbb{P}(X_n = j) &= \sum_{i\in S} \mathbb{P}(X_{n-1} = i)\mathbb{P}(X_n = j \mid X_{n-1} = i)\\ &= \sum_{i\in S} \lambda_i^{(n-1)} p_{ij} = (\lambda^{n-1}P)_j\,,\ j \in S\,,\end{aligned} \tag{1.11}$$

tj. $\lambda^{(n)} = \lambda^{(n-1)}P$. Iteriranjem dobivamo

$$\lambda^{(n)} = \lambda^{(n-1)}P = \lambda^{(n-2)}P^2 = \cdots = \lambda^{(0)}P^n = \lambda P^n\,,$$

pri čemu jednakost vrijedi i u slučaju $n = 0$. Sada (1.9) odmah slijedi, a (1.10) slijedi ako u (1.9) uvrstimo $\lambda = \delta^i$.

□

Interpretacija distribucije preko masa u stanjima

- O svakoj distribuciji $\lambda = (\lambda_i : i \in S)$ na S možemo razmišljati kao o raspodjeli *mase* na stanja iz S, pri čemu je ukupna masa jednaka 1 – masa u stanju $i \in S$ je λ_i.
- Ako je kao gore, $\lambda^{(k)} := \mathbb{P}(X_k = \cdot\,)$, $k \in \mathbb{N}_0$, kako iz $\lambda^{(n)}$ dobijemo $\lambda^{(n+1)}$?
  [Nacrtati sliku. Za sve $i, j \in S$, masa koju i "pošalje" j je $\lambda_i^{(n)} p_{ij}$, a masa koju "primi" je $\lambda_j^{(n)} p_{ji}$. Nakon preraspodjele dobivamo točno $\lambda^{(n+1)}$.]
  Zaista, nakon preraspodjele, masa u stanju i je

  $$\sum_{j\in S} \lambda_j^{(n)} p_{ji} = [(1.11)] = \lambda_i^{(n+1)} = \mathbb{P}(X_n = i)\,,\ \ \forall i \in S\,.$$

  [Često je vrlo instruktivno na ovaj način razmišljati o Markovljevim lancima na diskretnim skupovima stanja!]

Chapman-Kolmogorovljeva jednakost: za sve $m, n \geqslant 0$ i sve $i, j \in S$ vrijedi

$$\begin{aligned}\mathbb{P}_i(X_{n+m} = j) &= \sum_{k\in S} \overbrace{\mathbb{P}_i(X_n = k)}^{=p_{ik}^{(n)}} \underbrace{\mathbb{P}_i(X_{n+m} = j \mid X_n = k)}_{\overset{\text{Tm.1.8}}{=}\mathbb{P}_k(X_m = j) = p_{kj}^{(m)}}\\ &= \sum_{k\in S} p_{ik}^{(n)} p_{kj}^{(m)}\,.\end{aligned} \tag{1.12}$$

POGLAVLJE 2

Dekompozicija prostora stanja

Neka je $(X_n)_{n\geqslant 0}$ (λ, P)-ML na S. Za $B \subseteq S$ definiramo **prvo vrijeme pogađanja** skupa B sa

$$T_B := \min\{n \geqslant 0 : X_n \in B\}\,,$$

uz konvenciju $\min\emptyset := +\infty$. Za $j \in S$, pišemo $T_j := T_{\{j\}}$. Specijalno,

$$\{T_j < \infty\} = \{X_n = j \text{ za neki } n \geqslant 0\}\,. \tag{2.1}$$

Za stanja $i, j \in S$ kažemo

- da je j **dostižno iz** i te pišemo $i \longrightarrow j$, ako vrijedi

$$\mathbb{P}_i(T_j < \infty) > 0\,.$$

- da i i j **komuniciraju** te pišemo $i \longleftrightarrow j$, ako vrijedi $i \longrightarrow j$ i $j \longrightarrow i$.

Napomena.

(i) Gornje definicije zapravo ovise samo o P, ne i o λ.

(ii) Za sve $i \in S$, po definiciji uvijek vrijedi $i \longleftrightarrow i$. □

Propozicija 2.1. *Za sve $i, j \in S$, $i \neq j$, ekvivalentno je:*

(i) $i \longrightarrow j$;

(ii) $p_{ij}^{(n)} > 0$ *za neko* $n \geqslant 1$;

(iii) $p_{ii_1}p_{i_1i_2}\cdots p_{i_{n-1}j} > 0$ *za neki* $n \geqslant 1$ *i neke* $i_1, \ldots, i_{n-1} \in S$.

Dokaz. Pogledati sami. [Za sve $n \geqslant 1$, budući da je $\mathbb{P}_i(T_j < \infty) = \mathbb{P}_i(\bigcup_{k=1}^{\infty}\{X_k = j\})$, imamo

$$p_{ij}^{(n)} = \mathbb{P}_i(X_n = j) \leqslant \mathbb{P}_i(T_j < \infty) \leqslant \sum_{k=1}^{\infty}\mathbb{P}_i(X_k = j) = \sum_{k=1}^{\infty} p_{ij}^{(k)}\,,$$

iz čega slijedi da su (i) i (ii) ekvivalentni. S druge strane, za sve $n \geqslant 1$ vrijedi

$$\begin{aligned} p_{ij}^{(n)} &= \mathbb{P}_i(X_n = j) = \textstyle\sum_{i_1,\ldots,i_{n-1}\in S}\mathbb{P}_i(X_1 = i_1, \ldots, X_{n-1} = i_{n-1}, X_n = j) \\ &= \textstyle\sum_{i_1,\ldots,i_{n-1}\in S} p_{ii_1}p_{i_1i_2}\cdots p_{i_{n-1}j}\,, \end{aligned}$$

iz čega slijedi da su (ii) i (iii) ekvivalentni.]

□

Iz dijela (iii) (ili upotrebom Chapman-Kolmogorovljeve jednakosti (1.12)) slijedi da $i \longrightarrow j$ i $j \longrightarrow k$ povlače $i \longrightarrow k$, te da isto vrijedi za relaciju $\longleftrightarrow$, tj. obje su *tranzitivne*. Budući da

je relacija $\longleftrightarrow$ očito simetrična i refleksivna, slijedi da je to *relacija ekvivalencije* na $S \times S$, pa rastavlja S na klase ekvivalencije $C_1, C_2, \ldots$ koje ćemo zvati **klase komuniciranja**; ovih klasa može biti konačno ili najviše prebrojivo mnogo. Dakle, $C_k \cap C_l = \emptyset$, $\forall k \neq l$, $\bigcup_k C_k = S$, te

$$i, j \in C_k \text{ za neki } k \;\Leftrightarrow\; i \longleftrightarrow j\,.$$

Za $B \subseteq S$ kažemo da je **zatvoren** [B ne mora biti klasa] ako je za sve $i \in B$, $\mathbb{P}_i(T_{B^c} < \infty) = 0$ [tj. to je skup iz kojeg lanac ne može izaći].

Napomena 2.2. Lako se pokaže da je ekvivalentno

(i) B zatvoren;

(ii) $p_{ij} = 0$, za sve $i \in B, j \in B^c$. □

Za stanje $j \in S$ kažemo da je **apsorbirajuće** ako je $\{j\}$ zatvoren skup, što je po prethodnoj napomeni ekvivalentno s $p_{jj} = 1$. Na kraju, kažemo da je lanac $(X_n)_{n\geqslant 0}$ (tj. matrica prijelaza P) **ireducibilan** ako postoji samo jedna klasa komuniciranja, tj. ako svaka dva stanja iz S komuniciraju.

Primjer 2.3.

$$P = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{array} \begin{array}{c} \begin{array}{cccccc} 1 & 2 & 3 & 4 & 5 & 6 \end{array} \\ \begin{bmatrix} \frac{1}{2} & \frac{1}{2} & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ \frac{1}{3} & 0 & \frac{1}{3} & \frac{1}{3} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{bmatrix} \end{array}$$

Kada ovoj matrici prijelaza pridružimo usmjereni graf na $S = \{1, 2, \ldots, 6\}$ pri čemu imamo usmjereni brid od i prema j ako je $p_{ij} > 0$, odmah slijedi

- klase su $C_1 = \{1, 2, 3\}$, $C_2 = \{4\}, C_3 = \{5, 6\}$;
- od C_1, C_2, C_3, samo je C_3 zatvoren skup;
- P nije ireducibilna
- nema apsorbirajućih stanja □

POGLAVLJE 3

Apsorpcijske vjerojatnosti

U nastavku, ako nije drugačije zadano, $(X_n)_{n\geqslant 0}$ označava (λ, P)-ML.

PRIMJER 3.1 (**Kockareva propast**). Neka je P na $S = \{0,1,2,3\}$ zadana s [nacrtati usmjereni graf]

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \end{array} \begin{array}{c} \begin{array}{cccc} 0 & 1 & 2 & 3 \end{array} \\ \begin{bmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 1 \end{bmatrix} \end{array}$$

Zanima nas

(a) $\mathbb{P}_2(T_3 < \infty) = \mathbb{P}_2(T_3 < T_0)$, pri čemu jednakost vrijedi jer je 0 apsorbirajuće stanje.

(b) $\mathbb{E}_2[T_{\{0,3\}}]$.

RJEŠENJE. (a) Neka je $h_i := \mathbb{P}_i(T_3 < \infty)$, $i \in S$ [dakle, zanima nas h_2]. Uvjetovanje na poziciju lanca u prvom koraku ("analiza prvog koraka") te korištenje MS-a (tj. formalno Teorema 1.8) daje

$$h_2 = \frac{1}{2}\underbrace{\mathbb{P}_2(T_3 < \infty \mid X_1 = 1)}_{=\mathbb{P}_1(T_3<\infty)=h_1} + \frac{1}{2}\underbrace{\mathbb{P}_2(T_3 < \infty \mid X_1 = 3)}_{=h_3}$$

Zaista, formalno to slijedi jer

$$\begin{aligned} \mathbb{P}_2(T_3 < \infty \mid X_1 = 1) &= \mathbb{P}(T_3 < \infty \mid X_1 = 1, X_0 = 2) \\ &= \mathbb{P}(X_n = 3 \text{ za neki } n \geqslant 0 \mid X_1 = 1, X_0 = 2) \\ &= [X_0 \neq 3] = \mathbb{P}(\underbrace{X_n = 3 \text{ za neki } n \geqslant 1}_{\text{ovisi o } X_1, X_2, \ldots} \mid X_1 = 1, X_0 = 2) \\ &= [\text{MS, vidi (1.8)}] = \mathbb{P}_1(X_n = 3 \text{ za neki } n \geqslant 0) = \mathbb{P}_1(T_3 < \infty) = h_1\,. \end{aligned}$$

Dakle, $h_2 = \frac{1}{2}h_1 + \frac{1}{2}h_3$, te analogno dobivamo cijeli sustav

$$\begin{cases} h_0 = 0 \\ h_1 = \frac{1}{2}h_0 + \frac{1}{2}h_2 = \frac{1}{2}h_2 \\ h_2 = \frac{1}{2}h_1 + \frac{1}{2}h_3 = \frac{1}{2}h_1 + \frac{1}{2} \\ h_3 = 1 \end{cases}$$

čije je rješenje $h_1 = \frac{1}{3}, h_2 = \frac{2}{3}$.

(b) Slično, neka je $B := \{0,3\}$ te stavimo $g_i := \mathbb{E}_i[T_B]$, $i \in S$. Analizom prvog koraka i koristeći MS dobivamo[1]

$$g_2 = \frac{1}{2}\underbrace{\mathbb{E}_2[T_B \mid X_1 = 1]}_{=1+\mathbb{E}_1[T_B]=1+g_1} + \frac{1}{2}\underbrace{\mathbb{E}_2[T_B \mid X_1 = 3]}_{1+g_3} = 1 + \frac{1}{2}g_1 + \frac{1}{2}g_3\,.$$

[Zaista, formalno to slijedi jer

$$\begin{aligned}
\mathbb{E}[T_B \mid X_1 = 1, X_0 = 2] &= \mathbb{E}[\min\{n \geqslant 0 : X_n \in B\} \mid X_1 = 1, X_0 = 2] \\
&= [X_0 \notin B] = \mathbb{E}[\min\{n \geqslant 1 : X_n \in B\} \mid X_1 = 1, X_0 = 2] \\
&= 1 + \mathbb{E}[\underbrace{\min\{m \geqslant 0 : X_{1+m} \in B\}}_{\text{ovisi o } X_1, X_2, \ldots} \mid X_1 = 1, X_0 = 2] \\
&= [\text{MS}] = 1 + \mathbb{E}_1[\min\{m \geqslant 0 : X_m \in B\}] = 1 + \mathbb{E}_1[T_B] = 1 + g_1\,.]
\end{aligned}$$

Analogno dobivamo cijeli sustav

$$\begin{cases} g_0 = 0 \\ g_1 = 1 + \frac{1}{2}g_0 + \frac{1}{2}g_2 = 1 + \frac{1}{2}g_2 \\ g_2 = \frac{1}{2}g_1 + \frac{1}{2}g_3 = 1 + \frac{1}{2}g_1 \\ g_3 = 0 \end{cases}$$

čije je rješenje $g_1 = g_2 = 2$ [jer uz $X_0 \in \{1,2\}$, T_B zapravo ima geometrijsku razdiobu s parametrom $\frac{1}{2}$].

□

PRIMJER 3.2 (**Kockareva propast na** $\{0,1,\ldots,N\}$). Za $N \in \mathbb{N}$, promatramo P na $S = \{0,1,2,3\}$ zadanu s [nacrtati usmjereni graf]

$$P = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ \vdots \\ N-1 \\ N \end{array} \begin{array}{c} \begin{array}{cccccccc} 0 & 1 & 2 & 3 & \ldots & N-2 & N-1 & N \end{array} \\ \begin{bmatrix} 1 & 0 & 0 & 0 & \ldots & 0 & 0 & 0 \\ q & 0 & p & 0 & \ldots & 0 & 0 & 0 \\ 0 & q & 0 & p & \ldots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ldots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \ldots & q & 0 & p \\ 0 & 0 & 0 & 0 & \ldots & 0 & 0 & 1 \end{bmatrix} \end{array}$$

za proizvoljan $p \in (0,1)$, $q := 1-p$. Ako definiramo "vjerojatnosti propasti"

$$h_i := \mathbb{P}_i(T_0 < \infty) = \mathbb{P}_i(T_0 < T_N)\,, i \in S\,,$$

[1] Ako je X slučajna varijabla koja poprima vrijednosti u $\mathbb{N}_0$ i $(H_i)_{i\in I}$ potpun sistem događaja, znamo da vrijedi $\mathbb{E}[X] = \sum_{i\in I}\mathbb{E}[X \mid H_i]\mathbb{P}(H_i) \in [0,\infty]$. Može se pokazati da ista formula vrijedi i ako X poprima vrijednosti u $\mathbb{N}_0 \cup \{+\infty\}$.

dobivamo sustav

$$\begin{cases} h_i = q \cdot h_{i-1} + p \cdot h_{i+1}\,, \ i \neq 0, N \\ h_0 = 1 \\ h_N = 0\,. \end{cases}$$

Za sve $i \in \{2, \ldots, N\}$ dakle vrijedi

$$ph_i - h_{i-1} + qh_{i-2} = 0\,,$$

tj. imamo *homogenu linearnu rekurziju* reda 2. Karakteristična jednadžba je

$$px^2 - x + q = 0\,.$$

Budući da je $px^2 - x + q = (x-1)(px-q) = p(x-1)(x-\frac{q}{p})$, razlikujemo dva slučaja.

Prvi slučaj: ako je $p \neq q$, imamo rješenja $x_1 = 1, x_2 = \frac{p}{q}$, te je opće rješenje

$$h_i = A \cdot 1^i + B \cdot \left(\frac{q}{p}\right)^i\,.$$

Iz rubnih uvjeta $h_0 = 1, h_N = 0$ dobivamo

$$A = -\frac{\left(\frac{q}{p}\right)^N}{1 - \left(\frac{q}{p}\right)^N}\,,\ B = \frac{1}{1 - \left(\frac{q}{p}\right)^N}\,,$$

tj. da je rješenje

$$h_i = \frac{\left(\frac{q}{p}\right)^i - \left(\frac{q}{p}\right)^N}{1 - \left(\frac{q}{p}\right)^N}\,,\ i = 0, \ldots, N\,.$$

Drugi slučaj: ako je $p = q = \frac{1}{2}$, imamo rješenja $x_1 = x_2 = 1$, te je opće rješenje

$$h_i = (A + B \cdot i^1) \cdot 1^i = A + Bi\,.$$

Iz rubnih uvjeta $h_0 = 1, h_N = 0$ dobivamo

$$A = 1\,,\ B = -\frac{1}{N}\,,$$

tj. da je rješenje $h_i = 1 - \frac{i}{N}$, $i = 0, \ldots, N$. Dakle[2],

$$\mathbb{P}_i(T_N < T_0) = \frac{i}{N}\,,\ i = 0, \ldots, N\,.$$

□

[Prethodni model se zapravo često javlja u primijenjenoj vjerojatnosti.]

[2] Ovdje implicitno pretpostavljamo da je $\mathbb{P}(\{T_0 < \infty \text{ ili } T_N < \infty\}) = 1$ što će slijediti iz kasnijih rezultata.

PRIMJER 3.3 (**Procjena rizika**). Ako je $(S_n)_{n\geqslant 0}$ jednostavna slučajna šetnja na $\mathbb{Z}$ ($S_0 := 0$) uz $p_{i,i+1} = p, p_{i,i-1} = 1-p =: q$ za $p \in (0,1)$, za sve $a, b \in \mathbb{N}$ vrijedi

$$\mathbb{P}(\{(S_n)_{n\geqslant 0} \text{ dostiže prag } -b \text{ prije nego } a\}) = \begin{cases} \frac{\left(\frac{q}{p}\right)^b - \left(\frac{q}{p}\right)^{a+b}}{1-\left(\frac{q}{p}\right)^{a+b}}\,, & p \neq q \\ \frac{a}{a+b}\,, & p = q = \frac{1}{2}\,. \end{cases}$$

Ovo slijedi direktno iz prethodnog primjera uz $i = b, N = a+b$ [nacrtati sliku]. [Ako $(S_n)_{n\geqslant 0}$ modelira dobitak npr. neke osiguravajuće kuće koja u rezervi ima b EUR, gornje je vjerojatnost da će osiguravajuća kuća bankrotirati prije nego zaradi a EUR.] □

[Općenito, u slučaju kada je S beskonačan, često postoji više rješenja sustava lineranih jednadžbi kakvih smo vidjeli u prethodnim primjerima. Sljedeći rezultat govori da nas u tom slučaju zanima *minimalno* rješenje.]

TEOREM 3.4. *Za $B \in S$ definiramo $h_i := \mathbb{P}_i(T_B < \infty)$, $i \in S$. Tada je vektor $(h_i : i \in S)$ minimalno nenegativno rješenje sustava linearnih jednadžbi*

$$\begin{cases} h_i = 1\,, & i \in B \\ h_i = \sum_{j\in S} p_{ij} h_j\,, & i \notin B\,. \end{cases} \tag{3.1}$$

Minimalnost znači da ako je $(x_i : i \in S)$ neko drugo nenegativno rješenje gornjeg sustava, tada je nužno $x_i \geqslant h_i$, $\forall i \in S$.

DOKAZ. 1. Prvo dokazujemo da je $(h_i : i \in S)$ rješenje sustava (3.1) – za vježbu (vidi dolje).

- Za $i \in B$, ako je $X_0 = i$ imamo $T_B = 0$ te $h_i = 1$.
- Za $i \notin B$, koristeći MS (vidi Primjer 3.1) dobivamo

$$h_i = \sum_{j\in S} \underbrace{\mathbb{P}_i(T_B < \infty \mid X_1 = j)}_{=\mathbb{P}_j(T_B<\infty)=h_j} \cdot \mathbb{P}_i(X_1 = j) = \sum_{j\in S} p_{ij} h_j\,.$$

2. Sada dokazujemo da je $(h_i : i \in S)$ minimalno rješenje. Neka je $(x_i : i \in S)$ proizvoljno nenegativno rješenje sustava (3.1).

- Za $i \in B$, imamo $x_i = 1 = h_i$ pa očito vrijedi i $x_i \geqslant h_i$.

- Za $i \notin B$,

$$x_i \overset{(3.1)}{=} \sum_{j\in S} p_{ij}x_j = [x_j = 1,\, \forall j \in B] = \sum_{j\in B} p_{ij} + \sum_{j\notin B} p_{ij}x_j$$
$$= \mathbb{P}_i(X_1 \in B) + \sum_{j\notin B} p_{ij}x_j$$
$$= [\text{isto za } x_j,\, \forall j \notin B\ ]$$
$$= \mathbb{P}_i(X_1 \in B) + \sum_{j\notin B, k\in B} p_{ij}p_{jk} + \sum_{j,k\notin B} p_{ij}p_{jk}x_k$$
$$= \mathbb{P}_i(X_1 \in B) + \mathbb{P}_i(X_1 \notin B, X_2 \in B) + \sum_{j,k\notin B} p_{ij}p_{jk}x_k$$
$$= \ldots = \sum_{l=1}^{n} \underbrace{\mathbb{P}_i(X_1 \notin B, \ldots, X_{l-1} \notin B, X_l \in B)}_{=\mathbb{P}_i(T_B=l)} + \sum_{i_1,\ldots,i_n\notin B} p_{ii_1}\cdots p_{i_{n-1}i_n}x_{i_n}\,,$$

pri čemu je $n \geqslant 1$ proizvoljan. Budući da je $x_j \geqslant 0$ za sve $j \in S$, za sve $n \geqslant 1$ dakle vrijedi

$$x_i \geqslant \sum_{l=1}^{n} \mathbb{P}_i(T_B = l) = [\mathbb{P}_i(T_B = 0)] = \mathbb{P}_i(T_B \leqslant n)\,.$$

Puštanjem $n \to \infty$ [i korištenjem neprekidnosti vjerojatnosti] dobivamo

$$x_i \geqslant \lim_{n\to\infty} \mathbb{P}_i(T_B \leqslant n) = \mathbb{P}_i(T_B < \infty) = h_i\,.$$

□

NAPOMENA. Ako nas npr. zanima $\mathbb{P}_i(T_B < T_j)$ za $j \notin B$, možemo primijeniti prethodni teorem tako da stanje j promijenimo u apsorpcijsko – tada je $\mathbb{P}_i(T_B < T_j) = \mathbb{P}_i(\widetilde{T}_B < \infty)$. □

PRIMJER 3.5 (**Proces rađanja i umiranja, tj. "Birth-and-death chain"**). Promatramo ML na $S = \{0, 1, 2, \ldots\}$ s prijelaznim vjerojatnostima $p_{00} = 1$ te

$$p_{i,i+1} = p_i,\ p_{i,i-1} = q_i\,, \quad \forall i \geqslant 1\,,$$

pri čemu je $p_i \in (0, 1)$, $q_i := 1 - p_i$, za sve $i \geqslant 1$ [nacrtati sliku].

[Ovaj model i njegove generalizacije se također često javljaju u primijenjenoj vjerojatnosti. Primjerice X_n može predstavljati veličinu populacije ili broj korisnika u nekom sustavu ("Queueing theory"), u trenutku n. Tada nas npr. može zanimati dugoročno ponašanje populacije/sustava.]

Neka je $h_i = \mathbb{P}_i(T_0 < \infty)$ vjerojatnost "izumiranja" ako je $X_0 = i$, za sve $i \in S$. Tada vrijedi

$$\begin{cases} h_0 = 1\,, \\ h_i = p_i h_{i+1} + q_i h_{i-1}\,,\ i \geqslant 1\,. \end{cases} \tag{3.2}$$

Gornji sustav možemo riješiti tako da stavimo $u_i := h_{i-1} - h_i$, $i \geqslant 1$, te primijetimo da u tom slučaju vrijedi

$$u_i = p_i(h_{i-1} - h_{i+1})\,,$$
$$u_{i+1} = q_i(h_{i-1} - h_{i+1})$$

tj. $q_i u_i = p_i u_{i+1}$ za sve $i \geqslant 1$. Iz ovoga slijedi da je za sve $i \geqslant 1$,

$$u_{i+1} = \frac{q_i}{p_i} u_i = \cdots = \left(\frac{q_i \cdots q_1}{p_i \ldots p_1}\right) u_1 =: a_i \cdot u_1\,.$$

pri čemu je $a_i > 0$. Budući da je

$$u_1 + \cdots + u_i = h_0 - h_i = 1 - h_i\,,\ i \geqslant 1\,,$$

ako stavimo i $a_0 := 1$, dobivamo

$$h_i = 1 - u_1(a_0 + \cdots + a_{i-1})\,,\ \forall i \geqslant 1\,. \tag{3.3}$$

Dakle, preostaje odrediti $u_1 = 1 - h_1$.

- Budući da je $h_1 \in [0,1]$, nužno je i $u_1 \in [0,1]$.
- Uočimo da je $h_1, h_2, \ldots$ nerastući nenegativan niz, a iz (3.3) slijedi

$$0 \leqslant \inf_{i \geqslant 1} h_i = 1 - u_1 \sum_{k=0}^{\infty} a_k\,.$$

- Ako je $\sum_{k=0}^{\infty} a_k = \infty$, nužno je u tom slučaju $u_1 = 0$, tj.

$$h_1 = 1 = h_i = \mathbb{P}_i(T_0 < \infty)\,,\ \forall i \geqslant 1\,.$$

- Ako je $\sum_{k=0}^{\infty} a_k < \infty$, dobivamo nenegativno rješenje sustava (3.2) ako u (3.3) uzmemo $u_1 \leqslant \frac{1}{\sum_{k=0}^{\infty} a_k}$, a minimalno ako je $u_1 = \frac{1}{\sum_{k=0}^{\infty} a_k}$, pa prethodni teorem povlači da je u ovom slučaju

$$h_i = \frac{\sum_{k=i}^{\infty} a_k}{\sum_{k=0}^{\infty} a_k}\,,\ i \geqslant 1\,.$$

  Budući da je $a_0 = 1$ te $a_k > 0$ za sve $k \geqslant 1$, imamo da je i $\mathbb{P}_i(T_0 < \infty) = h_i < 1$ za sve $i \geqslant 1$.

Ako uzmemo $p_i = p$, $q_i = 1 - p =: q$, za sve $i \geqslant 1$, dobivamo "kockarevu propast" na $\{0, 1, 2, \ldots\}$, te je u tom slučaju

$$a_k = \left(\frac{q}{p}\right)^k\,,\ k \geqslant 0\,.$$

- ako je $q < p$ imamo $\sum_{k=0}^{\infty} a_k < \infty$ te dakle,

$$\mathbb{P}_i(T_0 < \infty) = \left(\frac{q}{p}\right)^i < 1\ \ \forall i \geqslant 1\,.$$

- ako je $q \geqslant p$ imamo $\sum_{k=0}^{\infty} a_k = \infty$ te dakle $\mathbb{P}_i(T_0 < \infty) = 1$ za sve $i \geqslant 1$. [Za $p = q = \frac{1}{2}$, ovaj "paradoks" naziva se "kockareva propast".]

Jesmo li mogli gornja dva rezultata dobiti i iz Primjera 3.2? □

TEOREM 3.6. *Neka je* $B \subseteq S$ *te* $g_i = \mathbb{E}_i[T_B] \in [0, \infty]$, $i \in S$. *Tada je vektor* $(g_i : i \in S)$ *minimalno nenegativno rješenje sustava jednadžbi*

$$\begin{cases} g_i = 0\,, & i \in B \\ g_i = 1 + \sum_{j \in S} p_{ij} g_j\,, & i \notin B\,. \end{cases} \tag{3.4}$$

DOKAZ. 1. Prvo dokazujemo da je $(g_i : i \in S)$ jedno rješenje sustava (3.4) – detalje ostavljamo za vježbu (vidi Primjer 3.1).

2. Zatim dokazujemo da je $(g_i : i \in S)$ minimalno rješenje gornjeg sustava – detalj pogledati sami.

   Neka je $(x_i : i \in S)$ proizvoljno nenegativno rješenje sustava (3.4).

   - za $i \in B$, $x_i = 0 = g_i$.
   - za $i \notin B$,

$$\begin{aligned} x_i &\overset{(3.4)}{=} 1 + \sum_{j \in S} p_{ij} x_j = [x_j = 0,\ \forall j \in B] = 1 + \sum_{j \notin B} p_{ij} x_j \\ &= [\text{isto za } x_j,\ \forall j \notin B\ ] \\ &= 1 + \sum_{j \notin B} p_{ij} + \sum_{j,k \notin B} p_{ij} p_{jk} x_k \\ &= \mathbb{P}_i(T_B \geqslant 1) + \mathbb{P}_i(T_B \geqslant 2) + \sum_{j,k \notin B} p_{ij} p_{jk} x_k \\ &= \ldots = \sum_{l=1}^{n} \mathbb{P}_i(T_B \geqslant l) + \sum_{i_1, \ldots, i_n \notin B} p_{i i_1} \cdots p_{i_{n-1} i_n} x_{i_n} \\ &\geqslant [x_j \geqslant 0\,,\ \forall j] \geqslant \sum_{l=1}^{n} \mathbb{P}_i(T_B \geqslant l)\,, \end{aligned}$$

   pri čemu je $n \geqslant 1$ proizvoljan. Puštanjem $n \to \infty$, iz činjenice da T_B poprima vrijednosti u $\mathbb{N}_0 \cup \{+\infty\}$ dobivamo[3]

$$x_i \geqslant \sum_{l=1}^{\infty} \mathbb{P}_i(T_B \geqslant l) = \mathbb{E}_i[T_B] = g_i\,.$$

□

[3] Ako slučajna varijabla X poprima vrijednosti u $\mathbb{N}_0$ znamo da vrijedi $\mathbb{E}[X] = \sum_{k=1}^{\infty} \mathbb{P}(X \geqslant k) \in [0, \infty]$. Jednostavno je za provjeriti da formula vrijedi i u slučaju kada X poprima vrijednosti u $\mathbb{N}_0 \cup \{+\infty\}$.

POGLAVLJE 4

Jako Markovljevo svojstvo

[Pitanje je vrijedi li MS, tj. Teorem 1.8, ako deterministično vrijeme n zamijenimo sa slučajnim vremenom. Intuitivno, to neće vrijediti ako to slučajno vrijeme ovisi o budućnosti procesa.]

Za slučajan proces $(X_n)_{n\geqslant 0}$ u S, $\forall n \geqslant 0$ definiramo σ-algebru[1]

$$\mathcal{F}_n = \sigma(X_0, \ldots, X_n) := \left\{ \{(X_0, \ldots, X_n) \in B_n\} : B_n \subseteq S^{n+1} \right\} .$$

O događajima iz $\mathcal{F}_n$ razmišljamo kao o događajima koji "ovise o $X_0, \ldots, X_n$".

Definicija 4.1. Slučajna varijabla $T : \Omega \to \mathbb{N}_0 \cup \{+\infty\}$ je **vrijeme zaustavljanja** ako vrijedi

$$\{T \leqslant n\} \in \mathcal{F}_n \,, \quad \forall n \geqslant 0 \,. \tag{4.1}$$

Napomena 4.2. Uvjet (4.1) ekvivalentan je s uvjetom

$$\{T = n\} \in \mathcal{F}_n \,, \quad \forall n \geqslant 0 \,. \tag{4.2}$$

Zaista,

$\Rightarrow$ $\{T = n\} = \{T \leqslant n\} \setminus \{T \leqslant n-1\} \in \mathcal{F}_n$ jer su oba događaja elementi od $\mathcal{F}_n$;
$\Leftarrow$ $\{T \leqslant n\} = \cup_{k=0}^{n} \{T = k\} \in \mathcal{F}_n$ jer $\{T = k\} \in \mathcal{F}_k \subseteq \mathcal{F}_n$ za sve $k \leqslant n$.

[Intuitivno, ako nam je netko rekao da prateći proces $X_0, X_1, \ldots$ stanete u trenutku T, znali bismo kada stati.]

Primjer 4.3. (i) Za $m \geqslant 0$ fiksan, $T := m$ je vrijeme zaustavljanja. Formalno, to slijedi jer za sve $n \geqslant 0$

$$\{T = n\} = \begin{cases} \Omega \,, & \text{ako } n = m \\ \emptyset \,, & \text{ako } n \neq m \end{cases} \in \mathcal{F}_n \,.$$

(ii) Za $B \subseteq S$, prvo vrijeme pogađanja T_B je vrijeme zaustavljanja jer

$$\{T_B = n\} = \{X_0 \notin B, \ldots, X_{n-1} \notin B, X_n \in B\} \in \mathcal{F}_n \,, \ \forall n \geqslant 0 \,.$$

(iii) Za $B \subseteq S$, $T_B + 1$ [trenutak nakon prvog posjeta] je vrijeme zaustavljanja jer

$$\{T_B + 1 = n\} \in \mathcal{F}_{n-1} \subseteq \mathcal{F}_n \,, \ \forall n \geqslant 0 \,.$$

(iv) Za $B \subseteq S$, $T_B - 1$ [trenutak prije prvog posjeta] tipično neće biti vrijeme zaustavljanja jer općenito $\{T_B - 1 = n\} \in \mathcal{F}_{n+1}$, $\forall n \geqslant 0$. Ipak, ako je npr. $X_n := n$, $\forall n \geqslant 0$, i $B = \{m\}$, iz dijela (i) slijedi da je $T_B - 1 = m - 1$ u ovom (specijalnom) slučaju vrijeme zaustavljanja.

[1] Provjerite da $\mathcal{F}_n$ zaista je σ-algebra na Ω.

(v) Za $B \subseteq S$ i uz uvjet $X_0 \in B$,

$$L_B := \sup\{n \geqslant 0 : X_n \in B\} = \text{vrijeme } \textbf{zadnjeg} \text{ posjeta skupu } B\,,$$

tipično neće biti vrijeme zaustavljanja [jer $\{L_B = n\}$ ovisi i o $X_{n+1}, X_{n+2}, \dots$]. □

Za vrijeme zaustavljanja T definiramo sl. varijablu X_T sa $X_T(\omega) := X_{T(\omega)}$, tj. $X_T := X_n$ na događaju $\{T = n\}$; uočimo da je X_T definirana samo na događaju $\{T < \infty\}$. Kažemo da događaj $A \in \mathcal{F}$ ovisi o $X_0, \dots, X_T$, oznaka je $A \in \mathcal{F}_T$, ako vrijedi

$$A \cap \{T = m\} \in \mathcal{F}_m\,, \quad \forall m \geqslant 0\,.$$

Na primjer,

- $A := \{X_T = j\} \in \mathcal{F}_T$ jer $A \cap \{T = m\} = \{X_m = j, T = m\} \in \mathcal{F}_m$, $\forall m \geqslant 0$;
- $A := \Omega \in \mathcal{F}_T$ jer $A \cap \{T = m\} = \{T = m\} \in \mathcal{F}_m$, $\forall m \geqslant 0$.

Uočite, iako familiju $\mathcal{F}_T$ možemo definirati i u slučaju kada T nije vrijeme zaustavljanja, u gornjim primjerima ključno je bilo da je T vrijeme zaustavljanja.[2]

Teorem 4.4 (**Jako MS**). *Neka je*

- $(X_n)_{n\geqslant 0}$ (λ, P)*-ML na* S*;*
- T *vrijeme zaustavljanja (za* $(X_n)_{n\geqslant 0}$*).*

Tada je uvjetno na $T < \infty$ *i* $X_T = i$*, proces*

$$(X_{T+n})_{n\geqslant 0} = (X_T, X_{T+1}, \dots)\,,$$

(i) (δ^i, P)*-ML, te*
(ii) nezavisan od $X_0, \dots, X_T$*.*

Dokaz. Neka su $A \in \mathcal{F}_T$, $n \geqslant 1$, te $j_0, \dots, j_n \in S$, proizvoljni, te neka je

$$B := \{X_{T+n} = j_n, \dots, X_{T+1} = j_1, X_T = j_0\}\,.$$

Pokazat ćemo da vrijedi

$$\mathbb{P}\,(B \cap A \mid T < \infty, X_T = i) = \delta^i_{j_0} p_{j_0 j_1} \cdots p_{j_{n-1} j_n} \mathbb{P}(A \mid T < \infty, X_T = i)\,. \tag{4.3}$$

Ako u (4.3) uvrstimo $A = \Omega \in \mathcal{F}_T$, dobivamo

$$\mathbb{P}\,(B \mid T < \infty, X_T = i) = \delta^i_{j_0} p_{j_0 j_1} \cdots p_{j_{n-1} j_n}\,,$$

pa ako se vratimo (4.3) dobivamo

$$\mathbb{P}\,(B \cap A \mid T < \infty, X_T = i) = \mathbb{P}\,(B \mid T < \infty, X_T = i)\,\mathbb{P}(A \mid T < \infty, X_T = i)\,,$$

tj. vrijede (i) i (ii).

[2] Općenito, nezavisnost slučajnih varijabli, vektora, procesa, događaja itd. definira se preko nezavisnosti σ-algebri koje ti slučajni elementi generiraju; npr. $\mathcal{F}_n$ je točno σ-algebra generirana slučajnim vektorom $(X_0, \dots, X_n)$. Nije teško za pokazati da je familija događaja $\mathcal{F}_T$ zaista σ-algebra kada je T vrijeme zaustavljanja, i zovemo je σ-algebra generirana sl. varijablama $X_0, \dots, X_T$.

Za sve $m \geqslant 0$, vrijedi

$$\begin{aligned}
&\mathbb{P}\left(B \cap A \cap \{T < \infty, X_T = i\} \cap \{T = m\}\right) \\
&= \mathbb{P}\left(\{X_{m+n} = j_n, \dots, X_{m+1} = j_1, X_m = j_0\} \cap A \cap \{X_m = i\} \cap \{T = m\}\right) \\
&= \mathbb{P}\Big(X_{m+n} = j_n, \dots, X_{m+1} = j_1, X_m = j_0 \mid \{X_m = i\} \cap \overbrace{A \cap \{T = m\}}^{\in \mathcal{F}_m}\Big) \\
&\qquad \cdot \mathbb{P}(\{X_m = i\} \cap A \cap \{T = m\}) \\
&= [\text{Tm. 1.8, tj. MS u trenutku } m] \\
&= \delta^i_{j_0} p_{j_0 j_1} \cdots p_{j_{n-1} j_n} \mathbb{P}(A \cap \{X_T = i\} \cap \{T = m\}) \qquad (4.4)
\end{aligned}$$

Ako (4.4) sumiramo po $m = 0, 1, 2, \dots$ i onda podijelimo s $\mathbb{P}(T < \infty, X_T = i)$ dobijemo točno (4.3). □

Napomena 4.5. Ako je $T = T_j - 1$, tada uvjetno na $T < \infty$ i $X_T = i$, imamo

$$(X_T, X_{T+1}, X_{T+2}, \dots) = (i, j, X_{T+2}, \dots),$$

tj. $(X_{T+n})_{n \geqslant 0}$ općenito neće biti (δ^i, P)-ML.

Primjer 4.6. Neka je

- $(X_n)_{n \geqslant 0}$ (λ, P)-ML na S,
- $B \subseteq S$, te pretpostavimo da je $\mathbb{P}(X_0 \in B) = 1$,
- $T_0 := 0$, te za $m \geqslant 1$,

$$T_m := \min\{n > T_{m-1} : X_n \in B\} = \text{vrijeme } m\text{-tog povratka u skup } B\,.$$

Pretpostavimo da vrijedi $\mathbb{P}(T_m < \infty)$, za sve $m \geqslant 1$, te definirajmo $Y_m := X_{T_m}$, $m \geqslant 0$ [nacrtati sliku]. Pokažimo da je $(Y_m)_{m \geqslant 0}$ ML na B.

Za proizvoljan $m \geqslant 0$ i stanja $i_0, \dots, i_{m-1}, i, j \in B$, vrijedi

$$\mathbb{P}(Y_{m+1} = j \mid Y_m = i, \dots, Y_0 = i_0) = \mathbb{P}(X_{T_{m+1}} = j \mid X_{T_m} = i, \dots, X_{T_0} = i_0)$$

Prvo uočimo da je T_m vrijeme zaustavljanja; formalno, to slijedi jer

$$\{T_m = n\} = \{\textstyle\sum_{k=1}^{n-1} \mathbb{1}_{\{X_k \in B\}} = m - 1, X_n \in B\} \in \mathcal{F}_n\,, \quad \forall n \geqslant 0\,. \qquad (4.5)$$

Nadalje, budući da događaj $\{X_{T_{m+1}} = j\}$ ovisi samo o $X_{T_m+1}, X_{T_m+2}, \dots$, koristeći JMS u trenutku T_m dobivamo

$$\mathbb{P}(Y_{m+1} = j \mid Y_m = i, \dots, Y_0 = i_0) = \mathbb{P}_i(X_{T_1} = j) =: q_{i,j}\,,$$

Dakle, $(Y_m)_{m \geqslant 0}$ je ML na B s prijelaznom matricom $Q = (q_{i,j} : i, j \in B)$. Za vježbu pokažite da je za svaki $j \in B$, vektor $(q_{ij} : i \in S)$ minimalno nenegativno rješenje sustava jednadžbi[3]

$$q_{ij} = p_{ij} + \sum_{k \notin B} p_{ik} q_{kj}\,, \quad i \in S\,.$$

[3] Uočite, ako $i \notin B$, $q_{ij} = \mathbb{P}_i(X_{T_B} = j)$.

POGLAVLJE 5

Povratnost i prolaznost

5.1. Definicija i karakterizacije

Neka je $(X_n)_{n\geqslant 0}$ ML na S s prijelaznom matricom P.

NOTACIJA: za $i \in S$,

- $T_i = \min\{n \geqslant 0 : X_n = i\}$,
- $T_i^{(1)} := \min\{n > 0 : X_n = i\}$ = vrijeme prvog povratka u i,
  Uočimo da je $T_i \neq T_i^{(1)}$ akko $X_0 = i$.
- općenito, za $m \geqslant 1$ definiramo

$$T_i^{(m)} := \min\{n > T_i^{(m-1)} : X_n = i\} = \text{vrijeme } m\text{-tog povratka u } i\,,$$

  pri čemu je $T_i^{(0)} := 0$ [nacrtati sliku].
- $N_i := \sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=i\}}$ = ukupan broj posjeta lanca stanju i [uključuje trenutak 0],
- $f_i := \mathbb{P}_i(T_i^{(1)} < \infty)$ = vjerojatnost povratka u i.

DEFINICIJA 5.1. Stanje $i \in S$ je **povratno** ako je $f_i = 1$, a **prolazno** ako je $f_i < 1$.

NAPOMENA 5.2. (i) Ključno će biti sljedeće: za sve $m \geqslant 0$, ako je $X_0 = i$ vrijedi

$$N_i > m \iff T_i^{(m)} < \infty\,.$$

(ii) Za sve $m \geqslant 0$, $T_i^{(m)}$ je vrijeme zaustavljanja (vidi (4.5) uz $B := \{i\}$).

PROPOZICIJA 5.3. *Za sve $i \in S$ i sve $m \geqslant 0$ vrijedi*

$$\mathbb{P}_i(N_i > m) = f_i^m\,. \tag{5.1}$$

DOKAZ. Dokaz je jednostavna posljedica JMS-a. Za $m = 0$, (5.1) očito vrijedi, a za $m \geqslant 1$,

$$\begin{aligned}
\mathbb{P}_i(N_i > m) &= \mathbb{P}_i(T_i^{(m)} < \infty) = \mathbb{P}_i(T_i^{(m)} < \infty, T_i^{(m-1)} < \infty)\\
&= \mathbb{P}_i(T_i^{(m-1)} < \infty)\mathbb{P}_i(T_i^{(m)} < \infty \mid T_i^{(m-1)} < \infty)\\
&= [\text{JMS u } T_i^{(m-1)}] = \mathbb{P}_i(T_i^{(m-1)} < \infty)\mathbb{P}_i(T_i^{(1)} < \infty)\\
&= \mathbb{P}_i(T_i^{(m-1)} < \infty) f_i = [\text{JMS u } T_i^{(m-2)}] = \mathbb{P}_i(T_i^{(m-2)} < \infty) f_i^2\\
&= \ldots = \mathbb{P}_i(T_i^{(1)} < \infty) f_i^{m-1} = f_i^m\,.
\end{aligned}$$

□

KOROLAR 5.4. *Za sve $i \in S$, nužno je $\mathbb{P}_i(N_i = \infty) \in \{0, 1\}$, te vrijedi*

(a) i povratno akko $\mathbb{P}_i(N_i = \infty) = 1$,

(b) i prolazno akko $\mathbb{P}_i(N_i < \infty) = 1$.

Nadalje, ako je stanje i prolazno, vrijedi

$$\mathbb{P}_i(N_i = m) = f_i^{m-1}(1 - f_i)\,, \quad m \geqslant 1\,, \tag{5.2}$$

tj. s obzirom na $\mathbb{P}_i$, N_i *ima geometrijsku razdiobu na* $\mathbb{N}$ *s parametrom* $1 - f_i$.

Dokaz. Neprekidnost vjerojatnosti i (5.1) povlače

$$\mathbb{P}_i(N_i = \infty) = \lim_{m\to\infty} \mathbb{P}_i(N_i > m) = \lim_{m\to\infty} f_i^m = \begin{cases} 1, & \text{ako } f_i = 1\,, \\ 0, & \text{ako } f_i < 1\,. \end{cases}$$

Dokaz tvrdnje (5.2) ostavljamo za vježbu.

[Ako je $f_i < 1$, za sve $m \geqslant 1$ vrijedi

$$\mathbb{P}_i(N_i = m) = \mathbb{P}_i(N_i > m - 1) - \mathbb{P}_i(N_i > m) \overset{(5.1)}{=} f_i^{m-1}(1 - f_i)\,. \ ]$$

□

Korolar 5.5. *Za sve* $i \in S$ *vrijedi*

(a) i je povratno akko $\mathbb{E}_i[N_i] = \infty$ *[ovo je slabiji uvjet od* $\mathbb{P}_i(N_i = \infty) = 1$*];*

(b) i je prolazno akko $\mathbb{E}_i[N_i] < \infty$ *[ovo je jači uvjet od* $\mathbb{P}_i(N_i < \infty) = 1$*].*

Nadalje, ako je stanje i prolazno, vrijedi

$$\mathbb{E}_i[N_i] = \frac{1}{1 - f_i}\,. \tag{5.3}$$

Dokaz. Iz Korolara 5.4 slijedi

$$\mathbb{E}_i[N_i] = \begin{cases} +\infty\,, & \text{ako } f_i = 1\,. \\ \frac{1}{1-f_i}\,, & \text{ako } f_i < 1. \end{cases}$$

□

Za sve $i \in S$, imamo

$$\begin{aligned} \mathbb{E}_i[N_i] &= \mathbb{E}\left[\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n = i\}}\right] = \text{[Teorem o monotonoj konvergenciji, vidi Dodatak B]} \\ &= \sum_{n=0}^{\infty} \mathbb{E}_i\left[\mathbb{1}_{\{X_n = i\}}\right] = \sum_{n=0}^{\infty} \mathbb{P}_i(X_n = i) = \sum_{n=0}^{\infty} p_{ii}^{(n)}\,. \end{aligned} \tag{5.4}$$

Sve skupa, dokazali smo:

Teorem 5.6 (**Karakterizacije povratnosti/prolaznosti**). *Za sve* $i \in S$,

(a) i je povratno akko $\mathbb{P}_i(N_i = \infty) = 1$ *akko* $\mathbb{E}_i[N_i] = \infty$ *akko* $\sum_{n=0}^{\infty} p_{ii}^{(n)} = \infty$*;*

(b) i je prolazno akko $\mathbb{P}_i(N_i < \infty) = 1$ *akko* $\mathbb{E}_i[N_i] < \infty$ *akko* $\sum_{n=0}^{\infty} p_{ii}^{(n)} < \infty$.

Na kraju, za sve $i, j \in S$, definiramo

$$f_{ji} := \mathbb{P}_j(T_i^{(1)} < \infty) = \begin{cases} f_i\,, & \text{ako } j = i, \\ \mathbb{P}_j(T_i < \infty)\,, & \text{ako } j \neq i. \end{cases} \tag{5.5}$$

Sljedeći rezultat je generalizacija Propozicije 5.3; dokaz ostavljamo za vježbu.

PROPOZICIJA 5.7. *Za sve $i, j \in S$, $i \neq j$, i sve $m \geqslant 1$, vrijedi*

$$\mathbb{P}_j(N_i \geqslant m) = f_{ji} f_{ii}^{m-1}\,. \tag{5.6}$$

Iz (5.6) za sve $i \neq j$ dobivamo

$$\begin{aligned} \sum_{n=0}^{\infty} p_{ji}^{(n)} &= [\text{vidi (5.4)}] = \mathbb{E}_j[N_i] = [N_i \in \mathbb{N}_0 \cup \{+\infty\}] \\ &= \sum_{m=1}^{\infty} \mathbb{P}_j(N_i \geqslant m) = \begin{cases} 0\,, & \text{ako } f_{ji} = 0, \\ +\infty\,, & \text{ako } f_{ji} > 0,\ f_{ii} = 1, \\ \frac{f_{ji}}{1-f_{ii}}\,, & \text{ako } f_{ji} > 0,\ f_{ii} < 1, \end{cases} \end{aligned} \tag{5.7}$$

Specijalno, ako je $i \in S$ prolazno stanje [bez obzira je li $f_{ji} > 0$ ili $f_{ji} = 0$], vrijedi

$$\sum_{n=0}^{\infty} p_{ji}^{(n)} = \mathbb{E}_j[N_i] < \infty\,, \tag{5.8}$$

te je nužno

$$\lim_{n\to\infty} p_{ji}^{(n)} = 0\,. \tag{5.9}$$

[Zadnja dva rezultata će nam trebati kasnije.]

5.2. Zatvorenost i klase komuniciranja

PROPOZICIJA 5.8 (**Povratnost/prolaznost je svojstvo klase komuniciranja**). *Ako su $i, j \in S$ stanja koja komuniciranju, tada je*

(a) i povratno akko j povratno;

(b) i prolazno akko j prolazno.

Iz prethodnog rezultata slijedi: ako je $C \subseteq S$ klasa komuniciranja, vrijedi točno jedna od iduće dvije tvrdnje

(a) sva stanja iz C su povratna (te kažemo da je "C povratna klasa");

(b) sva stanja iz C su prolazna (te kažemo da je "C prolazna klasa").

DOKAZ. Dio (b) slijedi odmah iz (a), a u (a) dijelu je zbog simetrije dovoljno pokazati samo smjeri $\Rightarrow$. Pretpostavimo da je $i \neq j$ [inače je trivijalno]: $i \longleftrightarrow j$ povlači da postoje $m, n \geqslant 1$

t.d. $p_{ij}^{(n)} > 0$, $p_{ji}^{(m)} > 0$. Nadalje, budući da je za sve $k \geqslant 0$,

$$p_{jj}^{(m+k+n)} \geqslant p_{ji}^{(m)} p_{ii}^{(k)} p_{ij}^{(n)} ,$$

vrijedi

$$\sum_{l=0}^{\infty} p_{jj}^{(l)} \geqslant \sum_{k=0}^{\infty} p_{jj}^{(m+k+n)} \geqslant \underbrace{p_{ji}^{(m)} p_{ij}^{(n)}}_{>0} \sum_{k=0}^{\infty} p_{ii}^{(k)} = [i \text{ povratno}] = \infty ,$$

gdje smo u zadnjem koraku koristili Teorem 5.6. Njegovom ponovnom upotrebom zaključujemo da je i stanje j povratno. □

Sada iskazujemo pomoćni tehnički rezultat.

Propozicija 5.9. *Neka su $i, j \in S$ stanja takva da je stanje i povratno te vrijedi $i \longrightarrow j$. Tada vrijedi (a) $\mathbb{P}_j(N_i = \infty) = 1$, (b) $\mathbb{P}_j(T_i^{(1)} < \infty) = 1$, (c) $j \longrightarrow i$.*

Dokaz. Dovoljno je dokazati tvrdnju (a), jer onda (b) i (c) slijede odmah. Također, ako je $i = j$, (a) slijedi iz Teorema 5.6.

Za $j \neq i$, $i \longrightarrow j$ povlači da postoji $m \geqslant 1$ t.d. $\mathbb{P}_i(X_m = j) > 0$, a budući da je i povratno znamo da je i $\mathbb{P}_i(N_i = \infty) = 1$. Ključna stvar je primijetiti da vrijedi

$$N_i = \textstyle\sum_{k=0}^{\infty} \mathbb{1}_{\{X_k = i\}} = \infty \iff \sum_{k=m}^{\infty} \mathbb{1}_{\{X_k = i\}} = \infty ,$$

bez obzira koliki je m. Dakle,

$$\begin{aligned} \mathbb{P}_i(X_m = j) &= \mathbb{P}_i(X_m = j, N_i = \infty) = \mathbb{P}_i\left(X_m = j, \textstyle\sum_{k=m}^{\infty} \mathbb{1}_{\{X_k = i\}} = \infty\right) \\ &= \mathbb{P}_i\left(X_m = j\right) \mathbb{P}_i\left(\textstyle\sum_{k=m}^{\infty} \mathbb{1}_{\{X_k = i\}} = \infty \mid X_m = j\right) \\ &= [\text{MS u trenutku } m] = \mathbb{P}_i\left(X_m = j\right) \mathbb{P}_j(N_i = \infty) . \end{aligned}$$

Budući da je $\mathbb{P}_i(X_m = j) > 0$, nužno je $\mathbb{P}_j(N_i = \infty) = 1$. □

Prethodni rezultat povlači sljedeće dvije tvrdnje; dokaze ostavljamo za vježbu.

Propozicija 5.10. *Svaka povratna klasa komuniciranja je nužno zatvoren skup.*

Propozicija 5.11. *Ako je $(X_n)_{n \geqslant 0}$ ireducibilan i povratan ML, vrijedi*

$$\mathbb{P}(T_i^{(1)} < \infty) = 1 ,$$

***neovisno** o početnoj distribuciji lanca.*

Propozicija 5.12. *Ako je S konačan skup, tada postoji barem jedno povratno stanje.*

Dokaz. Pretpostavimo da su sva stanja prolazna. Tada vrijedi $\mathbb{P}_i(N_i < \infty) = 1$, za sve $i \in S$. Sada koristeći JMS u trenutku $T_i^{(1)}$, za sve $i, j \in S$ dobivamo da vrijedi

$$\mathbb{P}_j(N_i = \infty) = \mathbb{P}_j(T_i^{(1)} < \infty) \mathbb{P}_i(N_i = \infty) = 0 .$$

[Implicitno smo pretpostavili da je $\mathbb{P}_j(T_i^{(1)} < \infty) > 0$, ali ukoliko to nije slučaj, $\mathbb{P}_j(N_i = \infty) = 0$ vrijedi trivijalno.] Fiksirajmo sada $j \in S$. Iz prethodnog slijedi

$$1 = \mathbb{P}_j(N_i < \infty,\, \forall i \in S) = [S \text{ konačan skup}] = \mathbb{P}_j\left(\textstyle\sum_{i\in S} N_i < \infty\right),$$

ali to je očito kontradikcija jer, bez obzira na početno stanje, mora vrijediti $\sum_{i\in S} N_i = \infty$; formalno,

$$\sum_{i\in S} N_i = \sum_{i\in S}\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=i\}} = \sum_{n=0}^{\infty} \underbrace{\sum_{i\in S} \mathbb{1}_{\{X_n=i\}}}_{=\mathbb{1}_{\{X_n\in S\}}=1} = \infty\,.$$

Dakle, nužno postoji barem jedno povratno stanje. □

NAPOMENA 5.13. Općenito, zatvorena klasa komuniciranja ne mora nužno biti povratna [npr. primjer slučajne šetnje u $\mathbb{Z}^3$ kasnije], ali Prop. 5.12 povlači da za **konačnu** klasu komuniciranja C vrijedi da je povratna **ako i samo ako** je zatvorena; dokaz na vježbama. [Specijalno, ovo rješava problem klasifikacije stanja u povratna/prolazna u slučaju kada je S konačan – dovoljno je pronaći klase komuniciranja te odrediti koje od njih su zatvorene, a koje nisu.]

5.3. Povratnost slučajne šetnje na $\mathbb{Z}^d$

Neka je $(S_n)_{n\geqslant 0}$ (uz $S_0 := 0$) **jednostavna** slučajna šetnja na $\mathbb{Z}^d$, $d \in \mathbb{N}$ (vidi Primjer 1.4). Nadalje, za nenegativne nizove $(a_n)_{n\geqslant 0}$ i $(b_n)_{n\geqslant 0}$ pišemo $a_n \sim b_n$ (kada $n \to \infty$) ako vrijedi $\lim_{n\to\infty} a_n/b_n = 1$. Specijalno, ako vrijedi $a_n \sim b_n$, imamo $\sum_{n=1}^{\infty} a_n < \infty$ akko $\sum_{n=1}^{\infty} b_n < \infty$.

5.3.1. Povratnost jednostavne šetnje na $\mathbb{Z}$. Imamo $p_{i,i+1} = p, p_{i,i-1} = 1-p =: q$, za sve $i \in \mathbb{Z}$, za $p \in (0,1)$ [nacrtati sliku]. Šetnja je ireducibilna pa je dovoljno provjeriti povratnost proizvoljnog stanja, uzmimo npr. stanje 0. Po Teoremu 5.6 znamo da je 0 povratno stanje akko je $\sum_{n=1}^{\infty} p_{00}^{(n)} = \infty$.

Pretpostavimo najprije da smo u simetričnom slučaju, tj. da je $p = q = \frac{1}{2}$.

- za $n = 2m-1$, $m \geqslant 1$, očito vrijedi $p_{00}^{(n)} = \mathbb{P}(S_n = 0) = 0$.
- za $n = 2m$, $m \geqslant 1$, vrijedi $S_{2m} = 0$ akko je broj koraka šetnja na desno (do trenutka n) jednak broju koraka šetnje na lijevo ($= m$). Budući da je broj takvih trajektorija točno $\binom{2m}{m}$, imamo dakle

$$p_{00}^{(2m)} = \binom{2m}{m}\left(\frac{1}{2}\right)^2 \cdot \left(\frac{1}{2}\right)^2 = \frac{(2m)!}{(m!)^2}\frac{1}{4^m}\,.$$

- iz Stirlingove formule ($n! \sim C\sqrt{n}\, n^n e^{-n}$ za $C = \sqrt{2\pi}$, kada $n \to \infty$) dobivamo da za $m \to \infty$,

$$p_{00}^{(2m)} \sim \frac{C\sqrt{2m}(2m)^{2m}e^{-2m}}{C^2 m\, m^{2m} e^{-2m}}\frac{1}{4^m} = \frac{\sqrt{2}}{C}\cdot\frac{1}{\sqrt{m}} =: C'\cdot\frac{1}{\sqrt{m}}\,. \tag{5.10}$$

Budući da je $\sum_{m=1}^{\infty} \frac{1}{\sqrt{m}} = \infty$, slijedi $\sum_{n=1}^{\infty} p_{00}^{(n)} = \sum_{m=1}^{\infty} p_{00}^{(2m)} = \infty$, tj. jednostavna simetrična slučajna šetnja na $\mathbb{Z}$ je **povratna**.

ZADATAK. Pokažite da za općeniti $p \in (0,1)$, vrijedi

$$p_{00}^{(2m)} \sim C' \cdot \frac{(4pq)^m}{\sqrt{m}}\,,$$

te da za $p \neq \frac{1}{2}$ slijedi da je šetnja **prolazna** (za $p \neq \frac{1}{2}$ je $4pq < 1$). □

Alternativno, šetnju uvijek možemo konstruirati kao $S_n := \sum_{i=1}^{n} Y_i$, $n \geqslant 1$, gdje su koraci šetnje $(Y_i)_{i\geqslant 1}$ njd niz sa zajedničkom distribucijom $\mathbb{P}(Y_i = 1) = p, \mathbb{P}(Y_i = -1) = q$. Budući da je $\mathbb{E}[Y_1] = p - q$, iz *jakog zakona velikih brojeva* slijedi

$$\mathbb{P}\left(\lim_{n\to\infty} \frac{S_n}{n} = p - q\right) = 1\,.$$

Specijalno, ako je $p \neq q$, npr. ako je $p > q$ [tj. šetnja ima pozitivan *drift*], iz $p - q > 0$ slijedi da je nužno

$$\mathbb{P}\left(\lim_{n\to\infty} S_n = +\infty\right) = 1\,,$$

što nadalje povlači da je i $\mathbb{P}(N_0 < \infty) = 1$, tj. šetnja je u ovom slučaju prolazna.

5.3.2. Jednostavna simetrična šetnja na $\mathbb{Z}^2$. [Nacrtati sliku.] Sada je $S_n = (S_n^{(1)}, S_n^{(2)}) \in \mathbb{Z}^2$, te uočimo da su projekcije $(S_n^{(1)})_{n\geqslant 0}$ i $(S_n^{(2)})_{n\geqslant 0}$ ML na $\mathbb{Z}$ s prijelaznim vjerojatnostima [nacrtati sliku]:

$$p_{i,i+1} = p_{i,i-1} = \frac{1}{4}\,,\ \ p_{i,i} = \frac{1}{2}\,,\ \ i \in \mathbb{Z}\,,$$

Prva ideja bila bi uočiti da je $p_{00}^{(2m)} = \mathbb{P}(S_{2m} = 0) = \mathbb{P}(S_{2m}^{(1)} = 0, S_{2m}^{(2)} = 0)$ te iskoristiti rezultate za slučajne šetnje na $\mathbb{Z}$. Ipak, problem je što su procesi $(S_n^{(1)})_n$ i $(S_n^{(2)})_n$ *zavisni*.

S druge strane, ako s S_n^+ i S_n^- označimo *projekcije* od S_n na pravce $y = x$ i $y = -x$ [nacrtati sliku], slijedi da su procesi $(S_n^+)_{n\geqslant 0}$ i $(S_n^-)_{n\geqslant 0}$ *nezavisne* jednostavne simetrične slučajne šetnje na $\frac{\sqrt{2}}{2}\mathbb{Z}$!

[Formalno, ako su $(Y_i)_{i\geqslant 1}$ koraci originalne šetnje $(S_n)_n$, vrijedi

$$\mathbb{P}(Y_i^+ = a, Y_i^- = b) = \frac{1}{4}\,,\ \ \forall a, b \in \{-\sqrt{2}/2, \sqrt{2}/2\}\,.$$

Specijalno,

$$Y_i^+ \sim Y_i^- \sim \begin{pmatrix} -\sqrt{2}/2 & \sqrt{2}/2 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

te su Y_i^+ i Y_i^- *nezavisne*. Tvrdnja sada slijedi odmah budući da su $(Y_i^+)_{i\geqslant 1}$ i $(Y_i^-)_{i\geqslant 1}$ koraci šetnja $(S_n^+)_n$ i $(S_n^-)_n$.]

Sada odmah dobivamo

$$p_{00}^{(2m)} = \mathbb{P}(S_{2m} = 0) = \mathbb{P}(S_{2m}^+ = 0, S_{2m}^- = 0) = \mathbb{P}(S_{2m}^+ = 0)^2\,,$$

pa iz (5.10) slijedi

$$p_{00}^{(2m)} \sim \left(\frac{C'}{\sqrt{m}}\right)^2 = (C')^2 \cdot \frac{1}{m}\,, \quad \text{kada } m \to \infty.$$

Iz $\sum_{m=1}^{\infty} \frac{1}{m} = \infty$ slijedi da je jednostavna simetrična slučajna šetnja na $\mathbb{Z}^2$ **povratna**.

5.3.3. Jednostavna simetrična šetnja na $\mathbb{Z}^3$. Sada imamo

$$\mathbb{P}(Y_1 = e_i) = \mathbb{P}(Y_1 = -e_i) = \frac{1}{6}\,, \quad \forall i = 1, 2, 3\,.$$

Intuitivno: za jednostavnu simetričnu slučajnu šetnju na $\mathbb{Z}^d$ pokazali smo

- ako je $d = 1$, $p_{00}^{(2m)} \sim \text{const.} \cdot m^{-\frac{1}{2}}$ $(\sum_m m^{-\frac{1}{2}} = \infty)$;
- ako je $d = 2$, $p_{00}^{(2m)} \sim \text{const.} \cdot m^{-\frac{2}{2}}$ $(\sum_m m^{-1} = \infty)$.

U slučaju $d = 3$ očekujemo da je

$$p_{00}^{(2m)} \sim \text{const.} \cdot m^{-\frac{3}{2}}\,,$$

pa budući da je $\sum_m m^{-\frac{3}{2}} < \infty$, to bi povlačilo da je jednostavna simetrična slučajna šetnja na $\mathbb{Z}^3$ **prolazna**. Ispostavlja se da je ovaj zaključak točan, formalan dokaz tvrdnje da je $\sum_{n\geqslant 1} p_{00}^{(n)} < \infty$, barem onaj koji ćemo prezentirati ovdje, je čisto kombinatoran te ne otkriva previše, pa ga ostavljamo studentima da sami pogledaju, vidi potpoglavlje 5.3.4. Napomenimo još da se može pokazati da je u ovom slučaju vjerojatnost povratka $\mathbb{P}_0(T_0^{(1)} < \infty) \approx 0.3405$. [Što je s povratnosti u slučaju $d \geqslant 4$?]

Napomena 5.14 (**Chung-Fuchsov kriterij**). [Iz prethodnog se može dobiti dojam da je, u dimenzijama $d = 1$ i $d = 2$, "simetričnost" ono što je zaista bitno za povratnost. Ipak, to zapravo nije tako, već je ključan uvjet da šetnja nema *drift*. Preciznije...] Može se pokazati da za slučajne šetnje na $\mathbb{Z}^d$ (dakle, ne nužno samo jednostavne, pa dakle ne nužno i ireducibilne), vrijede sljedeći rezultati.

- ako je $d = 1$ i $\mathbb{E}[Y_1] = 0$, sva stanja su povratna;
- ako je $d = 2$, $\mathbb{E}[Y_1] = (0, 0)$, i $\text{Var}(Y_1^{(1)}), \text{Var}(Y_1^{(2)}) < \infty$, sva stanja su povratna;
- ako je $d = 3$ i ne postoji ravnina D t.d. $\mathbb{P}(Y_1 \in D) = 1$, sva stanja su prolazna.

5.3.4. Dokaz prolaznosti jednostavne simetrične slučajne šetnje na $\mathbb{Z}^3$. Želimo pokazati da je $\sum_{n\geqslant 1} p_{00}^{(n)} < \infty$. Za $m \geqslant 1$ vrijedi $S_{2m} = 0$ akko je

- broj koraka desno i (do trenutka $2m$) = broj koraka lijevo,
- broj koraka gore j = broj koraka dolje, te
- broj koraka naprijed k = broj koraka nazad

Ukupna suma broja svih koraka je naravno $2\cdot(i+j+k) = 2m$, tj. $i+j+k = m$; u nastavku uvijek pretpostavljamo da su $i, j, k \in \mathbb{N}_0$. Dakle, prebrojavanjem svih takvih trajektorija dobivamo

da je

$$p_{00}^{(2m)} = \sum_{i+j+k=m} \frac{(2m)!}{(i!)^2(j!)^2(k!)^2} \left(\frac{1}{6}\right)^{2m} = \binom{2m}{m} \left(\frac{1}{2}\right)^{2m} \sum_{i+j+k=m} \left(\frac{m!}{i!j!k!}\right)^2 \left(\frac{1}{3}\right)^{2m} .$$

Prvo primijetimo da vrijedi

$$\sum_{i+j+k=m} \frac{m!}{i!j!k!} \left(\frac{1}{3}\right)^m = 1 ,$$

Zaista, ako zamislimo da svaku od m kuglica koje imamo nezavisno i uniformno rasporedimo u jednu od tri kutije, gornji sumand za svaki i, j, k je točno vjerojatnost da je i kuglica u 1. kutiji, j kuglica u 2. kutiji, te k kuglica u 3. kutiji, pa tvrdnja slijedi jer sumiramo po svim mogućim rasporedima kuglica. Druga stvar je primijetiti da je u slučaju $m = 3l$, za $l \geqslant 1$, za sve i, j, k takve da je $i + j + k = m = 3l$, nužno $i!j!k! \geqslant (l!)^3$, te specijalno

$$\frac{m!}{i!j!k!} \leqslant \frac{m!}{(l!)^3} = \frac{(3l)!}{(l!)^3} .$$

Kada spojimo ove dvije tvrdnje te primijenimo Stirlingovu formulu, dobivamo

$$p_{00}^{(6l)} \leqslant \binom{6l}{3l} \left(\frac{1}{2}\right)^{6l} \cdot \frac{(3l)!}{(l!)^3} \left(\frac{1}{3}\right)^{3l} \cdot 1 \sim \frac{\sqrt{2}}{C^3} \cdot \frac{1}{l^{3/2}} ,$$

kada $l \to \infty$. Uočimo da za sve $l \geqslant 1$ vrijedi

$$p_{00}^{(6l)} \geqslant p_{00}^{(6l-2)} \left(\frac{1}{6}\right)^2 , \quad p_{00}^{(6l)} \geqslant p_{00}^{(6l-4)} \left(\frac{1}{6}\right)^4 ,$$

Zaista, jedan mogući način da budemo u ishodištu nakon $6l$ koraka je da u ishodištu budemo nakon $6l - 2$ korak te onda napravimo po jedan korak desno i lijevo. Sada slijedi da je

$$\begin{aligned} \sum_{n=1}^{\infty} p_{00}^{(2m)} &= \sum_{l=1}^{\infty} \left(p_{00}^{(6l)} + p_{00}^{(6l-2)} + p_{00}^{(6l-4)}\right) \\ &\leqslant (1 + 6 + 6^2) \cdot \sum_{l=1}^{\infty} p_{00}^{(6l)} < \infty . \end{aligned}$$

Dakle, jednostavna simetrična slučajna šetnja na $\mathbb{Z}^3$ je **prolazna**.

POGLAVLJE 6

Stacionarna distribucija

6.1. Definicija i osnovna svojstva

Za ML $(X_n)_{n\geqslant 0}$ na S s prijelaznom matricom P, zanima nas *postoji* li distribucija $\pi = (\pi_i : i \in S)$ na S takva da vrijedi

$$\lim_{n\to\infty} \mathbb{P}(X_n = j) = \pi_j\,, \quad \forall j \in S\,. \tag{6.1}$$

U tom slučaju kažemo da lanac (tj. slučajni proces) $(X_n)_{n\geqslant 0}$ na S **konvergira po distribuciji** prema π (oznaka "$X_n \xrightarrow{d} \pi$"), te da je π **granična distribucija**.

Primjer 6.1. Promatramo lanac na $S = \{0, 1, \ldots, 10\}$ s prijelaznim vjerojatnostima

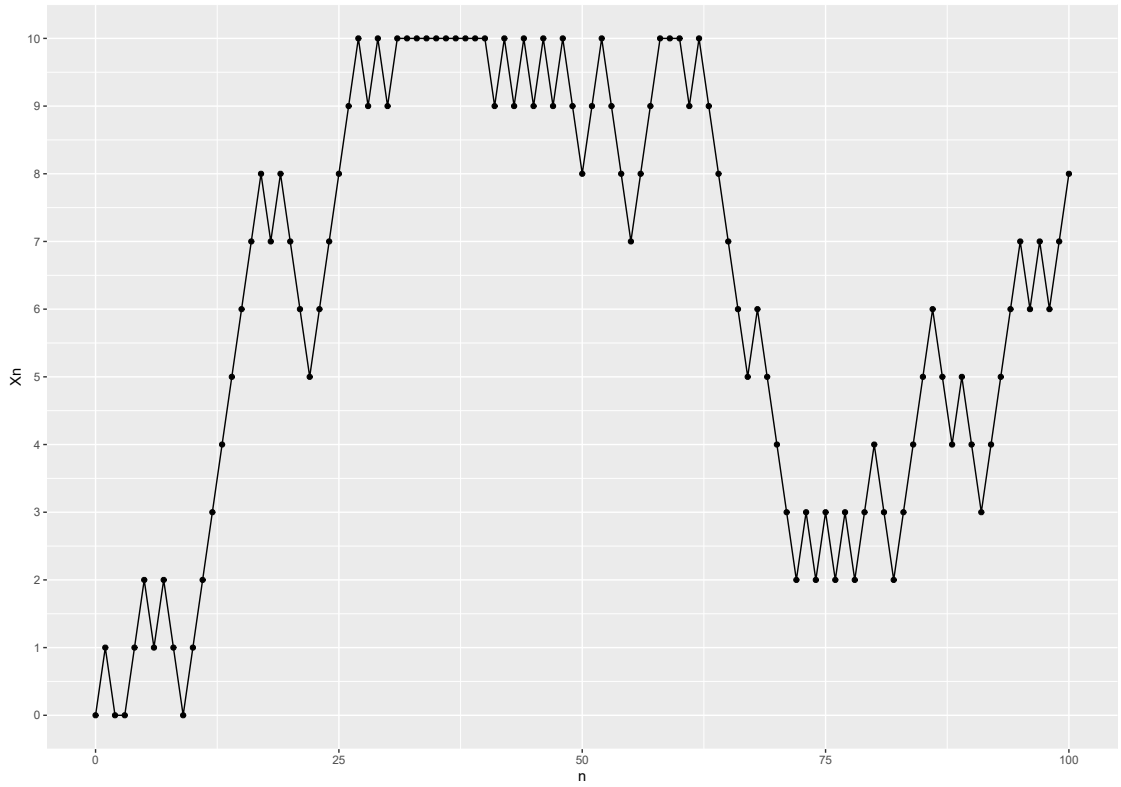
$$p_{i,i+1} = p_{10,10} = 0.6\,,\ i = 0, \ldots, 9$$
$$p_{i,i-1} = p_{0,0} = 0.4\,,\ i = 2, \ldots, 10\,.$$

uz $X_0 := 0$. Zanima nas razdioba $\mathbb{P}(X_n = \cdot\,)$ za $n = 0, 1, 2, \ldots$. U tu svrhu simulirat ćemo trajektoriju lanca $(X_0, X_1, \ldots, X_{100})$ veliki broj puta, te za svaki $n \in \{0, 1, \ldots, 100\}$, za sve $i \in S$ izračunati prosječan broj puta za koje je vrijedilo $X_n = i$ – na taj način za sve takve n dobivamo procjenu distribucije $\mathbb{P}(X_n = \cdot)$.

Na Slici 1 dolje je prikaz jedne takve trajektorije Na Slikama 2 i 3 (dolje niže) je prikaz procijenjenih distribucija $\mathbb{P}(X_n = \cdot\,)$ za razne n-ove. Simulacije sugeriraju da granična razdioba postoji te da stavlja veću masu na $i \in S$ koji su bliže 10. Pokazat ćemo da to zaista je slučaj te da jednostavno možemo precizno odrediti graničnu razdiobu. □

[Napomena.(*) Ako je $S \subseteq \mathbb{R}$, tj. $(X_n)_{n\geqslant 0}$ je niz slučajnih varijabli, oblik konvergencije po distribuciji dan u (6.1) je *jači* od standardnog pojma konvergencije po distribuciji definiranog preko konvergencije pripadnih funkcija distribucije (vidi kolegij Vjerojatnost). Na primjer, niz konstantnih slučajnih varijabli $X_n = 1/n$, u standardnom smislu konvergira po distribuciji prema konstanti 0, ali ako se shvati kao slučajni proces na $S = \{1/n : n \in \mathbb{N}\} \cup \{0\}$, ne vrijedi (6.1) niti za jednu razdiobu π jer $\mathbb{P}(X_n = j) \to 0$ za svaki $j \in S$.]

[Sada pokazujemo da, ukoliko je π granična razdioba, ona nužno mora zadovoljavati određeno svojstvo *invarijantnosti*.]



SLIKA 1. Prikaz jedne trajektorije.

PROPOZICIJA 6.2. *Ako je π vjerojatnosna distribucija na S te vrijedi $X_n \xrightarrow{d} \pi$, π nužno zadovoljava*

$$\pi_j = \sum_{k\in S} \pi_k p_{kj}\,,\ \forall j \in S\,, \tag{6.2}$$

to jest [ako π shvatimo kao vektor-redak dimenzije $1 \times |S|$],

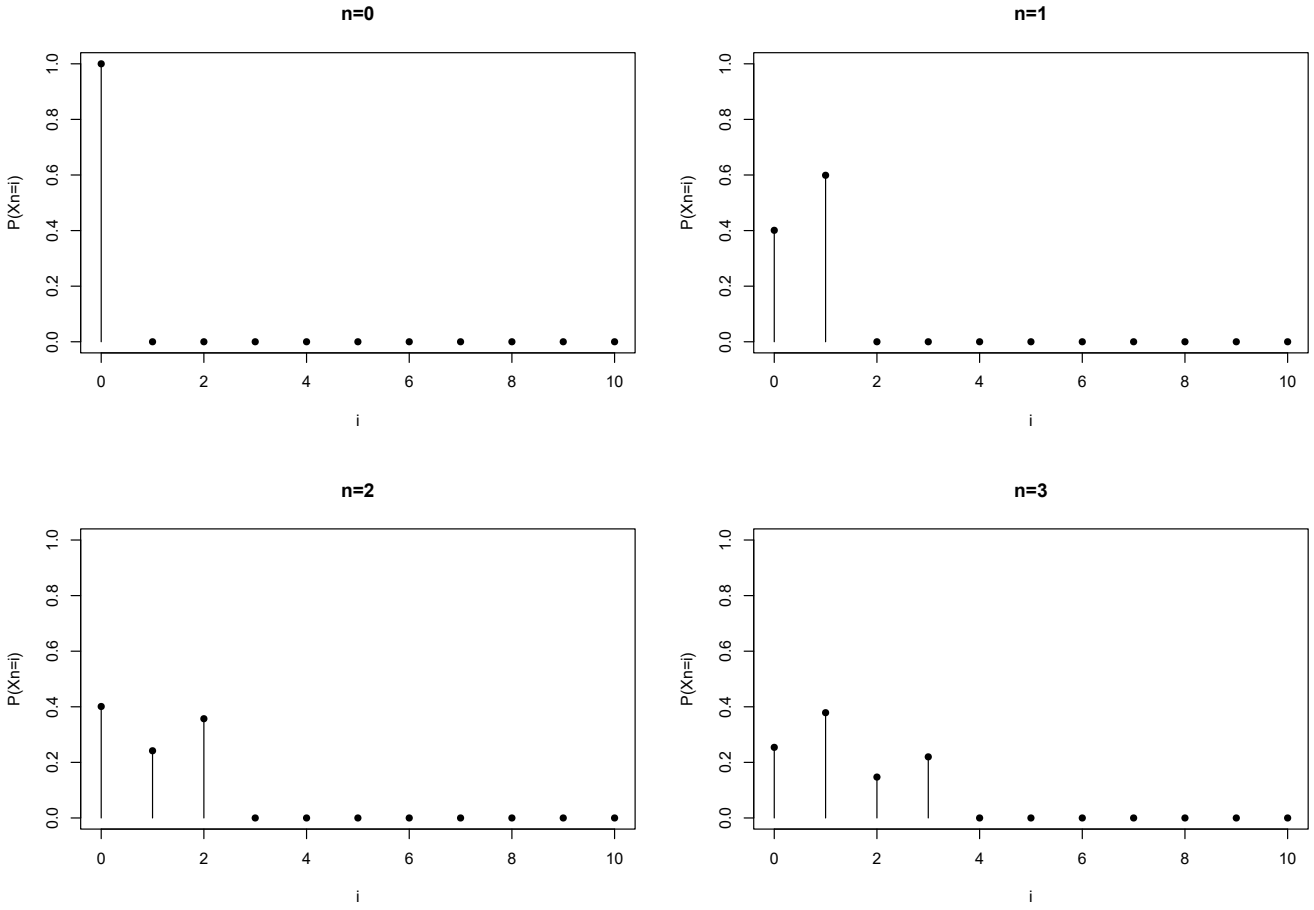
$$\pi = \pi P\,. \tag{6.3}$$

[Ako o distribucijama razmišljamo kao o raspodjeli mase na stanja iz S (vidi Potpoglavlje 1.5), uvjet (6.2) možemo interpretirati na sljedeći način: ako je trenutna raspodjela mase upravo π te ona zadovoljava (6.2), nakon preraspodjele prema prijelaznim vjerojatnostima iz P masa u svim stanjima ostat će ista.]

DOKAZ. Pretpostavimo najprije da je $|S| < \infty$. Imamo

$$\begin{aligned}
\pi_j &\overset{(6.1)}{=} \lim_{n\to\infty} \mathbb{P}(X_n = j) = \lim_{n\to\infty} \mathbb{P}(X_{n+1} = j) = \lim_{n\to\infty} \sum_{k\in S} \mathbb{P}(X_{n+1} = j, X_n = k) \\
&= \lim_{n\to\infty} \sum_{k\in S} \mathbb{P}(X_n = k) \underbrace{\mathbb{P}(X_{n+1} = j \mid X_n = k)}_{p_{kj}} = [|S| < \infty] \\
&= \sum_{k\in S} \lim_{n\to\infty} \mathbb{P}(X_n = k) p_{kj} \overset{(6.1)}{=} \sum_{k\in S} \pi_k p_{kj}\,.
\end{aligned}$$

Dokaz u općenitom slučaju kada je S prebrojiv skup je konceptualno isti, ali zamjenu sume i limesa u petoj jednakosti ne možemo tako jednostavno provesti; dokaz pogledati sami.



SLIKA 2. Procijenjene distribucije $\mathbb{P}(X_n = \cdot)$ za prvih nekoliko n-ova.

[BSOMP da je $S = \{1, 2, \dots, \}$ (jednostavno elemente od S poredamo u niz). Za svaki $m \geqslant 1$ imamo

$$\pi_j \overset{(6.1)}{=} \lim_{n\to\infty} \sum_{k=1}^{\infty} \mathbb{P}(X_n = k) p_{kj} \geqslant \lim_{n\to\infty} \sum_{k=1}^{m} \mathbb{P}(X_n = k) p_{kj} \overset{(6.1)}{=} \sum_{k=1}^{m} \pi_k p_{kj} \,.$$

Puštajući $m \to \infty$ dakle dobivamo da za sve $j \in S$ vrijedi[1]

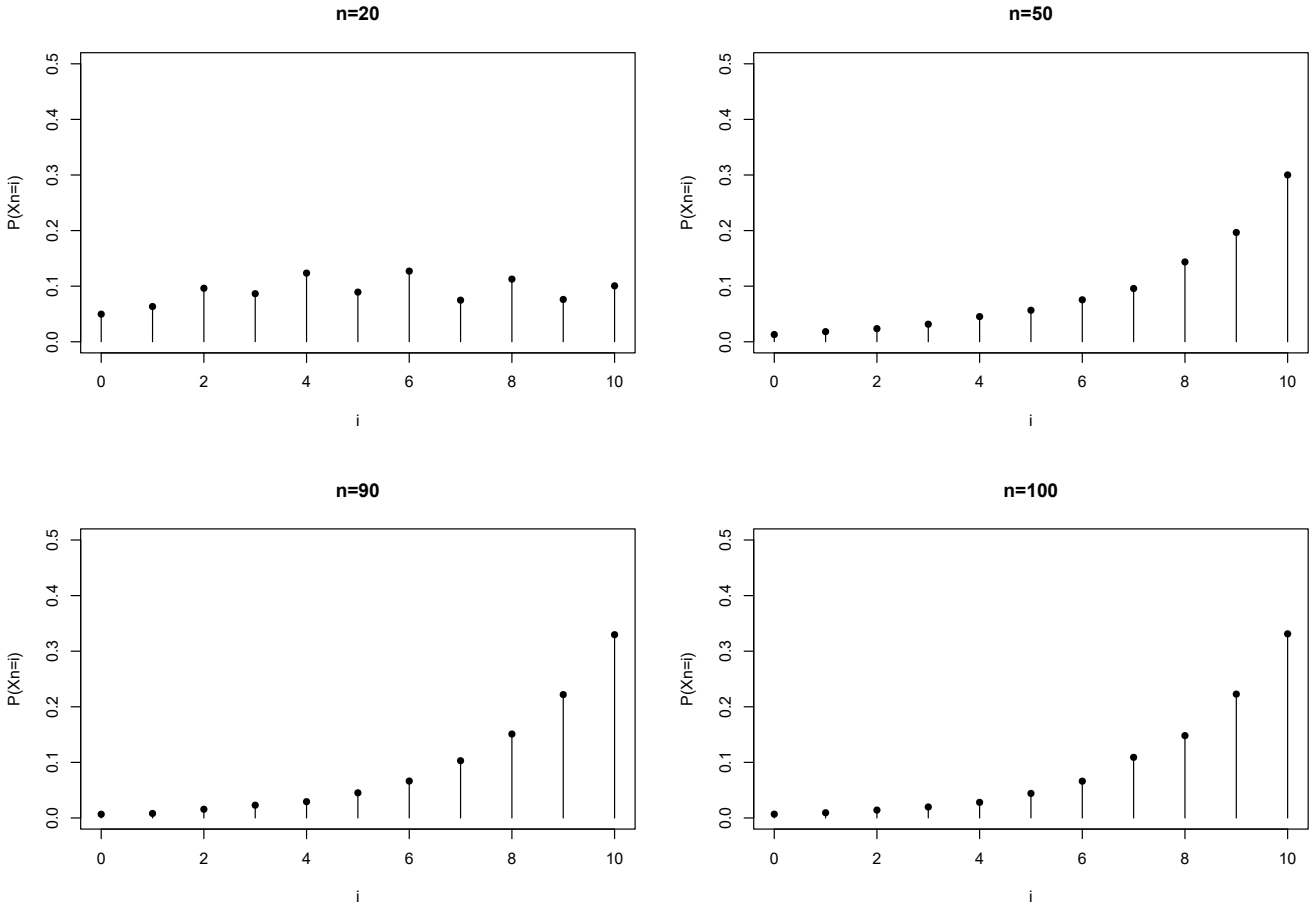
$$\pi_j \geqslant \sum_{k=1}^{\infty} \pi_k p_{kj} \,. \tag{6.4}$$

Pretpostavimo da postoji $j_0 \in S$ takav da u (6.4) vrijedi stroga nejednakost, tj. $\pi_{j_0} > \sum_{k=1}^{\infty} \pi_k p_{kj_0}$. Budući da je π vjerojatnosna distribucija, vrijedi

$$\begin{aligned} 1 &= \sum_{j=1}^{\infty} \pi_j > \sum_{j=1}^{\infty} \sum_{k=1}^{\infty} \pi_k p_{kj} = \text{[Fubini, tj. (B.1), jer je sve nenegativno]} \\ &= \sum_{k=1}^{\infty} \pi_k \underbrace{\sum_{j=1}^{\infty} p_{kj}}_{=1,\,\forall k} = \sum_{k=1}^{\infty} \pi_k = 1 \,, \end{aligned}$$

što je dakle kontradikcija. Dakle, za sve $j \in S$ u (6.4) zapravo imamo jednakost.] □

[1] Ovo zapravo odmah slijedi iz tzv. *Fatouove leme*.



Slika 3. Procijenjene distribucije $\mathbb{P}(X_n = \cdot)$ za veće n-ove.

Definicija 6.3. Svaku distribuciju $\pi = (\pi_i : i \in S)$ koja zadovoljava (6.2) nazivamo **stacionarna** (ili **invarijantna**) distribucija ML-a $(X_n)_{n\geqslant 0}$ (odnosno prijelazne matrice P).

Primjer 6.4. Na $S = \{1, 2\}$, za $a, b \in (0, 1)$ promatramo prijelaznu matricu

$$P = \begin{array}{c} \\ 1 \\ 2 \end{array} \begin{array}{c} \begin{array}{cc} 1 & \quad 2 \end{array} \\ \begin{bmatrix} 1-a & a \\ b & 1-b \end{bmatrix} \end{array}$$

Vektor $\pi = (\pi_1, \pi_2)$ je stacionarna distribucija ako vrijedi[2]

$$\begin{cases} \pi_1 = \pi_1 \cdot (1-a) + \pi_2 \cdot b \\ \pi_2 = \pi_1 \cdot a + \pi_2 \cdot (1-b)\,. \end{cases}$$

Ako sumiramo ove dvije jednadžbe vidimo da su one ekvivalentne [i zapravo će uvijek jedna jednadžba biti višak], ali imamo dodatni uvjet $\pi_1 + \pi_2 = 1$ (te $\pi_1, \pi_2 \geqslant 0$) iz čega lako dobivamo da je jedinstveno rješenje dano s

$$\pi_1 = \frac{b}{a+b}\,, \quad \pi_2 = \frac{a}{a+b}\,.$$

[2] Za razliku od apsorpcijskih vjerojatnosti, za sve $j \in S$ gledamo iz kojih sve stanja i s kojom vjerojatnsti možemo u jednom koraku prijeći u j.

Pokazat ćemo da [u ovom i mnogim drugim slučajevima] vrijedi obrat Propozicije 6.2, tj. da $X_n \xrightarrow{d} \pi$!

NAPOMENA 6.5 (**Što nam još govori stacionarna razdioba?**). Pokazat ćemo da, ako je $(X_n)_{n\geqslant 0}$ ireducibilan i postoji stacionarna distribucija π, vrijedi

(a) $\mathbb{E}_i[T_i^{(1)}] = \frac{1}{\pi_i}$ [očekivano vrijeme povratka];

(b) $\mathbb{E}_i\Big[\sum_{n=0}^{T_i^{(1)}-1} \mathbb{1}_{\{X_n=j\}}\Big] = \frac{\pi_j}{\pi_i}$ [očekivani broj posjeta stanju između dva posjeta drugom stanju];

(c) $\mathbb{P}(\frac{1}{n}\sum_{i=0}^{n-1} \mathbb{1}_{\{X_n=j\}} \overset{n\to\infty}{\longrightarrow} \pi_j) = 1$ [asimptotsko prosječno vrijeme provedeno u stanju].

[Lijepa stvar je to što, bilo da želimo precizno odrediti ili samo naslutiti što je stacionarna razdioba, možemo koristiti karakterizaciju koja nam najviše odgovara u tom slučaju.]

6.1.1. Zašto "stacionarna" distribucija? Za svaku distribuciju π na S, neka je $\mathbb{P}_\pi := \sum_{i\in S} \pi_i \mathbb{P}_i$ vjerojatnost uz koju je početna distribucija lanca $(X_n)_{n\geqslant 0}$ upravo π.

NAPOMENA 6.6. Budući da je $\mathbb{P}_\pi(X_0 = j) = \pi_j$, a $\mathbb{P}_\pi(X_1 = j) = (\pi P)_j$, za sve $j \in S$, vidimo da je π stacionarna razdioba akko je

$$\mathbb{P}_\pi(X_0 = j) = \mathbb{P}_\pi(X_1 = j)\,,\ \forall j \in S,$$

tj. ako uz $\mathbb{P}_\pi$, X_0 i X_1 imaju *istu distribuciju* (oznaka $X_0 \overset{d}{=} X_1$). Štoviše, iz $\pi = \pi P$ slijedi i

$$\pi = \pi P = (\pi P)P = \pi P^2 = \cdots = \pi P^n\,,\ \forall n \geqslant 0\,,$$

tj. ako je π stacionarna razdioba, s obzirom na $\mathbb{P}_\pi$ vrijedi

$$X_n \overset{d}{=} X_0 \sim \pi\,,\ \forall n \geqslant 0\,. \tag{6.5}$$

DEFINICIJA 6.7. Slučajni proces $(X_n)_{n\geqslant 0}$ s vrijednostima u S [dakle, ne nužno ML] definiran na $(\Omega, \mathcal{F}, \mathbb{P})$ je **stacionaran** ako za sve $k, n \geqslant 0$, vrijedi $(X_0, \ldots, X_k) \overset{d}{=} (X_n, \ldots, X_{n+k})$, to jest

$$\mathbb{P}(X_0 = i_0, \ldots, X_k = i_k) = \mathbb{P}(X_n = i_0, \ldots, X_{n+k} = i_k)\,, \quad \forall i_0, \ldots, i_k \in S\,. \tag{6.6}$$

□

Iz (6.6) za $k = 0$ specijalno slijedi i $X_n \overset{d}{=} X_0$, $\forall n \geqslant 1$. [Intuitivno, kod stacionarnih procesa ne samo da se marginalna razdioba ne mijenja kroz vrijeme, već cijela zavisnost ostaje ista. Sljedeći rezultat pokazuje da je kod Markovljevi lanaca, stacionarnost zapravo ekvivalentna s (6.5).]

TEOREM 6.8. *Ako je π stacionarna distribucija za P, a $(X_n)_{n\geqslant 0}$ (π, P)-ML, proces $(X_n)_{n\geqslant 0}$ je stacionaran. Specijalno, za sve $n \geqslant 0$, proces $(X_{n+k})_{k\geqslant 0}$ je ponovno (π, P)-ML.*

DOKAZ. Za sve $k, n \geqslant 0$, $i_0, \ldots, i_k \in S$, vrijedi

$$\begin{aligned}\mathbb{P}(X_n = i_0, \ldots, X_{n+k} = i_k) &= \mathbb{P}(X_n = i_0)\mathbb{P}(X_{n+1} = i_1, \ldots, X_{n+k} = i_k \mid X_n = i_0)\\ &= [(6.5) + \text{MS u trenutku } n] = \pi_{i_0} \cdot p_{i_0 i_1} p_{i_1 i_2} \cdots p_{i_{k-1} i_k}\\ &= [(X_n)_{n\geqslant 0} \text{ je } (\pi, P)\text{-ML}] = \mathbb{P}(X_0 = i_0, \ldots, X_k = i_k)\,.\end{aligned}$$

□

6.1.2. Invarijantna mjera. [Ako o distribuciji ML-a razmišljamo kao o preraspodjeli mase u stanjima iz S prema matrici prijelaza P, prirodno se čini promatrati i slučaj kada ukupna masa u stanjima nije nužno 1. Takve raspodjele ćemo zvati *mjere*, te će nam također biti korisne.]

Vektor $\lambda = (\lambda_i : i \in S)$ je **mjera** (na S) ako vrijedi $\lambda_i \in [0, \infty)$, $\forall i \in S$. Kažemo da je **netrivijalna** ako je $\pi_i > 0$ za neki $i \in S$.

DEFINICIJA 6.9. Netrivijalna mjera λ na S je **invarijantna mjera** za P ako vrijedi $\lambda = \lambda P$.

NAPOMENA 6.10. Samo ispričati.

[(a) Stacionarna distribucija je invarijantna mjera koja je ujedno i vjerojatnosna distribucija.

(b) Ako je λ invarijantna mjera, onda je za sve $c > 0$, mjera $c\lambda := (c\lambda_i : i \in S)$ također invarijantna mjera jer je

$$(c\lambda)P = c(\lambda P) = c\lambda\,.$$

(c) Ako je λ invarijantna mjera takva da je $\sum_{j\in S} \lambda_j < \infty$, tada je

$$\pi_i := \frac{\lambda_i}{\sum_{j\in S} \lambda_j}\,, \quad i \in S\,,$$

stacionarna distribucija.] □

Uočimo, λ je invarijantna mjera akko vrijedi $P^t\lambda^t = \lambda^t$, pri čemu je dakle λ^t vektor-stupac dimenzije $|S| \times 1$. Dakle, ako je $|S| < \infty$, λ je invarijantna mjera akko je λ^t **svojstveni vektor** matrice P^t za svojstvenu vrijednost 1 i to takav da je $\lambda \geqslant 0$. Zbog toga je moguće koristiti metode linearne algebre kako bi npr. pokazali egzistenciju i jedinstvenost invarijantne mjere.[3] Ipak, naš pristup će biti vjerojatnosan – to je sadržaj iduća dva potpoglavlja.

6.2. Egzistencija invarijantne mjere/distribucije

Neka je $(X_n)_{n\geqslant 0}$ ML na S sa prijelaznom matricom P, te $T_i^{(1)} = \min\{n \geqslant 1 : X_n = i\}$ prvo vrijeme povratka u stanje $i \in S$. Za fiksno stanje $i \in S$ definiramo

$$\nu_j^{(i)} := \mathbb{E}_i\Big[\sum_{n=0}^{T_i^{(1)}-1} \mathbb{1}_{\{X_n = j\}}\Big] \in [0, \infty]\,. \tag{6.7}$$

Očito je $\nu_i^{(i)} = 1$, za $j \neq i$, $\nu_j^{(i)}$ je **očekivani broj posjeta stanju j između dva posjeta stanju i.**

[3] Vidi *Perron-Frobeniusov* teorem.

[U nastavku ćemo pokazati da je $\nu^{(i)}$ invarijantna mjera čim je i povratno stanje, te da se ta mjera može normalizirati do stacionarne distribucije ako je dodatno i očekivano vrijeme povratka u stanje i konačno. Ključno pitanje je zašto je u tom slučaju $\nu^{(i)}$ stacionarna (granična) distribucija (nakon skaliranja)? Odgovor na to vidjet ćemo tek kasnije iz dokaza Ergodskog teorema – vidi Napomenu 8.5. Ugrubo, trajektoriju ML-a možemo rastaviti na izlete iz stanja i koji će zbog JMS-a biti nezavisni i jednako distribuirani – zbog jakog zakona velikih brojeva, vjerojatnost da se lanac nakon puno vremena nalazi u stanju j bit će određena očekivanim brojem posjeta stanju j na jednom izletu.]

TEOREM 6.11. *ako je $i \in S$ povratno stanje, vrijedi*

(a) $\nu^{(i)} = \nu^{(i)} P$;

(b) $\nu_j^{(i)} < \infty$, $\forall j \in S$.

Specijalno, $\nu^{(i)}$ je invarijanta mjera za P.

DOKAZ. Označimo, radi jednostavnosti, $\nu_j := \nu_j^{(i)}$, $\forall j \in S$.

- Vrijedi

$$\nu_j = \mathbb{E}_i\Big[\sum_{n=0}^{T_i^{(1)}-1} \mathbb{1}_{\{X_n=j\}}\Big] = \mathbb{E}_i\Big[\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=j, n<T_i^{(1)}\}}\Big] = \sum_{n=0}^{\infty} \mathbb{E}_i\Big[\mathbb{1}_{\{X_n=j, n<T_i^{(1)}\}}\Big]$$
$$= \sum_{n=0}^{\infty} \mathbb{P}_i\Big(X_n = j, n < T_i^{(1)}\Big), \tag{6.8}$$

  pri čemu smo u trećoj jednakosti iskoristli teorem o monotonoj konvergencije (TMK), vidi Dodatak B.

- Budući da je i povratno stanje, tj. $\mathbb{P}_i(T_i^{(1)} < \infty) = 1$, te vrijedi $X_{T_i^{(1)}} = i$, vrijedi

$$\nu_j = \mathbb{E}_i\Big[\sum_{n=1}^{T_i^{(1)}} \mathbb{1}_{\{X_n=j\}}\Big] = [\text{analogno}] = \sum_{n=1}^{\infty} \mathbb{P}_i\Big(X_n = j, n \leqslant T_i^{(1)}\Big). \tag{6.9}$$

  Gdje smo točno koristili povratnost? Uočimo da prva jednakost u (6.9) vrijedi uvijek za $j \neq i$, ali ako je $j = i$ imamo

$$\mathbb{E}_i\Big[\sum_{n=1}^{T_i^{(1)}} \mathbb{1}_{\{X_n=i\}}\Big] = \mathbb{E}_i\Big[\mathbb{1}_{\{T_i^{(1)}<\infty\}}\Big] = \mathbb{P}(T_i^{(1)} < \infty),$$

  pa budući da je $\nu_i = 1$, prva jednakost u (6.9) za $j = i$ vrijedi akko je i povratno stanje.

(a) Za sve $j \in S$ imamo

$$\nu_j \overset{(6.9)}{=} \sum_{n=1}^{\infty} \mathbb{P}_i\Big(X_n = j, n \leqslant T_i^{(1)}\Big) = \sum_{n=1}^{\infty} \sum_{k\in S} \mathbb{P}_i\Big(X_n = j, X_{n-1} = k, n \leqslant T_i^{(1)}\Big).$$

Uočimo da događaj $\{n \leqslant T_i^{(1)}\}$ zapravo ovisi samo o $X_0, \ldots, X_{n-1}$, tj. preciznije

$$\{n \leqslant T_i^{(1)}\} = \{T_i^{(1)} \leqslant n-1\}^c \in \sigma(X_0, \ldots, X_{n-1}).$$

Sada koristeći MS u trenutku $n-1$ dobivamo[4]

$$\begin{aligned}
&\mathbb{P}_i\Big(X_n = j, X_{n-1} = k, n \leqslant T_i^{(1)}\Big) \\
&\quad = \mathbb{P}_i\Big(X_{n-1} = k, n \leqslant T_i^{(1)}\Big) \cdot \mathbb{P}_i\Big(X_n = j \mid X_{n-1} = k, n \leqslant T_i^{(1)}\Big) \\
&\quad = \mathbb{P}_i\Big(X_{n-1} = k, n \leqslant T_i^{(1)}\Big) p_{kj}\,,
\end{aligned}$$

pa zamjenom indeksa sumacije (koristimo Fubinijev teorem) dobivamo

$$\begin{aligned}
\nu_j &= \sum_{k\in S} p_{kj} \sum_{n=1}^{\infty} \mathbb{P}_i\Big(X_{n-1} = k, n \leqslant T_i^{(1)}\Big) = [m := n-1] \\
&= \sum_{k\in S} p_{kj} \sum_{m=0}^{\infty} \mathbb{P}_i\Big(X_m = k, m < T_i^{(1)}\Big) \overset{(6.8)}{=} \sum_{k\in S} p_{kj}\nu_k\,.
\end{aligned}$$

Uočimo da gornji račun prolazi i ako je $\nu_k = +\infty$ za neke $k \in S$ uz standardne konvencije $0 \cdot \infty := 0$ i $c \cdot \infty = \infty$ za sve $c > 0$.

(b) Sada pokazujemo da je nužno $\nu_j < \infty$, $\forall j \in S$. Tvrdnja očito vrijedi ako je $j = i$ jer je $\nu_i = 1$, ili ako j nije dostižno iz i jer je $\nu_j = 0$.
Ako vrijedi $i \longrightarrow j$, i povratno povlači da je nužno i $j \longrightarrow i$ (vidi Prop. 5.9), pa postoji $n \geqslant 1$ t.d. $p_{ji}^{(n)} > 0$. Iz (a) dijela znamo da vrijedi

$$\nu = \nu P = \nu P^2 = \cdots = \nu P^n\,,$$

pa bi $\nu_j = \infty$ nužno povlačilo da je i $\nu_i = \infty$. [Intuitivno, to slijedi odmah ako razmišljamo u terminima raspodjele mase u stanjima, gdje dopuštamo da u nekim stanjima imamo masu ∞]. Formalno, $\nu_j = \infty$ bi povlačilo

$$1 = \nu_i = [\nu = \nu P^n] = \sum_{k\in S} \nu_k p_{ki}^{(n)} \geqslant \nu_j p_{ji}^{(n)} = \infty\,,$$

što je kontradikcija.

□

6.2.1. Pozitivna povratnost. Za *povratno* stanje $i \in S$ kažemo da je

- **pozitivno povratno** ako je $\mathbb{E}_i\big[T_i^{(1)}\big] < \infty$;
- **nul-povratno** ako je $\mathbb{E}_i\big[T_i^{(1)}\big] = \infty$.

Uočimo da općenito $\mathbb{E}_i\big[T_i^{(1)}\big] < \infty$ povlači da je $\mathbb{P}_i(T_i^{(1)} < \infty) = 1$, pa je proizvoljno stanje $i \in S$ pozitivno povratno akko je samo $\mathbb{E}_i\big[T_i^{(1)}\big] < \infty$.

Propozicija 6.12. *Ako je $i \in S$ pozitivno povratno stanje, mjera $\pi = (\pi_i : i \in S)$ definirana s $\pi := \frac{1}{\mathbb{E}_i\left[T_i^{(1)}\right]}\nu^{(i)}$, tj.*

$$\pi_j := \frac{1}{\mathbb{E}_i\big[T_i^{(1)}\big]} \mathbb{E}_i\Big[\textstyle\sum_{n=0}^{T_i^{(1)}-1} \mathbb{1}_{\{X_n=j\}}\Big]\,,\quad j \in S\,, \tag{6.10}$$

[4] Uočite da smo ovdje implicitno pretpostavili da je $\mathbb{P}_i\big(X_{n-1} = k, n \leqslant T_i^{(1)}\big) > 0$. Ipak, jednakost prvog i trećeg izraza vrijedi i kada to nije slučaj jer su tada oba izraza očito jednaka 0.

je stacionarna distribucija. Specijalno, $\pi_i = \frac{1}{\mathbb{E}_i[T_i^{(1)}]}$.

Dokaz. Budući da je i povratno znamo da je $\nu^{(i)}$ invarijanta mjera, a budući da uvijek vrijedi

$$\sum_{j\in S} \nu_j^{(i)} = \mathbb{E}_i\left[T_i^{(1)}\right], \tag{6.11}$$

tvrdnja slijedi iz pretpostavke da je $\mathbb{E}_i\left[T_i^{(1)}\right] < \infty$. Formalno, (6.11) slijedi jer je

$$\begin{aligned}\sum_{j\in S}\nu_j^{(i)} &= \sum_{j\in S}\mathbb{E}_i\left[\textstyle\sum_{n=0}^{T_i^{(1)}-1}\mathbb{1}_{\{X_n=j\}}\right] = \text{[TMK+Fubini]}\\ &= \mathbb{E}_i\left[\textstyle\sum_{n=0}^{T_i^{(1)}-1}\sum_{j\in S}\mathbb{1}_{\{X_n=j\}}\right] = \mathbb{E}_i\left[\textstyle\sum_{n=0}^{T_i^{(1)}-1}1\right] = \mathbb{E}_i\left[T_i^{(1)}\right].\end{aligned}$$

□

Napomena 6.13. Ako je skup stanja S konačan te $i \in S$ povratno stanje, iz (6.11) i Teorema 6.11(b) slijedi

$$\mathbb{E}_i\left[T_i^{(1)}\right] = \sum_{j\in S}\nu_j^{(i)} \overset{|S|<\infty}{<} \infty\,.$$

Dakle, ako je S konačan, sva povratna stanja su nužno i pozitivno povratna.

6.3. Jedinstvenost invarijantne mjere/distribucije

Prvo navodimo dva tehnička rezultata, čije dokaze ostavljamo studentima da pogledaju sami.

Propozicija 6.14. *Ako je P ireducibilna matrica prijelaza na S, a λ mjera na S za koju vrijedi $\lambda = \lambda P$ (ovdje dopuštamo mogućnost $\lambda \equiv 0$), tada je nužno (a) $\lambda \equiv 0$, ili (b) $\lambda_i > 0$, za sve $i \in S$.*

Dokaz. Ovo je slično kao dokaz (b) dijela u Teoremu 6.11. Pretpostavimo da postoji $i \in S$ t.d. je $\lambda_i > 0$. Za proizvoljan $j \in S$, $j \neq i$, ireducibilnost povlači da je postoji $n = n(j) \geqslant 1$ t.d. $p_{ij}^{(n)} > 0$, a uvjet $\lambda = \lambda P$ povlači da vrijedi i $\lambda = \lambda P^n$, pa vrijedi

$$\lambda_j = \sum_{k\in S}\lambda_k p_{kj}^{(n)} \geqslant \lambda_i p_{ij}^{(n)} > 0\,.$$

Dakle, ako λ nije nul-mjera, nužno vrijedi $\lambda_j > 0$, za sve $j \in S$. □

Propozicija 6.15. *Ako je λ invarijantna mjera za P takva da vrijedi $\lambda_i = 1$ za neko $i \in S$, tada je $\lambda \geqslant \nu^{(i)}$, tj. $\lambda_j \geqslant \nu_j^{(i)}$, za sve $j \in S$.*

Dokaz. [Dokaz je sličan dokazima minimalnosti u Teoremima 3.4 i 3.6.]

Za $j = i$, imamo $\nu_j^{(i)} = 1 = \lambda_j$ pa tvrdnja očito vrijedi. Ako je $j \neq i$,

$$\begin{aligned}\lambda_j &\overset{\lambda=\lambda P}{=} \sum_{i_0 \in S} \lambda_{i_0} p_{i_0 j} \overset{\lambda_i = 1}{=} p_{ij} + \sum_{i_0 \neq i} \lambda_{i_0} p_{i_0 j} = p_{ij} + \sum_{i_0 \neq i} \left(\sum_{i_1 \in S} \lambda_{i_1} p_{i_1 i_0} \right) p_{i_0 j} \\ &= p_{ij} + \sum_{i_0 \neq i} p_{i i_0} p_{i_0 j} + \sum_{i_0, i_1 \neq i} \lambda_{i_1} p_{i_1 i_0} p_{i_0 j} = \dots\dots \\ &= p_{ij} + \sum_{i_0 \neq i} p_{i i_0} p_{i_0 j} + \dots + \sum_{i_0, \dots, i_{n-1} \neq i} p_{i i_{n-1}} p_{i_{n-1} i_{n-2}} \cdots p_{i_1 i_0} p_{i_0 j} \\ &\quad + \sum_{i_0, \dots, i_n \neq i} \lambda_{i_n} p_{i_n i_{n-1}} p_{i_{n-1} i_{n-2}} \cdots p_{i_1 i_0} p_{i_0 j}\,, \quad \forall n \geqslant 0\,.\end{aligned}$$

Zadnji član je nenegativan, pa za sve $n \geqslant 0$ imamo

$$\begin{aligned}\lambda_j &\geqslant \mathbb{P}_i(X_1 = j) + \mathbb{P}_i(X_1 \neq i, X_2 = j) + \dots + \mathbb{P}_i(X_1 \neq i, \dots, X_n \neq i, X_{n+1} = j) \\ &\overset{j \neq i}{=} \mathbb{P}_i(X_1 = j, T_i^{(1)} > 1) + \mathbb{P}_i(X_2 = j, T_i^{(1)} > 2) + \dots + \mathbb{P}_i(X_{n+1} = j, T_i^{(1)} > n+1)\,.\end{aligned}$$

Puštanjem $n \to \infty$ slijedi

$$\lambda_j \geqslant \sum_{m=1}^{\infty} \mathbb{P}_i(X_m = j, T_i^{(1)} > m) \overset{j \neq i}{=} \sum_{m=0}^{\infty} \mathbb{P}_i(X_m = j, T_i^{(1)} > m) \overset{(6.8)}{=} \nu_j^{(i)}\,,$$

pri čemu (6.8) vrijedi bez obzira je li i povratno ili ne (što je bila pretpostavka Teorema 6.11). □

Teorem 6.16. *Neka je P ireducibilna i povratna matrica prijelaza. Tada za sve $i \in S$ vrijedi*

(a) $\nu^{(i)}$ je invarijanta mjera te vrijedi $\nu_j^{(i)} > 0$, $\forall j \in S$.

(b) Ako je λ prizvoljna invarijantna mjera, nužno je $\lambda_i > 0$ te vrijedi $\frac{1}{\lambda_i}\lambda = \nu^{(i)}$, tj.

$$\nu_j^{(i)} = \mathbb{E}_i\Big[\textstyle\sum_{n=0}^{T_i^{(1)}-1} \mathbb{1}_{\{X_n = j\}}\Big] = \frac{\lambda_j}{\lambda_i}\,, \quad \forall j \in S\,. \tag{6.12}$$

Dokaz. (a) Slijedi iz Teorema 6.11 i Propozicije 6.14 (jer je $\nu_i^{(i)} = 1 > 0$).

(b) Budući da je P ireducibilna, a λ netrivijalna mjera, Prop. 6.14 povlači da je $\lambda_i > 0$ iz čega slijedi da je $\widetilde{\lambda} := \frac{1}{\lambda_i}\lambda$ dobro definirana (netrivijalna) mjera koja je opet invarijantna te vrijedi $\widetilde{\lambda}_i = 1$. Propozicija 6.15 povlači da je nužno $\widetilde{\lambda} \geqslant \nu^{(i)}$. Iz ovoga pak slijedi da je $\mu := \widetilde{\lambda} - \nu^{(i)}$ dobro definirana mjera za koju vrijedi

$$\mu P = \widetilde{\lambda} P - \nu^{(i)} P = \widetilde{\lambda} - \nu^{(i)} = \mu\,.$$

Budući da je po konstrukciji $\mu_i = 0$, Propozicija 6.14 povlači da je $\mu \equiv 0$, tj. $\frac{1}{\lambda_i}\lambda_j = \nu_j^{(i)}$, $\forall j \in S$. □

Napomena 6.17. Ako je P *ireducibilna* i *povratna*, te λ i μ invarijantne mjere, Teorem 6.16 povlači da je $\lambda_j, \mu_j > 0$ za sve $j \in S$ te da postoji $c > 0$ t.d. vrijedi $\lambda = c \cdot \mu$ [tj. invarijantna mjera je **jedinstvena do na multiplikativnu konstantu**]. Specijalno,

- ako je $\sum_{j \in S} \lambda_j = \infty$ za neku invarijantnu mjeru λ, nužno je $\sum_{j \in S} \mu_j = \infty$ za svaku drugu invarijantnu mjeru μ, pa specijalno *ne postoji* stacionarna distribucija.

- ako postoji stacionarna distribucija, nužno je jedinstvena.

PRIMJER 6.18. Za jednostavnu simetričnu slučajnu šetnju $(X_n)_{n\geqslant 0}$ na $\mathbb{Z}$ znamo da je ireducibilna i povratna. Nadalje, $\lambda_i := 1$, $i \in \mathbb{Z}$, jedna invarijanta mjera jer imamo

$$\sum_{i\in\mathbb{Z}} \lambda_i p_{ij} = p_{j-1,j} + p_{j+1,j} = \frac{1}{2} + \frac{1}{2} = 1 = \lambda_j\,, \quad \forall j \in \mathbb{Z}\,.$$

- Budući da je $\sum_{j\in S} \lambda_j = \infty$, slijedi da ne postoji stacionarna distribucija.
- (6.12) povlači

$$\nu_i^{(0)} = \frac{\lambda_i}{\lambda_0} = 1\,, \quad \forall i \in \mathbb{Z}\,,$$

  što je pomalo neočekivano [uzmi npr. $i = 1$ te $i = 10^6$].

[Idući teorem glavni je rezultat cijelog poglavlja.]

TEOREM 6.19. *Neka je $(X_n)_{n\geqslant 0}$ ireducibilan ML s prijelaznom matricom P. Tada je ekvivalentno*

(a) $\forall i \in S$, i je pozitivno povratno stanje;

(b) postoji barem jedno pozitivno povratno stanje $i \in S$;

(c) postoji stacionarna distribucija π.

Nadlaje, ako vrijedi (c) [tj. (a), tj. (b)], π je jedinstvena te nužno vrijedi

$$\mathbb{E}_i[T_i^{(1)}] = \frac{1}{\pi_i}\,, \quad \forall i \in S\,, \tag{6.13}$$

te

$$\nu_j^{(i)} = \frac{\pi_j}{\pi_i}\,, \quad \forall i, j \in S\,. \tag{6.14}$$

DOKAZ. Smjer (a) $\Rightarrow$ (b) je očit, a (b) $\Rightarrow$ (c) smo dokazali u Propoziciji 6.12. Dokažimo da (c) povlači (a).

1. Najprije pokazujemo da je lanac $(X_n)_{n\geqslant 0}$ nužno *povratan*. Pretpostavimo da je prolazan. Tada iz (5.8) znamo da je

$$\lim_{n\to\infty} p_{ji}^{(n)} = 0\,, \quad \forall i, j \in S$$

(jer je $\sum_{n=0}^{\infty} p_{ji}^{(n)} = \mathbb{E}_j[N_i] < \infty$). Sada za sve $i \in S$, imamo

$$\pi_i = \lim_{n\to\infty} \pi_i = [\pi = \pi P^n] = \lim_{n\to\infty} \sum_{j\in S} \pi_j p_{ji}^{(n)} = \sum_{j\in S} \pi_j \lim_{n\to\infty} p_{ji}^{(n)} = 0\,,$$

pri čemu zamjenu limesa i sume možemo opravdati teoreom o dominiranoj konvergenciji (vidi Dodatak B) jer je $\pi_j p_{ji}^{(n)} \leqslant \pi_j$, $\forall j \in S, \forall n \geqslant 0$, te vrijedi $\sum_{j\in S} \pi_j = 1 < \infty$. Ali, to je kontradikcija jer $\sum_{i\in S} \pi_i = 1 > 0$. Dakle, lanac $(X_n)_{n\geqslant 0}$ je povratan.[5]

[5] Uočite da smo u dokazu pokazali i više – za proizvoljan ML, ako je i prolazno stanje i π stacionarna distribucija, nužno je $\pi_i = 0$.

2. [Pokazujemo da je lanac pozitivno povratan.] Budući da je lanac ireducibilan i povratan, te mu je π jedna invarijantna mjera, Teorem 6.16 povlači da je $\pi_i > 0$, $\forall i \in S$, te da je $\nu_j^{(i)} = \frac{\pi_j}{\pi_i}$, za sve $i, j \in S$. Specijalno, za sve $i \in S$, vrijedi

$$\mathbb{E}_i\left[T_i^{(1)}\right] \overset{(6.11)}{=} \sum_{j\in S} \nu_j^{(i)} = \sum_{j\in S} \frac{\pi_j}{\pi_i} = \frac{1}{\pi_i} \overset{\pi_i>0}{<} \infty\,.$$

□

KOROLAR 6.20 (**Pozitivna/nul-povratnost je svojstvo klase komuniciranja**). *Ako je $C \subseteq S$ povratna klasa komuniciranja, vrijedi*

(a) sva stanja iz C su nul-povratna, ili

(b) sva stanja iz C su pozitivno povratna.

DOKAZ. Budući da je C zatvoren skup, možemo gledati restrikciju lanca na skup stanja C. Taj lanac je očito ireducibilan i povratan, pa tvrdnja slijedi iz Teorema 6.19. □

PRIMJER 6.21. Neka je $(X_n)_{n\geqslant 0}$ jednostavna slučajna šetnja na $\mathbb{Z}$ uz $p_{i,i+1} = p, p_{i,i-1} = 1-p =: q$, za sve $i \in \mathbb{Z}$, za $p \in (0,1)$; dakle, lanac je ireducibilan.

- Ako je $p = q = \frac{1}{2}$ [simetričan slučaj], lanac je i povratan te smo pokazali da ne postoji stacionarna distribucija. Teorem 6.19 povlači da je lanac u ovom slučaju *nul-povratan*, tj. $\mathbb{E}_i\left[T_i^{(1)}\right] = \infty$, za sve $i \in S$.
- Ako je $p \neq q$, lako se provjeri da su $\lambda_i := 1$, $\mu_i := \left(\frac{p}{q}\right)^i$, $i \in \mathbb{Z}$, dvije invarijantne mjere, a budući da je $\lambda \neq c \cdot \mu$, za sve $c > 0$, lanac ne može biti povratan, pa je dakle prolazan (što smo naravno znali i od prije).
  [Dakle, općenito, ireducibilnost i postojanje invarijantne mjere ne povlače povratnost.]

NAPOMENA 6.22 (**Konačan skup stanja**). Ako je P ireducibilna, a skup stanja S konačan, lanac je nužno pozitivno povratan (vidi Napomenu 6.13), pa specijalno stacionarna distribucija π *uvijek* postoji, jedinstvena je te zadovoljava (6.13) i (6.14).

PRIMJER 6.23 (**Google PageRank**). Neka je (V, E) usmjereni graf gdje je

- V skup svih web-stranica ($|V| = N < \infty$);
- $(i, j) \in E$ ako stranica i sadrži *link* na stranicu j.

Označimo za sve $i \in V$, s $O_i := |\{j \in V : (i, j) \in E\}|$ ukupan broj bridova koji izlaze iz i ("out-degree").

Za parametar $\alpha \in (0, 1)$ (u Google-u inicijalno koristili $\alpha \approx 0.85$), *slučajni surfer* je ML $(X_n)_{n\geqslant 0}$ na V s prijelaznim vjerojatnostima

$$p_{ij} = \alpha \cdot \widehat{p}_{ij} + (1-\alpha) \cdot \frac{1}{N}\,, \quad \forall i, j \in V\,,$$

gdje je

$$\widehat{p}_{ij} = \begin{cases} \frac{1}{O_i}\,, & \text{ako } O_i \geqslant 1 \text{ te } (i,j) \in E \\ 0\,, & \text{ako } O_i \geqslant 1 \text{ te } (i,j) \notin E \\ \frac{1}{N}\,, & \text{ako } O_i = 0 \end{cases}$$

[Riječima, u svakom koraku, s vjerojatnošću $1-\alpha \approx 0.15$ skačemo u uniformno odabranu stranicu $j \in V$, a inače uniformno biramo jedan od susjeda (ili bilo koju stranicu ako trenutna stranica i nema susjeda).]

Skup stanja je dakle konačan, a zbog $1-\alpha > 0$, lanac je očito i iredubicibilan, pa dakle stacionarna distribucija postoji i jedinstvena je. Nadalje, pokazat ćemo da zapravo vrijedi i

$$\mathbb{P}\left(\frac{1}{n}\sum_{i=0}^{n-1} \mathbb{1}_{\{X_n=j\}} \overset{n\to\infty}{\longrightarrow} \pi_i\right) = 1\,,\ \forall i \in V\,.$$

[Dakle, π_i predstavlja prosječno vrijeme koje će surfer provesti u stranici i nakon velikog broja koraka.]

Brin i Page (osnivači Google-a) su pri rangiranju web-stranica u tražilici, definirali *važnost* stranice i ("PageRank") upravo kao π_i [Kako onda interpretiramo uvjet $\pi_j = \sum_{i\in S}\pi_i p_{ij}$?]. Praktično pitanje je kako izračunati π budući da je broj stranica N jako velik. Budući da je lanac i **aperiodičan** (iduće poglavlje), pokazat ćemo da vrijedi i

$$\nu \cdot P^n \overset{n\to\infty}{\longrightarrow} \pi\,,$$

bez obzira na početnu razdiobu ν. To nam daje idući algoritam za aproksimacuju stac. razdiobe π:

1. Stavi $\nu_0 := (\frac{1}{N}, \ldots, \frac{1}{N})$.
2. Za $k = 1, \ldots, K$ (K dovoljno velik),
$$\nu_k := \nu_{k-1} \cdot P\,.$$
3. Vrati ν_K ($\approx \pi$).

[Ključno je da ν_K računamo iterativno, a ne da prvo odredimo P^K te stavimo $\nu_K := \nu_0 \cdot P^K$.]

POGLAVLJE 7

Granična distribucija

7.1. Aperiodičnost

Za (λ, P)-ML $(X_n)_{n\geqslant 0}$ i vjerojatnosnu distribuciju $\pi = (\pi_i : i \in S)$ na S, pokazali smo da $X_n \xrightarrow{d} \pi$ povlači da π mora biti stacionarna distribucija. Zanimljivije pitanje je vrijedi li i pod kojim uvjetima obrat.

PRIMJER 7.1. Na $S = \{A, B\}$ gledamo lanac s prijelaznim vjerojatnostima $p_{A,B} = p_{B,A} = 1$ [nacrtati sliku]. Očito je $\pi = (\frac{1}{2}, \frac{1}{2})$ stacionarna razdioba, ali npr.

$$\mathbb{P}_A(X_n = B) = p_{A,B}^{(n)} = \begin{cases} 1\,, & \text{ako je } n \text{ neparan,} \\ 0\,, & \text{ako je } n \text{ paran} \end{cases}$$

pa specijalno ne postoji $\lim_{n\to\infty} p_{A,B}^{(n)}$ niti vrijedi $(X_n)_{n\geqslant 0} \xrightarrow{d} \pi$ (uz $X_0 := A$).

[Pokazat ćemo da je "periodičnost" lanca iz prethodnog primjera zapravo jedina prepreka u postojanju granične razdiobe.]

DEFINICIJA 7.2. Neka je $(X_n)_{n\geqslant 0}$ ML na S s prijelaznom matricom P. **Period** stanja $i \in S$ definiramo kao

$$\mathrm{d}(i) := \operatorname{nzd} \underbrace{\{n \geqslant 1 : p_{ii}^{(n)} > 0\}}_{=:\Lambda(i)}\,. \tag{7.1}$$

(Ako je $\Lambda(i) = \emptyset$, stavimo $\mathrm{d}(i) := +\infty$). □

Ako je

- $\mathrm{d}(i) = 1$, za i kažemo da je **aperiodično** stanje;
- $\mathrm{d}(i) \geqslant 2$, za i kažemo da je **periodično** stanje.

U Primjeru 7.1, $\Lambda(A) = \{2, 4, \dots\} = 2\mathbb{N}$ pa je $\mathrm{d}(A) = 2$ $(= \mathrm{d}(B))$.

U Primjeru 6.23 (PageRank), za sve $i \in V$ smo imali $p_{ii}^{(1)} \geqslant (1-\alpha)\cdot\frac{1}{N} > 0$, tj. $\Lambda(i) = \{1, \dots\}$, pa odmah slijedi $\mathrm{d}(i) = 1$.

7.1.1. Tri tehničke leme. Sljedeća tri rezultata su nam potrebna za dokazivanje teorema o graničnoj razdiobi, dokaze ostavljamo studentima da pogledaju sami.

LEMA 7.3 (**Intuitivnija karakterizacija aperiodičnosti**). *Vrijedi* $\mathrm{d}(i) = 1$ *akko postoji* $n_0 = n_0(i) \in \mathbb{N}$ *t.d. je* $p_{ii}^{(n)} > 0$ *za sve* $n \geqslant n_0$.

Dokaz. Smjer "⇐" je trivijalan, pa preostaje pokazati jedino "⇒".

- Budući da za sve $m, n \geqslant 1$ vrijedi $p_{ii}^{(n+m)} \geqslant p_{ii}^{(n)} p_{ii}^{(m)}$, slijedi da je skup $\Lambda(i)$ zatvoren na zbrajanje (tj. za $m, n \in \Lambda(i)$ vrijedi $m + n \in \Lambda(i)$), a budući da je $\Lambda(i)$ neprazan ($\mathrm{d}(i) < \infty$), slijedi da sadrži beskonačno mnogo elemenata.
- Pokažimo da postoji $m \geqslant 1$ takav da vrijedi $m, m + 1 \in \Lambda(i)$. Neka su $m_0, m_0 + k \in \Lambda$ te pretpostavimo da je $k \geqslant 2$ (inače smo gotovi). Budući da je $\mathrm{d}(i) = 1$, nužno postoji $m_1 \in \Lambda(i)$ takav da k *ne dijeli* m_1, tj.

$$m_1 = l \cdot k + r\,, \quad \text{za neki } l \geqslant 0 \text{ i ostatak } 0 < r < k.$$

  Budući da je $\Lambda(i)$ zatvoren na zbrajanje imamo

$$m_2 := (l+1) \cdot (m_0 + k) = \sum_{i=1}^{l+1} m_0 + k \in \Lambda(i)\,,$$
$$m_3 := (l+1) \cdot m_0 + m_1 \in \Lambda(i)\,,$$

  te vrijedi $m_2 - m_3 = k - r$, što je strogo manje od k jer je $r \geqslant 1$. Dakle, za m_3 i $k' := k - r \in \{1, \ldots, k-1\}$ vrijedi $m_3, m_3 + k' \in \Lambda(i)$. Iteriranjem gornjeg postupka dobit ćemo da postoji $m \geqslant 1$ takav da vrijedi $m, m + 1 \in \Lambda(i)$.
- Tvrdimo da $n_0 := m^2$ ima tražena svojstva. Za $n \geqslant n_0$ imamo

$$0 \leqslant n - m^2 = k \cdot m + r\,,$$

  za neke $k \geqslant 0$ i $0 \leqslant r < m$. Dakle,

$$n = r + m^2 + k \cdot m = [\pm r \cdot m] = r \cdot (m+1) + m \cdot (m - r + k) \in \Lambda(i)\,,$$

  pri čemu zadnje slijedi jer je $m, m + 1 \in \Lambda(i)$ i $r \geqslant 0, m - r + k \geqslant 1$.

□

Lema 7.4 (**Period je svojstvo klase komuniciranja**). *Za* $i, j \in S$, $i \longleftrightarrow j$ *povlači* $\mathrm{d}(i) = \mathrm{d}(j)$.

Dokaz. Pretpostavimo da je $i \neq j$ (inače je trivijalno). Tada postoje $m, n \geqslant 1$ takvi da je $p_{ij}^{(n)} > 0$ i $p_{ji}^{(m)} > 0$. Za sve $k \geqslant 0$ vrijedi

$$p_{jj}^{(m+k+n)} \geqslant p_{ji}^{(m)} p_{ii}^{(k)} p_{ij}^{(n)} =: c \cdot p_{ii}^{(k)}\,. \tag{7.2}$$

pri čemu je dakle $c = p_{ji}^{(m)} p_{ij}^{(n)} > 0$. Iz $p_{ii}^{(0)} = 1 > 0$ slijedi da je $p_{jj}^{(m+n)} > 0$, tj. $m + n \in \Lambda(j)$, pa iz definicije perioda $\mathrm{d}(j)$ slijedi da vrijedi

$$m + n = k_1 \cdot \mathrm{d}(j)\,, \quad \text{za neki } k_1 \geqslant 1\,.$$

Neka je sada $k \in \Lambda(i)$ proizvoljan ($k \geqslant 1$) [uočimo da je zbog $i \longleftrightarrow j$, skup $\Lambda(i)$ nužno neprazan]. Iz (7.2) slijedi $m + k + n \in \Lambda(j)$ pa je $m + k + n = k_2 \cdot \mathrm{d}(j)$ za neki $k_2 \geqslant 1$

($k_2 \geqslant k_1 + 1$ jer je $k \geqslant 1$). Specijalno,

$$k = (m + k + n) - (m + n) = (k_2 - k_1) \cdot \mathrm{d}(j)\,,$$

tj. $\mathrm{d}(j)$ dijeli k. Budući da je $k \in \Lambda(i)$ bio proizvoljan, pokazali smo da je $\mathrm{d}(j)$ djelitelj skupa $\Lambda(i)$, pa je dakle $\mathrm{d}(i) \leqslant \mathrm{d}(j)$. Zbog simetrije, vrijedi i $\mathrm{d}(j) \leqslant \mathrm{d}(i)$, pa je dakle $\mathrm{d}(i) = \mathrm{d}(j)$. □

[Sljedeća lema je poopćenje Leme 7.3.]

LEMA 7.5. *Pretpostavimo da je P ireducibilna i aperiodična matrica prijelaza. Tada za sve parove $i, j \in S$ postoji $n_0 = n_0(i, j) \geqslant 1$ takav da vrijedi $p_{ij}^{(n)} > 0$, za sve $n \geqslant n_0$*

[Uočimo, ako je S konačan, ovaj rezultat povlači da postoji $n_0 \geqslant 1$, takav da je $p_{i,j}^{(n)} > 0$, za sve $n \geqslant n_0$ i *sve* $i, j \in S$.]

DOKAZ. Iz $i \longrightarrow j$ slijedi da postoji $m \geqslant 0$ t.d. $p_{ij}^{(m)} > 0$ [moguće je $m = 0$ ako je $i = j$]. Iz $\mathrm{d}(j) = 1$ i Leme 7.3 slijedi da postoji $n_0(j) \geqslant 1$ takav da vrijedi $p_{jj}^{(n)} > 0$ za sve $n \geqslant n_0(j)$. Sada imamo da za sve

$$n \geqslant m + n_0(j) =: n_0(i, j)\,,$$

zbog $n - m \geqslant n_0(j)$ vrijedi

$$p_{ij}^{(n)} \geqslant p_{ij}^{(m)} p_{jj}^{(n-m)} > 0\,.$$

□

7.2. Teorem o graničnoj distribuciji i tehnika sparivanja

[PRIMJER. (**Magični trik**)

1. Uzmete jedan ili više špilova karate, promiješate ih, te otvarate kartu jednu za drugom.
2. Kažete prijatelju da prvo izabere bilo koju od prvih 10 karata (bez da vam kaže koja je to karta): ako izabrana karta ima "vrijednost" m (as= 1, 2, ..., 9, slike= 10), čeka još m karata i pogleda vrijednost te karte.
3. Prijatelj ponavlja gornji postupak sve dok ne dođe do karte čija je vrijednost, oznaka X, veća od broja preostalih karata.

Pitanje je možete li s velikom vjerojatnosti "pogoditi" X? Odgovor je DA – pratite karte na isti način kao vaš prijatelj, s tim da krenete npr. s prvom kartom po redu. Ako je Y vrijednost vaše zadnje karte, očekujemo da je vjerojatnost $\mathbb{P}(X = Y)$ velika. Intuitivno, ako su $T_1, T_2, \ldots$, odnosno $V_1, V_2, \ldots$, redni brojevi karata koje zanimaju prijatelja, odnosno vas, ako se dogodi da je $T_i = V_j$ za neke i, j ("**sparivanje**"), vrijedit će $X = Y$ jer nakon tog trenutka pratite *iste* karte. Također, očekujemo da se vjerojatnost sparivanja povećava što imamo više karata u početku.

U jednoj simulacijskoj studiji, gdje se ova igra simulirala 10000 puta, postotak igara u kojima je bilo $X = Y$ bio je

- za 1 špil (52 karte), $\widehat{\mathbb{P}}(X = Y) = 0.85$;
- za 2 špila, $\widehat{\mathbb{P}}(X = Y) = 0.9$;
- za 4 špil, $\widehat{\mathbb{P}}(X = Y) = 0.96$. □

Prethodni primjer daje osnovnu ideju tehnike sparivanja (engl. **coupling**). Ova metoda je vrlo generalna, a idući teorem je jedan primjer kako se ona može koristiti kod ML-a – ako želimo odrediti granično ponašanje našeg ML-a, ideja je na *istom* vjerojatnosnom prostoru $(\Omega, \mathcal{F}, \mathbb{P})$ konstruirati drugi ML čije granično ponašanje znamo i to na način da će se oni gotovo sigurno u nekom trenutku spariti, tj. naći u istom stanju. Ukoliko se to može napraviti, slijedit će da naš originalni ML ima isto granično ponašanje kao i konstruirani lanac. Štoviše, koristeći ovu tehniku često možemo dobiti i ocjene na brzinu konvergencije. Navodimo citat američkog matematičara J. Michael Steele-a:

Coupling is one of the most powerful of the "genuinely probabilistic" techniques. Here by "genuinely probabilistic" we mean something that works directly with random variables rather than with their analytical co-travelers (like distributions, densities, or characteristic functions).]

Teorem 7.6 (**Konvergencija prema stac. distr.**). *Ako je $(X_n)_{n\geqslant 0}$ ireducibilan i aperiodičan (λ, P)-ML koji ima stacionarnu distribuciju $\pi = (\pi_i : i \in S)$, tada vrijedi $X_n \xrightarrow{d} \pi$, tj.*

$$\lim_{n\to\infty} \mathbb{P}(X_n = j) = \pi_j\,, \quad \forall j \in S\,. \tag{7.3}$$

(Dakle, π je granična razdioba i to neovisno o početnoj distribuciji.)

Dokaz. Neka je $(Y_n)_{n\geqslant 0}$ (π, P)-ML *nezavisan* od $(X_n)_{n\geqslant 0}$ [kako bi mogli govoriti o nezavisnosti, ova dva procesa moraju biti konstruirana na istom $(\Omega, \mathcal{F}, \mathbb{P})$]. Nadalje, neka je $i_0 \in S$ proizvoljno stanje te definiramo

$$T := \min\{n \geqslant 0 : X_n = Y_n = i_0\}\,.$$

1. korak. Pokazujemo da vrijedi $\mathbb{P}(T < \infty) = 1$ [tj. lanci će se g.s. spariti u i_0].

Neka je $W_n := (X_n, Y_n)$, $n \geqslant 0$. Zbog nezavisnost ML-a $(X_n)_{n\geqslant 0}$ i $(Y_n)_{n\geqslant 0}$, $(W_n)_{n\geqslant 0}$ je $(\mu, \widetilde{P})$-ML na $S \times S$, pri čemu je (provjera za DZ)

- $\mu_{(i,k)} = \mathbb{P}(W_0 = (i, k)) = \lambda_i \pi_k$, za sve $i, k \in S$;
- $\widetilde{p}_{(i,k),(j,l)} = p_{ij} p_{kl}$, za sve $i, j, k, l \in S$, te zapravo
- $\widetilde{p}^{(n)}_{(i,k),(j,l)} = p^{(n)}_{ij} p^{(n)}_{kl}$, za sve $n \geqslant 1$ i sve $i, j, k, l \in S$.

[Zaista,

$$\widetilde{p}^{(n)}_{(i,k),(j,l)} = \mathbb{P}(X_n = j, Y_n = l \mid X_0 = i, Y_0 = k) = \frac{\mathbb{P}(X_n = j, Y_n = l, X_0 = i, Y_0 = k)}{\mathbb{P}(X_0 = i, Y_0 = k)}$$
$$\overset{\text{nez.}}{=} \frac{\mathbb{P}(X_n = j, X_0 = i)\mathbb{P}(Y_n = l, Y_0 = k)}{\mathbb{P}(X_0 = i)\mathbb{P}(Y_0 = k)} = p^{(n)}_{ij} p^{(n)}_{kl}\,. \ ]$$

Neka su $i,j,k,l \in S$ proizvoljni. Budući da je P ireducibilna i *aperiodična*, Lema 7.5 povlači da za sve $n \geqslant \max\{n_0(i,j), n_0(k,l)\}$

vrijedi

$$\widetilde{p}^{(n)}_{(i,k),(j,l)} = \underbrace{p^{(n)}_{ij}}_{>0}\underbrace{p^{(n)}_{kl}}_{>0} > 0\,.$$

Specijalno, za lanac $(W_n)_n$ je stanje (k,l) dostižno iz (i,j). Budući da su i,j,k,l bili proizvoljni, zaključujemo da je lanac $(W_n)_n$ ireducibilan.

Također, intuitivno je jasno da bi $\widetilde{\pi}_{(i,k)} := \pi_i\pi_k$, $i,k \in S$, trebala biti stacionarna distribucija za $(W_n)_n$, a formalno to slijedi jer

$$\begin{aligned}\sum_{i,k\in S}\widetilde{\pi}_{(i,k)}\widetilde{p}_{(i,k),(j,l)} &= \sum_{i,k\in S}\pi_i\pi_k p_{ij}p_{kl} = \left(\sum_{i\in S}\pi_i p_{ij}\right)\cdot\left(\sum_{k\in S}\pi_k p_{kl}\right)\\ &= [\pi = \pi P] = \pi_j\cdot\pi_l = \widetilde{\pi}_{(i,l)}\,,\ \forall j,l\in S\,,\end{aligned}$$

te je $\sum_{i,k\in S}\widetilde{\pi}_{(i,k)} = (\sum_{i\in S}\pi_i)\cdot(\sum_{k\in S}\pi_k) = 1\cdot 1 = 1$.

Sada iz Teorema 6.19 slijedi da je $(W_n)_n$ pozitivno povratan, pa specijalno i povratan. Budući da je $T = T_{(i_0,i_0)}$ prvo vrijeme pogađanja stanja (i_0,i_0), ireducibilnost lanca i Propozicija 5.11 povlače da je $\mathbb{P}(T<\infty) = \mathbb{P}(T_{(i_0,i_0)}<\infty) = 1$.

2. KORAK. Pokazujemo da vrijedi (7.3).

Budući da je $\pi = \pi P$ te je $(Y_n)_n$ (π,P)-ML, proces $(Y_n)_n$ je stacionaran pa specijalno vrijedi $\mathbb{P}(Y_n = j) = \pi_j$, $\forall j\in S$, $\forall n\geqslant 0$. Sada slijedi da je za (7.3) dovoljno pokazati da vrijedi

$$\lim_{n\to\infty}|\mathbb{P}(X_n=j) - \mathbb{P}(Y_n=j)| = 0\,,\quad \forall j\in S\,.$$

Pretpostavimo najprije da za sve $n\geqslant 0$, i sve $j\in S$, vrijedi

$$\mathbb{P}(X_n = j, n\geqslant T) = \mathbb{P}(Y_n = j, n\geqslant T)\,. \tag{7.4}$$

Intutivno, to slijedi iz JMS-a [nakon sparivanja u vremenu zaustavljanja T, distribucijsko ponašanje lanaca je isto].

Tada, za sve $j\in S$ i $n\geqslant 0$ vrijedi

$$\begin{aligned}&|\mathbb{P}(X_n=j) - \mathbb{P}(Y_n=j)|\\ &= |\mathbb{P}(X_n=j, n<T) + \mathbb{P}(X_n=j,n\geqslant T) - \mathbb{P}(Y_n=j,n<T) - \mathbb{P}(Y_n=j,n\geqslant T)|\\ &= |\mathbb{P}(X_n=j,n<T) - \mathbb{P}(Y_n=j,n<T)|\\ &\leqslant \max\{\mathbb{P}(X_n=j,n<T), \mathbb{P}(Y_n=j,n<T)\}\\ &\leqslant \mathbb{P}(T>n) \overset{n\to\infty}{\longrightarrow} \mathbb{P}(T=\infty) = 0\,.\end{aligned} \tag{7.5}$$

Pokažimo još da zaista vrijedi (7.4):

$$\begin{aligned}
\mathbb{P}(X_n = j, n \geqslant T) &= \sum_{m=0}^{n} \mathbb{P}(X_n = j, T = m) = \sum_{m=0}^{n} \mathbb{P}(X_n = j \mid T = m)\mathbb{P}(T = m) \\
&= \sum_{m=0}^{n} \mathbb{P}(T = m)\mathbb{P}(W_n \in \{j\} \times S \mid T = m, W_m = (i_0, i_0)) = [\text{MS za } (W_n)_n] \\
&= \sum_{m=0}^{n} \mathbb{P}(T = m)\mathbb{P}(W_{n-m} \in \{j\} \times S \mid W_0 = (i_0, i_0)) = [(X_n)_n \text{ i } (Y_n)_n \text{ nez.}] \\
&= \sum_{m=0}^{n} \mathbb{P}(T = m)\mathbb{P}(X_{n-m} = j \mid X_0 = i_0) \underbrace{\mathbb{P}(Y_{n-m} \in S \mid Y_0 = i_0)}_{=1} \\
&= [(X_n)_{n\geqslant 0} \ (\lambda, P)\text{-ML}] = \sum_{m=0}^{n} \mathbb{P}(T = m) p_{i_0 j}^{(n-m)} = \mathbb{P}(Y_n = j, n \geqslant T)\,,
\end{aligned}$$

pri čemu se zadnja jednakost dobije na isti način budući da je $(Y_n)_n$ ML s istom prijelaznom matricom P.

□

Napomena 7.7. Iz (7.3) uz $\lambda = \delta^i$ dobivam da vrijedi

$$\lim_{n\to\infty} p_{ij}^{(n)} = \pi_j\,, \quad \forall i, j \in S\,. \tag{7.6}$$

Zadatak. Neka je P prijelazna matrica na S i π vjerojatnosna distribucija na S. Pokažite da vrijedi (7.6) akko $X_n \xrightarrow{d} \pi$ za (λ, P)-ML $(X_n)_{n\geqslant 0}$, za sve početne razdiobe λ.

Napomena 7.8. (a) **Što ako nemamo aperiodičnost?** U tom slučaju lanac $(W_n)_{n\geqslant 0}$ iz dokaza nije nužno ireducibilan, te je moguće da vrijedi $\mathbb{P}(T < \infty) < 1$. Na primjer, ako gledamo periodičan lanac iz Primjera 7.1 – $\pi = (\frac{1}{2}, \frac{1}{2})$, pa ako stavimo $\lambda = \delta^A$ te $i_0 = A$, vrijedi

$$\mathbb{P}(T < \infty) = \mathbb{P}(T_{(A,A)} < \infty) = \mathbb{P}(Y_0 = A) = \pi_A = \frac{1}{2} < 1\,.$$

[Zaista, ako je $X_0 = Y_0 = A$, imamo $T = 0$, a ako je $X_0 = A, Y_0 = B$, očito je $T = \infty$.] Uočimo da u ovom slučaju $(W_n)_n$ ima dvije klase komuniciranja:

$$C_0 = \{(A, A), (B, B)\}\,, \quad C_1 = \{(A, B), (B, A)\}\,.$$

(b) Budući da ograda u (7.5) ne ovisi o stanju $j \in S$, zapravo smo pokazali uniformnu konvergenciju

$$\sup_{j\in S} |\mathbb{P}(X_n = j) - \pi_j| \leqslant \mathbb{P}(T > n) \overset{n\to\infty}{\longrightarrow} 0\,.$$

(c) **Koliko je brza konvergencija?** Analogno kao i (7.4) se pokaže da za sve $n \geqslant 0$ i sve $B \subseteq S$, vrijedi

$$\mathbb{P}(X_n \in B, n \geqslant T) = \mathbb{P}(Y_n \in B, n \geqslant T)\,.$$

Specijalno, umjesto (7.5) zapravo vrijedi i

$$\|\mathbb{P}(X_n \in \cdot\,) - \pi\|_{\mathrm{TV}} := \sup_{B\subseteq S} |\mathbb{P}(X_n \in B) - \pi(B)| \leqslant \mathbb{P}(T > n) \overset{n\to\infty}{\longrightarrow} 0\,, \tag{7.7}$$

pri čemu je

- $\pi(B) := \sum_{i\in B} \pi_i = \mathbb{P}(Y_n \in B)$, a
- $\|\mathbb{P}(X_n \in \cdot\,) - \pi\|_{\mathrm{TV}}$ je tzv. **udaljenost totalne varijacije** između distribucija $\mathbb{P}(X_n \in \cdot)$ i π.[1]

Za dani $\epsilon > 0$, **vrijeme miješanja**[2] ML-a $(X_n)_{n\geqslant 0}$ definira se kao *najmanji* $n_\epsilon \geqslant 1$ takav da za sve $n \geqslant n_\epsilon$ vrijedi

$$\|\mathbb{P}(X_n \in \cdot\,) - \pi\|_{\mathrm{TV}} < \epsilon\,.$$

Primjer 7.9 (**Top-to-random shuffle**). Na stolu se nalazi špil od 52 karte koje miješamo na sljedeći način. U svakom koraku uzmemo kartu koja se nalazi na vrhu špila te je sa jednakom vjerojatnošću stavljamo na dno, vraćamo na vrh ili guramo između neke dvije susjedne karte (dakle, ukupno 52 moguća poteza). Hoće li nakon velikog broja miješanja špil biti dobro promiješan?

Rješenje. Neka je

$$S = \{\text{svi rasporedi špila}\} = \{\text{sve permutacije skupa } \{1, 2, \ldots, 52\}\}\,,$$

(dakle, $|S| = 52!$), te X_n raspored karata nakon n miješanja, $n \geqslant 0$ – dakle, proces $(X_n)_{n\geqslant 0}$ je ML na S.

Lanac je ireducibilan jer za sve $i, j \in S$, vrijedi $p_{ij}^{(52)} > 0$ [npr. krećemo iz rasporeda i te kartu s vrha stavimo da dno, sljedeću stavimo ispod ili ispod nje ovisno o tome je li ispod ili iznad u rasporedu j, itd.]. Budući da je S konačan, zaključujemo da postoji i jedinstvena je stacionarna distribucija $\pi = (\pi_i : i \in S)$.

Lanac je očito i aperiodičan jer je $p_{ii}^{(1)} = \frac{1}{52} > 0$, za sve $i \in S$, [kartu s vrha ostavimo na vrhu], pa slijedi da je π i granična razdioba.

Preostaje odrediti π. Inuitivno, π bi trebala biti uniformna razdioba na S, tj. $\pi_i = \frac{1}{52!}$, za sve $i \in S$.[3] Uočimo, budući da je $\pi_i = \pi_j$ za sve $i, j \in S$, π će biti stacionarna akko je

$$\sum_{i\in S} p_{ij} = 1\,, \quad \forall j \in S\,.$$

(tj. ako je P "dvostruko-stohastička"). Pokažim da to zaista i je slučaj.

Prvo primijetimo da za sve $i, j \in S$, vrijedi $p_{ij} \in \{0, \frac{1}{52}\}$. S druge strane, za svaki raspored $j \in S$, postoji točno 52 različita rasporeda $i \in S$ takva da je $p_{ij} > 0$ [jer bilo koja od 52 karte

[1] Ova udaljenost je jedna od mogućih *metrika* na prostoru svih vjerojatnosnih razdioba na S.
[2] engl *mixing time*
[3] Budući da je ovaj lanac tzv. *slučajna šetnja na grupi* S, te je $|S| < \infty$, to da je uniformna distrubicija stacionarna slijedi iz općenitog rezultata za takve šetnje. Ovdje ćemo ipak dati direktan dokaz.

u rasporedu j je u prethodnom koraku mogla biti na vrhu], te specijalno vrijedi

$$\sum_{i\in S} p_{ij} = 52 \cdot \frac{1}{52} = 1,, \quad \forall j \in S\,.$$

Sada iz Teorema 7.6 (tj. relacije (7.7)) zaključujemo da vrijedi

$$\sup_{B\subseteq S} \underbrace{|\mathbb{P}(X_n \in B) - \pi(B)|}_{=:d(n)} \overset{n\to\infty}{\longrightarrow} 0\,,$$

pri čemu je $\pi(B) = \frac{|B|}{52!}$.

Koliko je brza gornja konvergencija?* Može se pokazati da za sve $n \geqslant 445$ vrijedi ograda $d(n) \leqslant 0.01$ što implicira da je 445 gornja ograda na vrijeme miješanja (za $\epsilon = 0.01$). Dakle, za danu razinu odstupanja od uniformne razdiobe, potrebno je špil promiješati najviše 445 puta. Pitanje donje granice (tj. je li potrebno baš toliko puta promiješati špil) je malo teže, ali može se pokazati da je za veliki broj karata N (kod nas $N = 52$), potreban broj miješanja približno jednak $N\log(N)$ (za $N = 52$ to je 205).

S druge strane, za tzv. **riffle shuffle** metodu miješanja koja modelira način kako većina ljudi miješa špil karata, moguće je numerički odrediti udaljenosti $d(n)$ (vidi [BD92]):

n	$\leqslant 4$	5	6	7	$\cdots$	12
$d(n)$	1	0.92	0.61	0.33	$\cdots$	0.01

Prethodni rezultat jedan je od najpoznatijih neasimptotskih rezultata za Markovljeve lance, te se često naziva "**seven shuffles suffice**" rezultat. Iako se nakon 7 miješanja zaista događa značajan pad udaljenosti od uniformne razdiobe, pitanje "koliko je puta potrebno promiješati špil?" ovisi o razini preciznosti koju želimo. Razumnije bi možda bilo tražiti broj miješanja n tako da udaljenost $d(n)$ bude najviše $\epsilon = 0.01$ – u tom slučaju, prethodni rezultat povlačio bi da je za to dovoljno 12 miješanja.

Za više o vremenima miješanja Markovljevih lanaca pogledajte jako lijepu knjigu [LP17].

□

7.3. Periodičan lanac

PROPOZICIJA 7.10. *Neka je $(X_n)_{n\geqslant 0}$ ireducibilan ML s periodom $d \in \mathbb{N}$, te neka je $i_0 \in S$ fiksno stanje. Za sve $j \in S$ definiramo*

$$K_j := \{n \geqslant 0 : p_{i_0 j^{(n)}} > 0\}\,.$$

Tada

(a) Za sve $j \in S$, postoji ostatak $r_j \in \{0, \ldots, d-1\}$ takav da za sve $n \in K_j$ vrijedi

$$n = r_j \pmod d\,.$$

[Po definiciji perioda, nužno je $r_{i_0} = 0$.]

(b) Ako su $i, j \in S$ te $n \geqslant 0$ takvi da je $p_{ij}^{(n)} > 0$, nužno je

$$n = r_j - r_i \pmod{d}.$$

(c) Za svaki $r \in \{0, \ldots, d-1\}$ definiramo

$$C_r = \{j \in S : r_j = r\}.$$

Tada za ML s prijelaznom matricom P^d vrijedi da su $C_0, \ldots, C_{d-1}$ klase komuniciranja i zatvoreni skupovi, te su sva stanja aperiodična.

NAPOMENA 7.11. Particija $C_0, \ldots, C_{d-1}$ skupa S naziva se **ciklička dekompozicija** lanca $(X_n)_{n\geqslant 0}$. Jedinstvena je do na izbor prvog skupa C_0, tj. stanja $i_0 \in S$ (jer $i_0 \in C_0$). Iz (b) dijela gornjeg rezultata slijedi da ukoliko je npr. $X_0 \in C_0$, nužno je [nacrtati sliku]

$$X_1 \in C_1, X_2 \in C_2, \ldots, X_{d-1} \in C_{d-1}, X_d \in C_0, X_{d+1} \in C_1, \ldots,$$

što nam zapravo daje kako intuitivno razmišljati o periodu (u slučaju ireducibilnog lanca).

Dokaz Propozicije 7.10. Pogledati sami.

(a) Neka je $j \in S$ fiksan. Zbog ireducibilnosti, postoji $m \geqslant 0$ takav da je $p_{ji_0}^{(m)} > 0$. Specijalno, za sve $n \in K_j$ (dakle, $p_{i_0 j}^{(n)} > 0$) vrijedi

$$p_{i_0 i_0}^{(n+m)} \geqslant p_{i_0 j}^{(n)} p_{ji_0}^{(m)} > 0,$$

pa budući da je period lanca d, nužno d dijeli $m+n$ (ovo vrijedi i u slučaju kada je $m = n = 0$ te je nužno $j = i_0$).
Neka je sada $r := m \pmod{d} \in \{0, \ldots, d-1\}$. Tada za sve $n \in K_j$ imamo

$$n \pmod{d} = (m+n) - m \pmod{d} = d - r \pmod{d} =: r_j,$$

gdje dakle gornji ostatak r_j ne ovisi o $n \in K_j$.

(b) Ireducibilnost povlači da postoji $m \geqslant 0$ takav da je $p_{i_0 i}^{(m)} > 0$, pa iz (a) dijela slijedi da vrijedi $m = r_i \pmod{d}$. Nadalje, budući da je

$$p_{i_0 j}^{(m+n)} \geqslant p_{i_0 i}^{(m)} p_{ij}^{(n)} > 0,$$

(a) dio povlači da vrijedi $m + n = r_j \pmod{d}$. Budući da je $n = (m+n) - m$, nužno vrijedi $n = r_j - r_i \pmod{d}$.

(c) Neka je $r \in \{0, 1, \ldots, d-1\}$ te $i, j \in C_r$ (tj. $r_i = r_j = r$). Zbog ireducibilnosti postoji $n \geqslant 0$ t.d. $p_{ij}^{(n)} > 0$, a iz (b) dijela slijedi da je taj n nužno oblika $n = l \cdot d$ za neki $l \in \mathbb{N}_0$. Dakle, $(P^d)_{i,j}^l > 0$, što povlači da je j dostižno iz i za prijelaznu matricu P^d.
Ako su $i, j \in S$ takvi da je $r_i \neq r_j$ (tj. i i j su iz različitih C_r-ova), budući da je $r_j - r_i \pmod{d} \neq 0$, (b) dio povlači da je $(P^d)_{i,j}^l = 0$ za sve $l \in \mathbb{N}_0$, te specijalno j nije dostižno iz i za prijelaznu matricu P^d.
Sve skupa, pokazali smo da su $C_0, \ldots, C_{d-1}$ zatvoreni skupovi te klase komuniciranja za P^d.

Odredimo sada period proizvoljnog stanja $j \in S$ za prijelaznu matricu P^d. Budući da je $d(j) = d$ za P, nužno je $p_{jj}^{(n)} = 0$ za sve $n \neq l \cdot d$, $l \geqslant 1$. Specijalno,

$$\begin{aligned} d &= \operatorname{nzd}\{n \geqslant 1 : p_{jj}^{(n)} > 0\} = \operatorname{nzd}\{l \cdot d : l \geqslant 1, p_{jj}^{(ld)} > 0\} \\ &= d \cdot \operatorname{nzd}\{l : l \geqslant 1, p_{jj}^{(ld)} > 0\} = [p_{jj}^{(ld)} = (P^d)_{jj}^l] = d \cdot d_{P^d}(j)\,, \end{aligned}$$

iz čega slijedi da je $d_{P^d}(j) = 1$.

□

Teorem 7.12 (**Granično ponašanje u periodičnom slučaju**). *Neka je $(X_n)_{n\geqslant 0}$ ireducibilan ML s prijelaznom matricom P, periodom $d \in \mathbb{N}$ i stacionarnom distribucijom π, te neka je $i_0 \in S$ proizvoljno stanje. Ako su $C_0, \ldots, C_{d-1}$ elementi cikličke dekompozicije (takvi da je $i_0 \in C_0$), za sve $r \in \{0, 1, \ldots, d-1\}$ i svako stanje $j \in C_r$ vrijedi*

$$\lim_{n\to\infty} p_{i_0 j}^{(nd+r)} = d \cdot \pi_j \quad \left(= \frac{\pi_j}{1/d}\right).$$

Dokaz. Ako je $Y_n := X_{nd}$, $n \geqslant 0$, $(Y_n)_{n\geqslant 0}$ je ML na S s prijelaznom matricom P^d. Ako je dodatno $Y_0 = X_0 = i_0 \in C_0$, Prop. 7.10(c) povlači da je $(Y_n)_{n\geqslant 0}$ zapravo ML na C_0, te da je on ireducibilan i aperiodičan. Koja mu je stacionarna distribucija? Uočimo, za sve $j \in C_0$,

$$\sum_{k\in C_0} \pi_k p_{kj}^{(d)} = [p_{kj}^{(d)} = 0,\ k \notin C_0] = \sum_{k\in S} \pi_k p_{kj}^{(d)} = [\pi P^d = \pi] = \pi_j\,.$$

Dakle, $(\pi_j : j \in C_0)$ je invarijantna mjera za $(Y_n)_n$ (tj. P^d na C_0). Preostaje odrediti ukupnu masu te mjere $\sum_{j\in C_0} \pi_j$. [Intuitivno?] Budući da je

$$\pi_j = \frac{1}{\mathbb{E}_{i_0}[T_{i_0}^{(1)}]} \cdot \mathbb{E}_{i_0}\Big[\textstyle\sum_{n=0}^{T_{i_0}^{(1)}-1} \mathbb{1}_{\{X_n=j\}}\Big]\,,\quad j \in S\,,$$

te da se lanac $(X_n)_{n\geqslant 0}$ ciklički kreće po skupovima $C_0, \ldots, C_{d-1}$, imamo da je

$$\begin{aligned} \sum_{j\in C_0} \pi_j &= [\text{TMK+ Fubini}] = \frac{1}{\mathbb{E}_{i_0}[T_{i_0}^{(1)}]} \cdot \mathbb{E}_{i_0}\Big[\textstyle\sum_{n=0}^{T_{i_0}^{(1)}-1} \overbrace{\sum_{j\in C_0} \mathbb{1}_{\{X_n=j\}}}^{=\mathbb{1}_{\{X_n\in C_0\}}}\Big] \\ &= \frac{1}{\mathbb{E}_{i_0}[T_{i_0}^{(1)}]} \cdot \mathbb{E}_{i_0}\Big[T_{i_0}^{(1)}/d\Big] = \frac{1}{d}\,. \end{aligned}$$

Dakle, $\widetilde{\pi}_j := \frac{\pi_j}{1/d} = d\pi_j$, $j \in C_0$, je stac. distribucija za P^d na C_0. Iz Teorema 7.6 za lanac $(Y_n)_n$ sada slijedi da za sve $j \in C_0$ (dakle $r = 0$), vrijedi

$$p_{i_0 j}^{(nd)} = (P^d)_{i_0,j}^n \xrightarrow{n\to\infty} \widetilde{\pi}_j = d\pi_j\,.$$

Slučaj $j \in C_r$ za $r \in \{1, \ldots, d-1\}$ pogledati sami.

[Neka je $r \in \{1, \ldots, d-1\}$ te $j \in C_r$ proizvoljan. Budući da je $p_{i_0 k}^{(r)} = 0$ za sve $k \notin C_r$, imamo

$$p_{i_0 j}^{(nd+r)} = \sum_{k\in C_r} p_{i_0 k}^{(r)} p_{kj}^{(nd)}\,.$$

Iz prethodno dokazanog slijedi da za sve $k \in C_r$, $p_{kj}^{(nd)} \overset{n\to\infty}{\longrightarrow} d\pi_j$, jer se k, j oba nalaze u C_r (jednostavno provedemo gornji dokaz uz $i_0 := k$). Kako bi u gornjoj jednakosti pustili limes $n \to \infty$ te zamijenili limes i sumu, koristit ćemo teorem o dominiranoj konvergenciji – budući da je

$$p_{i_0k}^{(r)} p_{kj}^{(nd)} \leqslant p_{i_0k}^{(r)}\,, \quad \forall k \in C_0, \forall n \geqslant 0\,, \quad \text{te} \quad \sum_{k\in C_r} p_{i_0k}^{(r)} = 1 < \infty\,,$$

po TDK slijedi

$$\lim_{n\to\infty} p_{i_0j}^{(nd+r)} = \sum_{k\in C_r} p_{i_0k}^{(r)} \cdot \lim_{n\to\infty} p_{kj}^{(nd)} = d\pi_j \sum_{k\in C_r} p_{i_0k}^{(r)} = d\pi_j\,.\,]$$

□

7.4. Prolazan/nul-povratan slučaj

Teorem 7.13. *Neka je $(X_n)_{n\geqslant 0}$ ireducibilan ML s prijelaznom matricom P. Ako je $(X_n)_{n\geqslant 0}$ prolazan ili nul-povratan, vrijedi*

$$p_{ij}^{(n)} \overset{n\to\infty}{\longrightarrow} 0\,, \quad \forall i, j \in S\,.$$

Dokaz. U prolaznom slučaju, tvrdnja slijedi iz (5.9), a u nul-povratnom slučaju dokaz preskačemo. □

Primjer 7.14. Ako je $(X_n)_{n\geqslant 0}$ jednostavna simetrična slučajna šetnja na $\mathbb{Z}$, budući da je nul-povratna, prethodni teorem povlači da je

$$\mathbb{P}_0(X_n = j) \overset{n\to\infty}{\longrightarrow} 0\,, \quad \forall j \in \mathbb{Z}\,.$$

Specijalno, $(X_n)_{n\geqslant 0}$ nema graničnu razdiobu. Ipak, centralni granični teorem nam kaže da nakon prikladne normalizacije granična razdioba ipak postoji – budući da je $X_n = \sum_{i=1}^n Y_i$ za $(Y_i)_i$ njd sa zajedničkom razdiobom $Y_i \in \{-1, 1\}$, $\mathbb{P}(Y_i = 1) = \mathbb{P}(Y_i = -1) = \frac{1}{2}$, te je $\mu := \mathbb{E}[Y_i] = 0$, $\sigma^2 := \mathrm{Var}(Y_i) = 1$, vrijedi

$$\frac{X_n}{\sqrt{n}} = \frac{X_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} Z \sim \mathrm{N}(0, 1)\,,$$

tj. za sve $a < b$, vrijedi

$$\mathbb{P}_0(\sqrt{n}a \leqslant X_n \leqslant \sqrt{n}b) \to \mathbb{P}(a \leqslant Z \leqslant b)\,.$$

Drugim riječima, za velike n, X_n ima približno $\mathrm{N}(0, n)$ razdiobu.

7.5. Diskretna teorija obnavljanja

Za *njd* niz $(Y_n)_{n\geqslant 1}$ s vrijednostima u $\mathbb{N}$, proces $S_k := \sum_{i=1}^k Y_i$, $n \geqslant 1$ (uz $S_0 := 0$) zovemo **proces obnavljanja** (generiran nizom $(Y_n)_{n\geqslant 1}$) [nacrtati sliku].[4]

[4] Drugim riječima, proces obnavljanja je slučajna šetnja na $\mathbb{N}_0$ koja kreće iz 0 te čiji koraci poprimaju vrijednosti u $\mathbb{N}$.

[Vremena $S_0, S_1, \dots$ zamišljamo kao trenutke u kojima se događa neki fenomen (npr. dolazak autobusa na stanicu ili kupaca u trgovinu) i zovemo ih **vremena obnavljanja**, a $Y_k = S_k - S_{k-1}$ vrijeme čekanja ili duljina intervala između $(k-1)$-vog i k-tog obnavljanja. U nastavku proučavamo granično ponašanje općenitih procesa obnavljanja, a kasnije ćemo to primijeniti na slučaj Markovljevih lanaca – gledat ćemo proces obnavljanja generiran izletima iz (pozitivno) povratnog stanja $i \in S$.]

Za sve $n \geqslant 0$, dodatno definiramo [naznačiti na slici]

- $N_n := \max\{k \geqslant 0 : S_k \leqslant n\}$ = broj intervala do trenutka n;
- $A_n := n - S_{N_n} \in \{0, 1, \dots\}$ = vrijeme prošlo od zadnjeg obnavljanja;
- $D_n := S_{N_n+1} - S_{N_n} = Y_{N_n+1} \in \mathbb{N}$ = duljina intervala koji sadrži trenutak n;
- $m := \mathbb{E}[Y_i] \in [1, \infty]$ = očekivana duljina *tipičnog* intervala.

[Idući teorem je netrivijalna primjena teorema o graničnoj distribuciji za Markovljeve lance. Teorem se ne ispituje, a studentima ostavljamo da dokaz pogledaju sami.]

Teorem 7.15 (**Paradoks vremena čekanja***). *Pretpostavimo da vrijedi $m < \infty$ te $\mathbb{P}(Y_1 \in d\mathbb{N}) < 1$, za sve $d \geqslant 2$ [zadnje je tehnički uvjet vezan uz aperiodičnost]. Tada za sve $k \in \mathbb{N}$ i $j \in \{0, 1, \dots, k-1\}$, vrijedi*

$$\mathbb{P}(D_n = k, A_n = j) \xrightarrow{n\to\infty} \frac{\mathbb{P}(Y_1 = k)}{m}\,.$$

Interpretacija: (i) Za sve k imamo

$$\mathbb{P}(D_n = k) = \sum_{j=0}^{k-1} \mathbb{P}(D_n = k, A_n = j) \xrightarrow{n\to\infty} \frac{k\mathbb{P}(Y_1 = k)}{m} =: \mathbb{P}(Y_1^* = k)\,, \tag{7.8}$$

to jest $D_n \xrightarrow{d} Y_1^*$. Na primjer,

$$Y_1 \sim \begin{pmatrix} 1 & 2 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix} \quad \Rightarrow \quad Y_1^* \sim \begin{pmatrix} 1 & 2 \\ \frac{1}{3} & \frac{2}{3} \end{pmatrix}$$

jer je

$$\frac{\mathbb{P}(Y_1^* = 2)}{\mathbb{P}(Y_1^* = 1)} = \frac{2}{1} \cdot \frac{\mathbb{P}(Y_1 = 2)}{\mathbb{P}(Y_1 = 1)} = 2\,.$$

[Dakle, iako su tipična vremena između obnavljanja s jednakom vjerojatnosti duljine 1 ili 2, dva puta je vjerojatnije da je interval koji sadrži veliki n duljine 2 nego 1. To da je asimptotski, D_n "duži" od tipičnog intervala Y_1 se naziva raznim imenima ovisno o kontestu u kojem se pojavljuje – *size-biasing*, *waiting time paradox* ili *inspection paradox*.]

Inuitivno objašnjenje: Ako je U_n uniformno odabrani trenutak iz $\{1, 2, \dots, n\}$ [nezavisan od Y_i-eva], za sve $k \geqslant 1$ imamo

$$\mathbb{P}(D_{U_n} = k) = \sum_{i=1}^{n} \mathbb{P}(D_{U_n} = k \mid U_n = i)\mathbb{P}(U_n = i) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{P}(D_i = k) \xrightarrow{n\to\infty} \mathbb{P}(Y_1^* = k)\,,$$

gdje zadnji korak slijedi iz (7.8).

[Dakle, graničnu (tj. stacionarnu) distribuciju intervala D_n možemo dobiti tako da uniformno izaberemo trenutak iz $1, 2, \ldots, n$ za veliki n – budući da u gornjem primjeru intervali duljine 2 zauzimaju dvostruko više vremenskih trenutaka od intervala duljine 1, dva puta je vjerojatnije da ćemo upasti u dulji interval. Općenito, budući da je postotak intervala duljine k približno $\mathbb{P}(Y_1 = k)$, vjerojatnost da upadnemo u interval dane duljine k je približno proporcionalna s $k\mathbb{P}(Y_1 = k)$, što objašnjava zašto u limesu duljina odabranog intervala ima upravo distribuciju kao i Y_1^*. Za više o *size-biasing* fenomenu i primjenama u raznim područjima vjerojatnosti, vidi [**AGK19**].]

Općenito, Y_1^* je "duži" od tipičnog intervala Y_1 – npr.

$$\mathbb{E}[Y_1^*] = \sum_{k=1}^{\infty} k\mathbb{P}(Y_1^* = k) = \frac{1}{m}\sum_{k=1}^{\infty} k^2\mathbb{P}(Y_1 = k) = \frac{\mathbb{E}[Y_1^2]}{\mathbb{E}[Y_1]} \geqslant \mathbb{E}[Y_1]\,,$$

pri čemu zadnja nejednakost slijedi jer je $\mathbb{E}[Y_1]^2 \leqslant \mathbb{E}[Y_1^2]$; to npr. slijedi jer je $0 \leqslant \mathrm{Var}(Y_1) = \mathbb{E}[Y_1^2] - \mathbb{E}[Y_1]^2$.

(ii) Ako je $\mathbb{P}(Y_1 = k) > 0$, za sve $j \in \{0, \ldots, k-1\}$ vrijedi

$$\mathbb{P}(A_n = j \mid D_n = k) \xrightarrow{n\to\infty} \frac{1}{k}\,,$$

tj. za velike n, uvjetno na $D_n = k$, A_n je uniformno odabran iz $\{0, 1, \ldots, k-1\}$. □

Dokaz Teorema 7.15. Može se pokazati da je, pod pretpostavkama teorema, slučajan proces $((D_n, A_n))_{n\geqslant 0}$ ireducibilan i aperiodičan ML na

$$E := \{(k, j) : \mathbb{P}(Y_1 = k) > 0, j \in \{0, 1, \ldots, k-1\}\}\,.$$

Probajte mu za vježbu odrediti prijelazne vjerojatnosti.

Odredit ćemo $\mathbb{E}_{(k,j)}[T^{(1)}_{(k,j)}]$ za proizvoljan $(k, j) \in E$, iz čega će slijediti da je lanac pozitivno povratan te ćemo usput dobiti i stacionarnu razdiobu.

Neka je $(k, j) \in E$ proizvoljan. Uvjet $(D_n, A_n) = (k, j)$ znači da se trenutno nalazimo u intervalu duljine k, te da je do idućeg obnavljanje ostalo $k - j \geqslant 1$ koraka. Budući da N_n ovisi samo o $Y_1, \ldots, Y_{N_n+1}$, slijedi da su $Y_{N_n+2}, Y_{N_n+3}, \ldots$ opet njd s istom distribucijom kao i Y_1, te nezavisni od $Y_1, \ldots, Y_{N_n+1}$. Dakle, uvjetno na $(D_0, A_0) = (k, j)$, prvo vrijeme povratka $T^{(1)}_{(k,j)}$ ima istu distribuciju kao i

$$(k - j) + Y_1 + \cdots + Y_K + j = k + \sum_{i=1}^{K} Y_i\,,$$

gdje je $K := \max\{i \geqslant 1 : Y_i \neq k\}$. Može se pokazati da vrijedi

$$\mathbb{E}\Big[\sum_{i=1}^{K} Y_i\Big] = \mathbb{E}[K] \cdot \mathbb{E}[Y_1 \mid Y_1 \neq k]\,,$$

pa budući da K ima geometrijsku razdiobu na $\mathbb{N}_0$ s parametrom $\mathbb{P}(Y_1 = k)$, imamo

$$\mathbb{E}\Big[\sum_{i=1}^{K} Y_i\Big] = \frac{\mathbb{P}(Y_1 \neq k)}{\mathbb{P}(Y_1 = k)} \cdot \frac{\mathbb{E}[Y_1 \mathbb{1}_{\{Y_1 \neq k\}}]}{\mathbb{P}(Y_1 \neq k)} = \frac{1}{\mathbb{P}(Y_1 = k)} \Big(\mathbb{E}[Y_1] - \mathbb{E}[Y_1 \mathbb{1}_{\{Y_1 = k\}}]\Big)$$
$$= \frac{1}{\mathbb{P}(Y_1 = k)} \left(m - k\mathbb{P}(Y_1 = k)\right) = \frac{m}{\mathbb{P}(Y_1 = k)} - k\,.$$

Dakle,

$$\mathbb{E}_{(k,j)}[T^{(1)}_{(k,j)}] = \mathbb{E}\Big[k + \sum_{i=1}^{K} Y_i\Big] = \frac{m}{\mathbb{P}(Y_1 = k)} < \infty\,,$$

pri čemu zadnja nejednakost slijedi jer je $m < \infty$ i $\mathbb{P}(Y_1 = k) > 0$. Dakle, lanac je pozitivno povratan, te smo usput pokazali da je stacionarna distribucija

$$\pi_{(k,j)} = \frac{1}{\mathbb{E}_{(k,j)}[T^{(1)}_{(k,j)}]} = \frac{\mathbb{P}(Y_1 = k)}{m}\,, \quad \forall (k,j) \in E\,.$$

Teorem 7.6 sada povlači tvrdnju za sve $(k,j) \in E$. Ako je k takav da je $\mathbb{P}(Y_1 = k) = 0$, tvrdnja slijedi trivijalno.

□

Teorem 7.16 (**Elementarni teorem obnavljanja**). *Ako je $(S_k)_{k\geqslant 0}$ proces obnavljanja [generiran njd nizom $(Y_i)_i$], vrijedi*

$$\mathbb{P}\left(\frac{n}{N_n} \xrightarrow{n\to\infty} m\right) = 1\,, \tag{7.9}$$

tj. $\frac{n}{N_n}$ gotovo sigurno konvergira prema $m = \mathbb{E}[Y_1] \in [1, \infty]$.

Uočimo da (7.9) intuitivno slijedi iz JZVB-a jer je $\frac{n}{N_n}$ približno jednak prosječnoj duljini svih intervala koji su u potpunosti sadržani u vremenskom intervalu $[0, n]$.

[U dokazu ćemo koristiti malo poopćenje JZVB-a koji dopušta slučaj $m = \infty$. Rezultat navodimo bez dokaza.]

Teorem 7.17 (**JZVB**). *Ako su $Z_1, Z_2, \ldots$, njd slučajne varijable takve da postoji $\mathbb{E}[Z_1]$, kada $n \to \infty$ vrijedi*

$$\frac{1}{n}\sum_{i=1}^{n} Z_i \xrightarrow{g.s.} \mathbb{E}[Z_1]\,. \tag{7.10}$$

Ako je Z_1 nenegativna slučajna varijabla, (7.10) vrijedi i ako je $\mathbb{E}[Z_1] = \infty$.

Dokaz Teorema 7.16. Budući da su $Y_1, Y_2, \ldots$ njd u $\mathbb{N}$ te $S_k = \sum_{i=1}^{k} Y_i$, JZVB povlači da kada $k \to \infty$ vrijedi

$$\frac{S_k}{k} \xrightarrow{\text{g.s.}} \mathbb{E}[Y_1] = m\,. \tag{7.11}$$

Za sve $n \geqslant 0$, vrijedi [nacrtati sliku]

$$S_{N_n} \leqslant n < S_{N_n+1}\,. \tag{7.12}$$

Budući da je $\mathbb{P}(S_k < \infty\,,\ \forall k \geqslant 0) = 1$, slijedi da kada $n \to \infty$

$$N_n \xrightarrow{\text{g.s.}} +\infty\,. \tag{7.13}$$

Sve skupa, (7.12) povlači

$$\frac{S_{N_n}}{N_n} \leqslant \frac{n}{N_n} < \frac{S_{N_n+1}}{N_n}\,,\ \ \forall n \geqslant 0\,,$$

pa (7.9) slijedi jer kada $n \to \infty$, iz (7.11) i (7.13) slijedi

$$\frac{S_{N_n}}{N_n} \xrightarrow{\text{g.s.}} m\,,$$

te

$$\frac{S_{N_n+1}}{N_n} = \frac{N_n+1}{N_n} \cdot \frac{S_{N_n+1}}{N_n+1} \xrightarrow{\text{g.s.}} 1 \cdot m = 1\,.$$

□

POGLAVLJE 8

Ergodski teorem

Za ML $(X_n)_{n\geqslant 0}$ na S, zanima nas vrijeme koje lanac provede u stanju $i \in S$ prije trenutka n:

$$N_i(n) := \sum_{k=0}^{n-1} \mathbb{1}_{\{X_k=i\}}\,, \tag{8.1}$$

tj. $N_i(n)/n$ za velike n.

8.1. Regenerativni ciklusi

Pretpostavimo da je $i \in S$ *povratno* stanje. Kao i do sada, neka je $T_i^{(0)} := 0$ te

$$T_i^{(m)} := \min\{n > T_i^{(m-1)} : X_n = i\}\,,\quad m \geqslant 1\,,$$

vrijeme m-tog povratka lanca u i. Iz pretpostavke povratnosti slijedi da je $\mathbb{P}_i(T_i^{(m)} < \infty\,,\ \forall m \geqslant 0) = 1$.[1]

[Dakle, za g.s. $\omega \in \Omega$, trajektoriju $X_0(\omega), X_1(\omega), X_2(\omega), \dots$ našeg ML možemo rastaviti na "izlete" iz stanja i – nacrtati sliku.]

Za svaki $m \geqslant 1$, definiramo m-ti **regenerativni ciklus** ili **izlet iz stanja** i

$$\eta_m := \left(X_{T_i^{(m-1)}}, X_{T_i^{(m-1)}+1}, \dots, X_{T_i^{(m)}-1}\right), \tag{8.2}$$

kao slučajni element u skupu $E := \cup_{k=1}^{\infty} S^k$.[2] Nadalje, definiramo **duljinu m-tog izleta** s

$$Y_m := T_i^{(m)} - T_i^{(m-1)} \in \{1, 2, \dots\}\,. \tag{8.3}$$

Sljedeći rezultat je ključan, a slijedi odmah iz JMS-a.

Teorem 8.1 (**Izleti su njd**). *Ako je $(X_n)_{n\geqslant 0}$ (δ^i, P)-ML te $i \in S$ povratno stanje, izleti $(\eta_m)_{m\geqslant 1}$ (te specijalno duljine $(Y_m)_{m\geqslant 1}$) su njd.*

Dokaz. Neka su $n \in \mathbb{N}$ te $z_1, \dots, z_n \in E$ proizvoljni, ali takvi da je svaki z_i oblika $(i_0, \dots, i_{k-1})$ za neki $k \geqslant 1$ i neka stanja $i_0, \dots, i_{k-1} \in S$ pri čemu je $i_0 = i, i_1, \dots, i_{k-1} \neq i$. Vrijedi

$$\mathbb{P}_i(\eta_1 = z_1, \dots, \eta_n = z_n) = \mathbb{P}_i(\eta_1 = z_1, \dots, \eta_{n-1} = z_{n-1})\mathbb{P}_i(\eta_n = z_n \mid \eta_1 = z_1, \dots, \eta_{n-1} = z_{n-1})\,.$$

[1] Formalno, ako je $A_m := \{T_i^{(m)} < \infty\}$, znamo da je $\mathbb{P}(A_m) = 1$ za sve $m \geqslant 0$, pa budući da A_m-ova ima prebrojivo mnogo, vrijedi i $\mathbb{P}(\cap_{m\geqslant 0} A_m) = 1$ (vidi kolegij Vjerojatnost).
[2] Bitno je ovdje da je skup E ponovno prebrojiv, tj. η_m je diskretan slučajni element.

Budući da $\eta_1, \dots, \eta_{n-1}$ ovise o $X_0, X_1, \dots, X_{T_i^{(n-1)}}$,[3] a η_n o $X_{T_i^{(n-1)}}, X_{T_i^{(n-1)}+1}, \dots$, JMS u trenutku $T_i^{(n-1)}$ povlači da je

$$\mathbb{P}_i(\eta_1 = z_1, \dots, \eta_n = z_n) = \mathbb{P}_i(\eta_1 = z_1, \dots, \eta_{n-1} = z_{n-1})\mathbb{P}_i(\eta_1 = z_n)\,.$$

Iteriranjem gornjeg postupka dobivamo

$$\mathbb{P}_i(\eta_1 = z_1, \dots, \eta_n = z_n) = \mathbb{P}_i(\eta_1 = z_1)\mathbb{P}_i(\eta_1 = z_2)\cdots\mathbb{P}_i(\eta_1 = z_n)\,.$$

Iz gornjeg lako slijedi da η_i ima istu distribuciju kao η_1, za sve $i = 1, \dots, n$, te da su $\eta_1, \dots, \eta_n$ nezavisni. Budući da je n bio proizvoljan, slijedi da su $\eta_1, \eta_2, \dots$ njd, a tvrdnja za duljine izleta slijedi odmah budući da je $Y_m = h(\eta_m)$, za sve $m \geqslant 1$ (gdje je $h(i_0, \dots, i_{k-1}) := k$ za sve $(i_0, \dots, i_{k-1}) \in E$). □

ZADATAK. U gornjem dokazu je zapravo bilo dovoljno koristiti samo Markovljevo svojstvo. Koristeći samo MS pokažite direktno da su $Y_1, Y_2, \dots$ njd s obzirom na $\mathbb{P}_i$.

Specijalno, budući da je $T_i^{(n)} = \sum_{i=1}^{n} Y_m$, $n \geqslant 1$, slijedi da je (uz $\mathbb{P}_i$) niz $(T_i^{(n)})_{n\geqslant 0}$ zapravo *proces obnavljanja* generiran (njd) nizom $(Y_m)_{m\geqslant 1}$ s očekivanom duljinom intervala

$$m_i := \mathbb{E}_i[Y_1] = \mathbb{E}_i[T_i^{(1)}] \in [1, \infty]\,. \tag{8.4}$$

Dakle, ako za svaki $n \geqslant 0$ definiramo broj povrataka u stanje i do trenutka n sa

$$B_n := \max\{m \geqslant 0 : T_i^{(m)} \leqslant n\}\,, \tag{8.5}$$

elementarni teorem obnavljanja (B_n je upravo N_n iz Poglavlja 7.5) povlači da $\mathbb{P}_i$-g.s.

$$\frac{n}{B_n} \xrightarrow{n\to\infty} m_i\,. \tag{8.6}$$

te specijalno

$$\frac{N_i(n)}{n} = \frac{B_{n-1}+1}{n} \xrightarrow{n\to\infty} \frac{1}{m_i}\,. \tag{8.7}$$

[Zapravo, (8.7) vrijedi čak i ako je (a) i je prolazno i/ili (b) početna razdioba $\lambda \neq \delta^i$ (uz ireducibilnost). Detalje ostavljamo za vježbu.]

TEOREM 8.2. *Ako je $(X_n)_{n\geqslant 0}$ ireducibilan (λ, P)-ML, za sve $i \in S$ vrijedi*[4]

$$\mathbb{P}\left(\frac{N_i(n)}{n} \xrightarrow{n\to\infty} \frac{1}{m_i}\right) = 1\,.$$

[3] npr. za η_1 i $z = (i_0, \dots, i_{k-1})$ imamo

$$\eta_1 = z \iff X_0 = i_0, \dots, X_{k-1} = i_{k-1}, \mathbf{X_k = i}\,,$$

Dakle, na $\{\eta_1 = z\}$ je zapravo nužno $T_i^{(1)} = k$ te taj događaj ovisi o $X_0, \dots, X_k$.

[4] Tvrdnja vrijedi i bez ireducibilnosti – potrebno je samo u slučaju kada je i povratno pretpostaviti da je $\mathbb{P}(T_i^{(1)} < \infty) = 1$. Također, uočite da Teorem 8.2 povlači (8.7) jer uvijek možemo restringirati lanac na (zatvorenu) klasu koja sadrži povratno stanje i.

[Dokaz. Ako je lanac prolazan, $N_i(n) \leqslant \sum_{k=0}^{\infty} \mathbb{1}_{\{X_k=i\}} =: N_i$ te znamo da je $\mathbb{P}(N_i < \infty) = 1$ (bez obzira na početnu razdiobu). Specijalno, gotovo sigurno

$$\frac{N_i(n)}{n} \leqslant \frac{N_i}{n} \xrightarrow{n\to\infty} 0 = \frac{1}{\mathbb{E}_i[T_i^{(1)}]}$$

jer $\mathbb{E}_i[T_i^{(1)}] = +\infty$ budući da je $\mathbb{P}_i(T_i^{(1)} = +\infty) > 0$.

Ako je lanac povratan, ireducibilnost povlači da je $\mathbb{P}(T_i < \infty) = 1$, iz čega imamo ekvivalenciju

$$\frac{N_i(n)}{n} \xrightarrow{n\to\infty} \frac{1}{m_i} \quad \Longleftrightarrow \quad \frac{1}{n} \sum_{k=T_i}^{n-1+T_i} \mathbb{1}_{\{X_k=i\}} \xrightarrow{n\to\infty} \frac{1}{m_i}\,.$$

Zaista, $T_i < \infty$ g.s., pa čim je $n - 1 \geqslant T_i$, imamo

$$\frac{1}{n} \sum_{k=T_i}^{n-1+T_i} \mathbb{1}_{\{X_k=i\}} = \frac{N_i(n)}{n} - \frac{1}{n} \sum_{k=0}^{T_i-1} \mathbb{1}_{\{X_k=i\}} + \frac{1}{n} \sum_{k=n}^{n-1+T_i} \mathbb{1}_{\{X_k=i\}}\,,$$

pri čemu je očito $\sum_{k=0}^{T_i-1} \mathbb{1}_{\{X_k=i\}} = 0$, a

$$\frac{1}{n} \sum_{k=n}^{n-1+T_i} \mathbb{1}_{\{X_k=i\}} \leqslant \frac{T_i}{n} \xrightarrow{n\to\infty} 0 \quad \text{g.s.}\,,$$

jer je $\mathbb{P}(T_i < \infty) = 1$.

Sada koristeći JMS u T_i dobivamo

$$\begin{aligned}
\mathbb{P}\left(\frac{N_i(n)}{n} \xrightarrow{n\to\infty} \frac{1}{m_i}\right) &= \mathbb{P}\left(\frac{1}{n} \sum_{k=T_i}^{n-1+T_i} \mathbb{1}_{\{X_k=i\}} \xrightarrow{n\to\infty} \frac{1}{m_i}\right) \\
&= \mathbb{P}\left(\frac{1}{n} \sum_{k=T_i}^{n-1+T_i} \mathbb{1}_{\{X_k=i\}} \xrightarrow{n\to\infty} \frac{1}{m_i} \,\middle|\, T_i < \infty\right) \\
&= \mathbb{P}_i\left(\frac{N_i(n)}{n} \xrightarrow{n\to\infty} \frac{1}{m_i}\right) \overset{(8.7)}{=} 1\,.
\end{aligned}$$

□]

Uočimo, ako je u prethodnom teoremu

- lanac prolazan ili nul-povratan, vrijedi $\frac{1}{m_i} = 0$;
- pozitivno povratan, vrijedi $\frac{1}{m_i} = \pi_i > 0$, gdje je $(\pi_j : j \in S)$ jedinstvena stacionarna distribucija lanca [u ovom slučaju, Ergodski teorem daje puno više].

8.2. Ergodski teorem

Teorem 8.3 (**Ergodski teorem**). *Neka je $(X_n)_{n\geqslant 0}$ (λ, P)-ML na S koji je ireducibilan te ima stacionarnu distribuciju π [dakle, pozitivno povratan je]. Tada za svaku funkciju $f : S \to \mathbb{R}$ koja je (a) nenegativna, ili (b) zadovoljava $\sum_{j\in S} |f(j)|\pi_j < \infty$ [npr. ako je f ograničena], vrijedi*

$$\frac{1}{n} \sum_{k=0}^{n-1} f(X_k) \xrightarrow{n\to\infty} \pi(f) := \sum_{j\in S} f(j)\pi_j\,, \quad g.s\,, \tag{8.8}$$

tj.

$$\mathbb{P}\left(\frac{1}{n}\sum_{k=0}^{n-1} f(X_k) \xrightarrow{n\to\infty} \pi(f)\right) = 1\,.$$

[Uočimo, (8.8) ne ovisi o početnoj razdiobi λ, te nije potrebna aperiodičnost.]

NAPOMENA 8.4. (a) Ako je X_π slučajna varijabla u S s distribucijom π, tj. $\mathbb{P}(X_\pi = j) = \pi_j$, $\forall j \in S$, vrijedi

$$\pi(f) = \mathbb{E}[f(X_\pi)]\,. \tag{8.9}$$

Specijalno, ako je $\lambda = \pi$, od prije znamo da vrijedi $X_n \overset{d}{=} X_\pi$, za sve $n \geqslant 0$, te (8.8) možemo zapisati kao

$$\frac{1}{n}\sum_{k=0}^{n-1} f(X_k) \xrightarrow{n\to\infty} \mathbb{E}[f(X_0)]\,, \quad \text{g.s.}\,.$$

Dakle, na Ergodski teorem je zapravo JZVB za Markovljeve lance.

(b) Za sve $i \in S$ vrijedi

$$\begin{aligned}\pi(f) &= \sum_{j\in S} f(j)\pi_j = \sum_{j\in S} f(j)\frac{1}{\mathbb{E}_i\left[T_i^{(1)}\right]}\mathbb{E}_i\left[\textstyle\sum_{n=0}^{T_i^{(1)}-1}\mathbb{1}_{\{X_n=j\}}\right]\\ &= \frac{1}{\mathbb{E}_i\left[T_i^{(1)}\right]}\mathbb{E}_i\Big[\textstyle\sum_{n=0}^{T_i^{(1)}-1}\underbrace{\sum_{j\in S} f(j)\mathbb{1}_{\{X_n=j\}}}_{=f(X_n)}\Big]\\ &= \frac{1}{\mathbb{E}_i\left[T_i^{(1)}\right]}\mathbb{E}_i\left[\textstyle\sum_{n=0}^{T_i^{(1)}-1} f(X_n)\right]. \end{aligned} \tag{8.10}$$

(c) Ako u (8.8) uzmemo $f = \mathbb{1}_{\{i\}}$ za $i \in S$ [tj. $f(j) = 1$ ako $j = i$ te $f(j) = 0$ ako $j \neq i$], imamo $\pi(f) = \pi_i$, $\frac{1}{n}\sum_{k=0}^{n-1} f(X_k) = \frac{N_i(n)}{n}$ te dakle (8.8) povlači

$$\mathbb{P}\left(\frac{N_i(n)}{n} \xrightarrow{n\to\infty} \pi_i\right) = 1\,, \quad \forall i \in S\,, \tag{8.11}$$

što je dakle specijalan slučaj Teorema 8.2.

DOKAZ TEOREMA 8.3. Prvo primijetimo da je dovoljno dokazati (8.8) za slučaj $\lambda = \delta^i$, za $i \in S$ proizvoljan, budući da općenito vrijedi $\mathbb{P} = \sum_{i\in S}\lambda_i\mathbb{P}_i$. Neka je dakle $i \in S$ proizvoljan, $\lambda = \delta^i$ te f nenegativna funkcija.

Budući da je i povratno stanje, Teorem 8.1 povlači da su izleti $(\eta_m)_{m\geqslant 1}$ njd. Ako definiramo[5]

$$Z_m := \sum_{k=T_i^{(m-1)}}^{T_i^{(m)}-1} f(X_k) =: H(\eta_m)\,, \quad m \geqslant 1$$

[5] Formalno, definiramo $H((s_0,\ldots,s_{k-1})) := \sum_{i=0}^{k-1} f(s_i)$, za sve $(s_0,\ldots,s_{k-1}) \in E = \cup_{l=1}^{\infty} S^l$.

slijedi da je $(Z_m)_{m\geqslant 1}$ niz njd nenegativnih slučajnih varijabli, pa po JZVB-a slijedi da $\mathbb{P}_i$-g.s. vrijedi

$$\frac{1}{M}\sum_{m=1}^{M} Z_m \xrightarrow{M\to\infty} \mathbb{E}_i[Z_1] = \mathbb{E}_i\Big[\textstyle\sum_{k=0}^{T_i^{(1)}-1} f(X_k)\Big]\,. \tag{8.12}$$

Budući da za B_n definiram u (8.5) vrijedi (vidi (7.12))

$$T_i^{(B_n)} \leqslant n < T_i^{(B_n+1)}\,,\quad \forall n \geqslant 0 \tag{8.13}$$

iz nenegativnosti funkcije f slijedi da za sve $n \geqslant 0$ vrijedi

$$\sum_{m=1}^{B_n} Z_m = \textstyle\sum_{k=0}^{T_i^{(B_n)}-1} f(X_k) \leqslant \displaystyle\sum_{k=0}^{n-1} f(X_k) \leqslant \textstyle\sum_{k=0}^{T_i^{(B_n+1)}-1} f(X_k) = \displaystyle\sum_{m=1}^{B_n+1} Z_m \tag{8.14}$$

Sada, iz (8.6) znamo da $\mathbb{P}_i$-g.s. vrijedi

$$\frac{n}{B_n} \xrightarrow{n\to\infty} \mathbb{E}_i\Big[T_i^{(1)}\Big]\,,$$

pa iz (8.12) i činjenice da $\mathbb{P}_i(B_n \xrightarrow{n\to\infty} \infty) = 1$ slijedi da $\mathbb{P}_i$-g.s. vrijedi

$$\frac{1}{n}\sum_{m=1}^{B_n} Z_m = \frac{B_n}{n}\cdot\frac{1}{B_n}\sum_{m=1}^{B_n} Z_m \xrightarrow{n\to\infty} \frac{1}{\mathbb{E}_i\Big[T_i^{(1)}\Big]}\cdot\mathbb{E}_i\Big[\textstyle\sum_{n=0}^{T_i^{(1)}-1} f(X_n)\Big] \overset{(8.10)}{=} \pi(f)\,,$$

Analogno se dobije da $\mathbb{P}_i$-g.s. vrijedi i $\frac{1}{n}\sum_{m=1}^{B_n} Z_m \xrightarrow{n\to\infty} \pi(f)$, pa (8.8) slijedi iz (8.14).

Slučaj (b) pogledati sami.

[Definiramo pozitivni i negativni dio od f: za sve $j \in S$,

$$f^+(j) := \max\{0, f(j)\}$$
$$f^-(j) := \max\{0, -f(j)\}\,.$$

Očito su $f^+, f^- : S \to \mathbb{R}$ obje nenegativne te vrijedi $f = f^+ - f^-$ i $|f| = f^+ + f^-$. Budući da je

$$\infty > \sum_{j\in S} |f(j)|\pi_j = \pi(f^+) + \pi(f^-)\,,$$

slijedi da je i

$$\pi(f^+) < \infty\,,\quad \pi(f^-) < \infty$$

pa je $\pi(f) = \pi(f^+) - \pi(f^-)$ dobro definirano. Budući da je

$$\frac{1}{n}\sum_{k=0}^{n-1} f(X_k) = \frac{1}{n}\sum_{k=0}^{n-1} f^+(X_k) - \frac{1}{n}\sum_{k=0}^{n-1} f^-(X_k)\,,$$

tvrdnja (8.8) za f slijedi ako (8.8) primijenimo na nenegativne funkcije f^+ i f^-.[6]]

□

[6] Uočimo da je dovoljno pretpostaviti da je $\pi(f^+) < \infty$ ili $\pi(f^-) < \infty$, te u tom slučaju imamo $\pi(f) \in [-\infty, \infty]$.

NAPOMENA 8.5 (**Intuicija o obliku stacionarne razdiobe**). Pretpostavimo da je i pozitivno povratno stanje, te $X_0 = i$. Iz dokaza ergodskog teorema (za $f = \mathbb{1}_{\{j\}}$) slijedi da gotovo sigurno

$$\frac{N_j(n)}{n} \xrightarrow{n\to\infty} \frac{1}{\mathbb{E}_i\left[T_i^{(1)}\right]} \mathbb{E}_i\left[\sum_{n=0}^{T_i^{(1)}-1} \mathbb{1}_{\{X_n=j\}}\right] = \frac{\nu_j^{(i)}}{m_i}\,, \quad \forall j \in S\,. \tag{8.15}$$

S druge strane, ako za distribuciju π vrijedi $X_n \xrightarrow{d} \pi$, nužno je $\pi = \pi P$, ali i

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=0}^{n-1} \mathbb{P}(X_k = j) = \lim_{n\to\infty} \mathbb{P}(X_n = j) \xrightarrow{n\to\infty} \pi_j\,, \quad \forall j \in S\,. \tag{8.16}$$

Budući da je

$$\frac{1}{n} \sum_{k=0}^{n-1} \mathbb{P}(X_k = j) = \mathbb{E}\left[\frac{1}{n} \sum_{k=0}^{n-1} \mathbb{1}_{\{X_k=j\}}\right] = \mathbb{E}\left[\frac{N_j(n)}{n}\right],$$

nužno je

$$\pi_j \overset{(8.16)}{=} \lim_{n\to\infty} \mathbb{E}\left[\frac{N_j(n)}{n}\right] = \mathbb{E}\left[\lim_{n\to\infty} \frac{N_j(n)}{n}\right] \overset{(8.15)}{=} \mathbb{E}\left[\frac{\nu_j^{(i)}}{m_i}\right] = \frac{\nu_j^{(i)}}{m_i}\,, \quad \forall j \in S\,,$$

pri čemu smo u drugoj jednakosti koristili TDK ($N_j(n)/n \leqslant 1$, $\forall n$, te $\mathbb{E}[1] = 1 < \infty$). [Ovo daje intuiciju zašto bi distribucija koja zadovoljava $\pi = \pi P$ trebala biti baš tog oblika.]

POGLAVLJE 9

Reverzibilnost i uvjeti detaljne ravnoteže

Za matricu prijelaza $P = (p_{i,j} : i, j \in S)$ i mjeru $\lambda = (\lambda_i : i \in S)$ na S kažemo da su u **detaljnoj ravnoteži** ako vrijedi

$$\lambda_i p_{ij} = \lambda_j p_{ji}\,, \quad \forall i, j \in S\,. \tag{9.1}$$

[Ako λ_i interpretiramo kao masu u stanju i, očito vrijedi...]

Propozicija 9.1. *Ako su P i λ u detaljnoj ravnoteži [i λ nije nul-mjera], tada je λ invarijantna mjera za P.*

Dokaz. Za proizvoljni $j \in S$ imamo

$$\sum_{i\in S} \lambda_i p_{ij} \overset{(9.1)}{=} \sum_{i\in S} \lambda_j p_{ji} = \lambda_j \sum_{i\in S} p_{ji} = \lambda_j\,.$$

□

[Ako postoji rješenje sustava (9.1), tipično ga je puno jednostavnije pronaći nego riješiti sustav $\lambda = \lambda P$!]

Vjerojatnosna interpretacija uvjeta detaljne ravnoteže?

Za slučajni proces $(X_n)_{n\geqslant 0}$ u S kažemo da je **reverzibilan** ako za sve $N \geqslant 0$ vrijedi

$$(X_N, X_{N-1}, \ldots, X_0) \overset{d}{=} (X_0, X_1, \ldots, X_N)\,. \tag{9.2}$$

Teorem 9.2. *Ako je $(X_n)_{n\geqslant 0}$ (λ, P)-ML, on je reverzibilan akko su P i λ u detaljnoj ravnoteži.*

Dokaz. Ako je $(X_n)_{n\geqslant 0}$ reverzibilan proces, tada iz (9.2) uz $N = 1$ imamo da za sve $i, j \in S$ vrijedi

$$\lambda_i p_{ij} = \mathbb{P}(X_0 = i, X_1 = j) = [\text{reverzibilnost}] = \mathbb{P}(X_0 = j, X_1 = i) = \lambda_j p_{ji}\,.$$

Obratno, ako su P i λ u detaljnoj ravnoteži, za proizvoljne $N \geqslant 0, i_0, \ldots, i_N \in S$ imamo

$$\begin{aligned}
&\mathbb{P}(X_N = i_0, \ldots, X_0 = i_N) = \lambda_{i_N} p_{i_N i_{N-1}} \cdots p_{i_1 i_0} \\
&\overset{(9.1)}{=} p_{i_{N-1} i_N} \lambda_{i_{N-1}} p_{i_{N-1} i_{N-2}} \cdots p_{i_1 i_0} \overset{(9.1)}{=} p_{i_{N-1} i_N} p_{i_{N-2} i_{N-1}} \lambda_{i_{N-2}} p_{i_{N-2} i_{N-3}} \cdots p_{i_1 i_0} \\
&= \cdots = p_{i_{N-1} i_N} p_{i_{N-2} i_{N-1}} \cdots p_{i_0 i_1} \lambda_{i_0} = \lambda_{i_0} p_{i_0 i_1} \cdots p_{i_{N-1} i_N} = \mathbb{P}(X_0 = i_0, \ldots, X_N = i_N)\,.
\end{aligned}$$

[Dakle, na reverzibilnost možemo gledati kao na poopćenje uvjeta detaljne ravnoteže.] □

[Uočimo da početna razdioba uz koju je lanac u reverzibilan može jedino biti jedna od njegovih stacionarnih razdioba. Budući da za ireducibilne lance može postojati najviše jedna takva razdioba, jednostavno ćemo reći da je "lanac reverzibilan" ako takva razdioba postoji.

U nastavku se nećemo previše baviti posljedicama reverzibilnosti, već ćemo dati neke primjere klasa reverzibilnih ML-a – za njih stacionarnu razdiobu možemo relativno jednostavno odrediti iz uvjeta detaljne ravnoteže.]

PRIMJER 9.3 (**Proces rađanja i umiranja**). Neka je $M \in \mathbb{N}$ i $(X_n)_{n\geqslant 0}$ lanac na $S = \{0, 1, \ldots, M\}$ s prijelaznim vjerojatnostima [nacrtati graf]:

$$p_{i,i-1} = q_i\,, \quad p_{i,i} = r_i, \quad p_{i,i+1} = p_i\,, \quad i \in S$$

pri čemu je $q_0 = p_M = 0$, te

- $p_0, \ldots, p_{M-1} > 0$, $q_1, \ldots, q_M > 0$, te
- $\forall i \in S$, $q_i + r_i + p_i = 1$.

Lanac je ireducibilan, a lako se pokaže (DZ, vidi zadatke za vježbu) da postoji rješenje λ sustava (9.1) te da je dano s

$$\lambda_i = \lambda_0 c_i\,, \quad i \in S\,, \tag{9.3}$$

pri čemu je $\lambda_0 > 0$ proizvoljan, te $c_0 = 1$ i

$$c_i = \frac{p_{i-1}\cdots p_0}{q_i \cdots q_1}\ (>0)\,, \quad i \geqslant 1\,, \tag{9.4}$$

Specijalno, $\pi_i; = \frac{c_i}{\sum_{j\in S} c_j}$, $i \in S$ je vjerojatnosna distribucija koja je u detaljnoj ravnoteži s P.

$\Rightarrow$ π je (jedinstvena) stacionarna distribucija;

$\Rightarrow$ $(X_n)_{n\geqslant 0}$ je reverzibilan ML (ako $X_0 \sim \pi$) bez obzira na q_i, r_i, p_i!

PRIMJER 9.4 (**Ehrenfestov model**). Imamo M kuglica u 2 kutije, označimo ih s A i B. Svake sekunde slučajno (uniformno) odaberemo bilo koju od M kuglica, te ju prebacimo u drugu kutiju. Neka je X_n ukupan broj kuglica u kutiji A nakon n sekundi, $n \geqslant 0$.[1]

Proces $(X_n)_{n\geqslant 0}$ je očito ML na $S = \{0, 1, \ldots, M\}$ s prijelaznim vjerojatnostima [nacrtati graf]:

$$p_{i,i-1} = \frac{i}{M}\,, \quad p_{i,i+1} = \frac{M-i}{M}\,, \quad i \in S, i \neq 0, M\,,$$

uz $p_{0,1} = p_{M,M-1} = 1$. Budući da je ovo specijalan slučaj procesa rađanja i umiranja iz Primjera 9.3, znamo da je lanac reverzibilan te da je (jedinstvena) stacionarna distribucija dana s

$$\pi_i = \frac{1}{2^M}\binom{M}{i}\,, \quad i \in S\,. \tag{9.5}$$

Prethodno slijedi jer u (9.4) imamo $c_i = \binom{M}{i}$, $i \in S$ te je $\sum_{j\in S} c_j = (1+1)^M = 2^M$, ili jednostavno direktnim rješavanjem sustava (9.1).

[1] Originalno, svrha modela bila je statističko-mehanički opis izmjene topline izmedu dva sustava različitih temperatura.

Uočimo, π je točno binomna razdioba s parametrima M i $\frac{1}{2}$! Intuicija? [Ako fiksiramo jednu kuglicu te gledamo u kojoj se kutiji nalazi nakon n sekundi, dobivamo ML na $\{A, B\}$ čija je granična razdioba uniformna, tj. kuglica se asimptotski s jednakom vjerojatnosti nalazi u bilo kojoj od kutija. Iako su ML-i koji odgovaraju kretanjima svake od M kuglica zavisni, asimptotski (tj. nakon velikog broja sekundi) će svaka od kuglica puno puta promijeniti kutiju pa očekujemo da se svaka kuglica nezavisno od ostalih nalazi u kutiji A s vjerojatnošću $\frac{1}{2}$.]

Nadalje, period lanca je 2 [Zašto? Koja je ciklička dekompozicija? Ako npr. krećemo iz 0, u parnim trenutcima se nalazimo u parnim, a u neparnim trenutcima u neparnim stanjima $i \in S$.]. Ipak, graničnu razdiobu možemo dobiti ako gledamo tzv. *lijenu verziju* lanca – to je ML s prijelaznom matricom $\widetilde{P} := \frac{1}{2}(P + I)$, gdje je I jedinična matrica, tj.

- $\widetilde{p}_{ij} := \frac{1}{2}p_{i,j}$, za sve $i \neq j$;
- $\widetilde{p}_{ii} := \frac{1}{2} + \frac{1}{2}p_{i,i} \geqslant \frac{1}{2}$, za sve $i \in S$.

[Dakle, u svakom koraku s vjerojatnošću $\frac{1}{2}$ ostajemo u istom stanju, a s vjerojatnošću $\frac{1}{2}$ napravimo prijelaz po P.]

Lako se pokaže (DZ) da je stacionarna distribucija za $\widetilde{P}$ i dalje $\pi = \mathrm{B}(M, \frac{1}{2})$ te da je ML $(\widetilde{X}_n)_n$ ireducibilan i reverzibilan, a period je očito jednak 1. Teorem o graničnoj razdiobi povlači da za velike n razdioba od $\widetilde{X}_n$ približno jednaka π, pa reverzibilnost povlači da za takve n,

$$(\widetilde{X}_n, \widetilde{X}_{n+1}, \ldots, \widetilde{X}_{n+N}) \overset{d}{\approx} (\widetilde{X}_{n+N}, \widetilde{X}_{n+N-1}, \ldots, \widetilde{X}_n)\,, \quad \forall N \geqslant 0\,.$$

[Nacrtati jednu tipičnu trajektoriju ovog lanca ako je $X_0 = 0$ – nakon nekog vremena, očekujemo da lanac "oscilira" oko $\frac{M}{2}$ (ako pretp. da je M paran).]

[Reverzibilnost na primjer povlači da (pretp. da je M paran) broj trenutaka $k \in \{n, n+1, \ldots, n+N-1\}$ u kojima se lanac (u sljedećem koraku) udaljava od $\frac{M}{2}$ ima (približno) istu distribuciju kao i broj trenutaka u kojima se lanac približava $\frac{M}{2}$. To se čini kontraintuitivno, ali ključ je u tome da je marginalna distribucija lanca (približno) jednaka π, pri čemu je π_i najveća za $i = \frac{M}{2}$, a svaki put kada se lanac nađe u $\frac{M}{2}$, nužno se u idućem koraku udaljava od $\frac{M}{2}$.]

Primjer 9.5 (**Slučajna šetnja na težinskom grafu**). Neka je $G = (V, E)$ neusmjeren graf sa skupom vrhova V i skupom bridova E[2] (dozvoljeno je da V prebrojiv, dakle da $|V| = \infty$, te da postoje petlje). Svakom bridu $(i, j) \in E$ pridružena je težina $c_{ij} \in (0, \infty)$ (zbog neusmjerenosti pretpostavljamo $c_{ij} = c_{ji}$), a za uređene parove $(i, j) \notin E$ definiramo $c_{ij} := 0$. Za proizvoljni vrh $i \in V$ definiramo težinu vrha i sa $c_i = \sum_{j \in V} c_{ij}$ te pretpostavimo da je $0 < c_i < \infty$ za sve $i \in V$ [npr. zadnji uvjet vrijedi automatski ako je G konačan i povezan graf].

[2] Na skup bridova E gledamo kao na podskup Kartezijevog produkta $V \times V$ koji ima svojstvo da je $(i, j) \in E$ ako i samo ako je $(j, i) \in E$. Alternativno, i vjerojatno prirodnije, je E shvatiti kao skup dvočlanih podskupova od V.

Slučajna šetnja na težinskom grafu $G^c = (V, E, c)$ je Markovljev lanac sa skupom stanja V i prijelaznim vjerojatnostima

$$p_{ij} = \frac{c_{ij}}{c_i} \quad i, j \in V\,, \tag{9.6}$$

to jest, $\forall i \in V$, prijelazne vjerojatnosti $(p_{i,j} : j \in V)$ su proporcionalne s težinama $(c_{ij} : j \in V)$ bridova koji izlaze iz vrha i [uočite da je u definiciji (9.6) zaista bitno da je $c_i \in (0, \infty)$.]

- Očito je šetnja ireducibilna akko je graf G povezan.
- (!) Težine vrhova $(c_i : i \in V)$ su u detaljnoj ravnoteži s P. Zaista, za sve $i, j \in V$,

$$c_i p_{ij} = c_i \frac{c_{ij}}{c_i} = c_{ij} = c_{ji} = c_j \frac{c_{ji}}{c_j} = c_j p_{ji}\,.$$

  [Specijalno, $(c_i : i \in V)$ je invarijantna mjera.]
- Specijalno, ako je graf G povezan [tj. šetnja ireducibilna], stacionarna distribucija postoji akko vrijedi

$$c := \sum_{i \in V} c_i < \infty$$

  U tom slučaju je (jedinstvena) stacionarna distribucija dana s s

$$\pi_i := \frac{c_i}{c}\,, \quad i \in V\,, \tag{9.7}$$

  te je šetnja reverzibilan lanac [ukoliko je početna razdioba jednaka stacionarnoj].
  [Zapravo, lako se pokaže da se *svaki* ireducibilan i reverzibilan ML može prikazati kao slučajna šetnja na povezanom težinskom grafu za koji vrijedi $c < \infty$ – vidi vježbe.]

Napomena 9.6. Ako na danom neusmjerenom grafu $G = (V, E)$ [opet dopuštamo da je $|V| = \infty$, te da postoje petlje] stavimo $c_{ij} = 1$, $\forall (i, j) \in E$, imamo da je

$$c_i = \sum_{j \in V} c_{ij} = \text{broj susjeda od } i \text{ (”stupanj”)} =: d_i\,, \quad \forall i \in V.$$

Uvjet $c_i \in (0, \infty)$, $\forall i \in V$, je ekvivalentan s $d_i \notin \{0, \infty\}$, $\forall i \in V$, [tj. svaki vrh ima barem jednog, a najviše konačno mnogo susjeda], pa je u tom slučaju šetnja dobro definirana te prijelazne vjerojatnosti iz (9.6) postaju

$$p_{ij} = \begin{cases} \frac{1}{d_i}\,, & (i, j) \in E \\ 0\,, & (i, j) \notin E \end{cases}$$

tj. uvjetno na $X_n = i$, X_{n+1} je uniformno odabran susjed vrha i. ML s gornjim prijelaznim vjerojatnostima jednostavno ćemo zvati **slučajna šetnja na** G.

Nadalje, budući da je $c_i = d_i \in \mathbb{N}$, $\forall i \in V$, vrijedi $c = \sum_{i \in V} c_i < \infty$ akko je V konačan skup. Specijalno, ako je G povezan skup, slučajna šetnja na G ima (jedinstvenu) stacionarnu distribuciju akko je V konačan [te je u tom slučaju ona dana s (9.7)].

Primjer 9.7. Neka $(X_n)_{n \geqslant 0}$ slučajna šetnja na potpunom binarnom stablu dubine $N \geqslant 1$ [nacrtati stablo – dakle, korijen stabla ima stupanj 2 (i dubinu 0), listovi stabla imaju stupanj

1 (i dubinu N), a svi ostali vrhovi su stupnja 3 (te dubinu između $1, \dots, N-1$)]. Ako K označava korijen stabla, zanima nas $m := \mathbb{E}_K[T_K^{(1)}]$.

Uočimo, ako s $\widetilde{X}_n$ označimo dubinu vrha X_n, $n \in \mathbb{N}$, proces $(\widetilde{X}_n)_n$ je ML na $\{0, 1, \dots, N\}$ s prijelaznim vjerojatnostima [nacrtati graf]:

$$p_{i,i-1} = \frac{1}{3}\,, \quad p_{i,i+1} = \frac{2}{3}\,, \quad i \neq 0, N\,,$$

uz $p_{0,1} = p_{N,N-1} = 1$. Nadalje, imamo $m = \mathbb{E}_0[\widetilde{T}_0^{(1)}]$.

Budući da se radi o specijalnom slučaju procesa rađanja i umiranja, stacionarnu razdiobu možemo odrediti iz uvjeta detaljne ravnoteže kao u Primjeru 9.3.

Alternativno, ovaj lanac [kao i svaki drugi ireducibilan i reverzibilan ML] možemo prikazati kao slučajnu šetnju na povezanom težinskom grafu. U ovom slučaju to je graf s vrhovima $V = \{0, 1, \dots, N\}$ pri čemu su $i, j \in V$ povezani bridom akko je $|i - j| = 1$. Težine odredimo tako da npr. stavimo $c_{0,1} := 1$, pa budući da mora vrijediti $c_{i,i+1} = 2c_{i,i-1}$ za sve $i = 2, \dots, N-1$, za težine bridova dobivamo $c_{i,i+1} = 2^i$, $i = 2, \dots, N-1$ [nacrtati ovaj težinski graf].

Za ovaj težinski graf vrijedi $c_0 = 1$ te

$$c := \sum_{i=0}^{N} c_i = [\text{nema petlji}] = 2 \cdot \sum \text{težina svih bridova} = 2 \cdot \sum_{i=0}^{N-1} 2^i = 2 \cdot \frac{1 - 2^N}{1 - 2} = 2^{N+1} - 2\,.$$

Dakle, jedinstvena stacionarna distribucija π zadovoljava $\pi_0 = \frac{c_0}{c} = \frac{1}{2^{N+1}-2}$, pa je

$$m = \frac{1}{\pi_0} = 2^{N+1} - 2\,.$$

Primjer 9.8 (**Lanci sa strukturom stabla**). Pretpostavimo da je $(X_n)_{n \geqslant 0}$ ireducibilan i pozitivno povratan ML na S [npr. ireducibilan i $|S| < \infty$] sa stacionarnom distribucijom π, te takav da je, $\forall i, j \in S$, $p_{ij} > 0$ akko $p_{ji} > 0$. Formiramo neusmjereni graf $G = (S, E)$ na sljedeći način: za svaki par $i \neq j \in S$, dodamo brid između njih ako je $p_{ij} > 0$ [ili ekvivalentno $p_{ji} > 0$]; dakle, igorniramo petlje – vidi Sliku 4. Ako je rezultirajući (povezan) graf **stablo**, $(X_n)_{n \geqslant 0}$ je nužno reverzibilan [ukoliko je početna distribucija jednaka stacionarnoj] – npr. proces rađanja i umiranja iz Primjera 9.3 zadovoljava ove pretpostavke te ovako dobivamo alternativan dokaz reverzibilnosti.

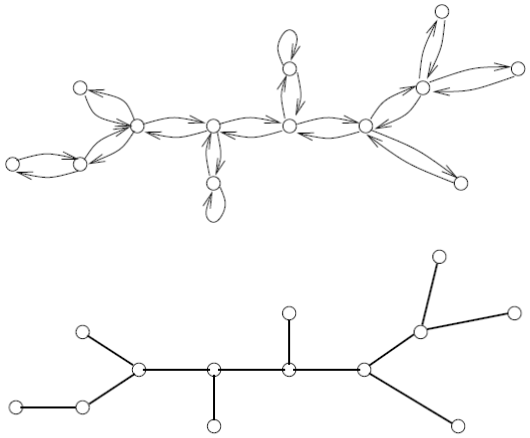
[Elegantan dokaz prethodne tvrdnje slijedi iz sljedećeg rezultata koji je intuitivno trivijalan ako kretanje MLa interpretiramo kao preraspodjelu mase u stanjima. Dokaz tvrdnje ostavljamo za DZ.]

Zadatak. Ako je P prijelazna matrica i λ distribucija na S, za sve $A \subseteq S$ definiramo

$$F_\lambda(A, A^c) := \sum_{i \in A} \sum_{j \in A^c} \lambda_i p_{ij}\,.$$

Ako je $\lambda = \lambda P$, pokažite da vrijedi $F_\lambda(A, A^c) = F_\lambda(A^c, A)$ za sve $A \subseteq S$. □

Pokažimo sada da za naš lanac uvijek vrijedi $\pi_i p_{ij} = \pi_j p_{ji}, \forall i, j \in S$. Neka su $i \neq j$ proizvoljni.



SLIKA 4. Primjer lanca sa strukturom stabla – lanac je reverzibilan bez obzira na vrijednosti prijelaznih vjerojatnosti! Slika preuzeta iz [**Kon**].

- ako je $p_{ij} = 0$, po pretpostavci je i $p_{ji} = 0$, pa je uvjet $\pi_i p_{ij} = \pi_j p_{ji}$ očito zadovoljen;
- ako je $p_{ij} > 0$, micanjem brida (i, j), G rastavljamo na točno dvije komponente $A, A^c \subseteq S$. Zaista, budući da je G povezan, nakon micanja ovog brida možemo dobiti najviše dvije komponente povezanosti, a ako bi i nakon micanja ovog brida postojao put između i i j, originalnom grafu G bi imali ciklus, što je kontradikcija s pretpostavkom da je G stablo. Budući je (i, j) jedini brid između A i A^c, vrijedi

$$\pi_i p_{ij} = F_\pi(A, A^c) = [\pi = \pi P] = F_\pi(A^c, A) = \pi_j p_{ji}\,.$$

9.1. Okretanje vremena

[Za kraj ovog dijela pokazujemo da je tzv. okrenuti lanac *uvijek* ML (ako krećemo iz stacionarne razdiobe).]

TEOREM 9.9. *Neka je $(X_n)_{n\geqslant 0}$ ireducibilan (π, P)-ML gdje je π stacionarna razdioba za P [dakle, postoji]. Tada je za sve $N \geqslant 0$, okrenuti proces $(Y_n)_{0\leqslant n\leqslant N} := (X_{N-n})_{0\leqslant n\leqslant N}$, $(\pi, \widehat{P})$-ML pri čemu je*

$$\widehat{p}_{ji} = \frac{\pi_i}{\pi_j} p_{ij}\,, \quad i, j \in S\,. \tag{9.8}$$

Nadalje, $\widehat{P}$ je ireducibilna te je π njena stacionarna distribucija.

NAPOMENA 9.10. (a) Budući da je $\pi_j > 0, \forall j \in S$, prijelazna vjerojatnost $\widehat{p}_{ji}$ je dobro definirana za sve $i, j \in S$.

(b) Iz prethodnog teorema slijedi da je lanac $(X_n)_{n\geqslant 0}$ reverzibilan akko vrijedi $\widehat{P} = P$ što je dalje ekvivalentno s time da su π i P u detaljnoj ravnoteži – ovo daje alternativan dokaz Teorema 9.2 (uz pretpostavku ireducibilnosti i $X_0 \sim \pi$).

PRIMJER 9.11. Neka je P prijelazna matrica na skupu stanja $S = \{0, 1, \dots, M-1\}$ (skup ostataka modulo M) za $M \geqslant 3$, pri čemu je za $p \in (0,1)$, $q := 1-p$,

$$p_{i,i+1} = p\,, \quad p_{i,i-1} = q\,, \quad i \in S\,.$$

[$M = 0$, a $-1 = M-1$; nacrtati pripadni graf]

Matrica P je očito ireducibilna, te je $\pi_i = \frac{1}{M}$, $i \in S$, jedinstvena stacionarna distribucija [zašto?]. Iz (9.8) dobivamo da su prijelazne vjerojatnosti okrenutog lanca u ovom slučaju dane s $\widehat{p}_{ji} = p_{ij}$, $i, j \in S$, tj.

$$\widehat{p}_{i,i+1} = q\,, \quad \widehat{p}_{i,i-1} = p\,, \quad i \in S\,.$$

Dakle, budući da je stacionarna razdioba upravo uniformna razdioba na S, okrenuti lanac je isti kao i originalni, ali uz zamjenu p i q. Specijalno, originalni lanac je reverzibilan akko je $p = q = \frac{1}{2}$.

DOKAZ TEOREMA 9.9. *1. korak* $\widehat{P}$ je stohastička matrica na S (DZ).

2. korak Za proizvoljan $N \geqslant 0$, proces $(Y_n)_{0 \leqslant n \leqslant N}$ je $(\pi, \widehat{P})$-ML.

Prvo, $Y_0 = X_N$, a budući da je π stacionarna za $(X_n)_{n \geqslant 0}$, imamo $X_N \sim \pi$ – dakle, $Y_0 \sim \pi$. Neka su sada $n \in \{0, 1, \dots, N-1\}$ te $i_0, \dots, i_{n-1}, j, i \in S$ proizvoljni. Ako označimo $k := N - n$, imamo

$$\begin{aligned}
\mathbb{P}(Y_{n+1} \mid Y_n = j, Y_{n-1} = i_{n-1}, \dots, Y_0 = i_0) &= \mathbb{P}(X_{k-1} \mid X_k = j, X_{k+1} = i_{n-1}, \dots, X_N = i_0) \\
&= [(X_n)_{n \geqslant 0} \text{ ML } \Rightarrow \text{uvjetno na } X_k = j,\ X_{k-1} = \text{i } X_{k+1}, \dots, X_N \text{ su nezavisni!}] \\
&= \mathbb{P}(X_{k-1} = i \mid X_k = j) = [\text{Bayesov teorem!}] = \frac{\mathbb{P}(X_k = j \mid X_{k-1} = i)\mathbb{P}(X_{k-1} = i)}{\mathbb{P}(X_k = j)} \\
&= [\pi = \pi P \Rightarrow \mathbb{P}(X_k = i) = \pi_i\,, \ \ \forall i \in S, k \in \mathbb{N}_0] = \frac{p_{ij}\pi_i}{\pi_j} = \widehat{p}_{ji}\,.
\end{aligned}$$

3. korak Vrijedi $\pi\widehat{P} = \pi$, tj. π je stacionarna za $\widehat{P}$ (DZ).

4. korak Matrica $\widehat{P}$ je ireducibilna.

Neka su $j, i \in S$ proizvoljni. Budući da je P ireducibilna, postoji $k \geqslant 0$ t.d. vrijedi $p_{ij}^{(k)} > 0$. Iz 2. koraka (za $N := k$), dobivamo

$$\begin{aligned}
p_{ji}^{(k)} &= \mathbb{P}(Y_k = i \mid Y_0 = j) = \mathbb{P}(X_0 = i \mid X_k = j) = [\text{Bayes, te } \pi = \pi P] \\
&= \frac{p_{ij}^{(k)}\pi_i}{\pi_j} > 0\,.
\end{aligned}$$

□

POGLAVLJE 10

Markov Chain Monte Carlo (MCMC)

[Ovo poglavlje bazirano je na [LP17] i [Bre17].]

Cilj: Za danu distribuciju π na S, simulirati $X \sim \pi$ i/ili procijeniti

$$\pi(A) := \mathbb{P}(X \in A) = \sum_{i \in A} \pi_i \,.$$

Problemi:

1. Skup S je jako velik (ali konačan) i kompliciran, i/ili
2. $\pi_i = \frac{w_i}{c}$, $i \in S$, gdje su *težine* w_i poznate, ali *normalizacijsku konstantu* $c = \sum_{i \in S} w_i \in (0, \infty)$ nije moguće odrediti egzaktno.

[U ovim slučajevima standardna metoda za simuliranje iz diskretnih razdioba (vidi dokaz Teorema 1.7), jednostavno nije upotrebljiva.]

MCMC pristup: Pronaći ML $(X_n)_{n \geqslant 0}$ na S komu je π stacionarna distribucija – ako je lanac ireducibilan, Ergodski teorem povlači

$$\frac{1}{n} \sum_{k=0}^{n-1} 1_{\{X_k \in A\}} \approx \pi(A) \,, \quad \text{za velike } n, \text{ g.s.}$$

a ako je i aperiodičan, $X_n \overset{d}{\approx} \pi$ za velike n.

10.1. Bojanja grafa

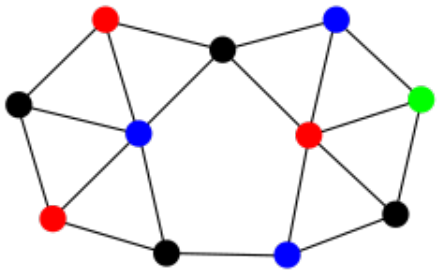
Neka je

- $G = (V, E)$ neusmjeren (jednostavan) graf pri čemu pretpostavljamo da je V konačan skup [dakle nema petlji i višestrukih bridova];
- $k \geqslant 1$, te $[k] := \{1, 2, \ldots, k\}$ skup od k "boja".

Pridruživanje $x \in [k]^V$ (tj. $x : V \to [k]$) zovemo **k-bojanje**[1] grafa G ako vrijedi $x(v) \neq x(w)$, $\forall (v, w) \in E$; vidi Sliku 5. [Riječima, k-bojanje svakom vrhu pridružuje jednu od k boja, ali na način da niti jedan par susjednih vrhova nije iste boje.]

[Motivacija? Na primjer, u problemima slaganja rasporeda – svakom kolegiju treba dodijeliti termin, pri čemu između nekih kolegija postoji, tj. ne smiju ići u istom terminu. Zanima nas najmanji broj termina k tako da kolegije možemo rasporediti u k različitih termina tako da nema

[1] engl. *(proper) k-coloring*



SLIKA 5. Primjer 4-bojanja grafa s 11 vrhova (tzv. *penny graph*). U ovom slučaju ne postoji 3-bojanje jer bi u svakom takvom bojanju, gornji i donja dva središnja vrha nužno bili iste boje. Dakle $4 = \Lambda(G) + 1$ je zapravo kromatski broj.

kolizija. Ako kolegije shvatimo kao vrhove, pri čemu dva vrha spojimo bridom ako između tih kolegija postoji kolizija, traženi problem ekvivalentan je traženju k-bojanja ovog grafa.]

Definiramo skup $S_k(G) := \{x \in [k]^V : x \text{ je } k\text{-bojanja grafa } G\}$ te tzv. *kromatski broj*

$$k^*(G) := \min\{k \geqslant 1 : S_k(G) \neq \emptyset\}\,.$$

[Određivanje skupa $S_k(G)$ i kromatskog broja je netrivijalan problem!] Ipak, lako se pokaže da je uvijek

$$k^*(G) \leqslant \Lambda(G) + 1\,,$$

gdje je $\Lambda(G)$ maksimalan stupanj grafa G (DZ – indukcija po $N = |V|$).

Pretpostavimo da je $k \geqslant k^*(G)$ (tako da je $S_k(G) \neq \emptyset$). Ako je π uniformna razdioba na $S_k(G)$, tj.

$$\pi_x = \frac{1}{|S_k(G)|}\,, \quad x \in S_k(G)\,,$$

za $X \sim \pi$ može nas zanimati

$$\pi(A) = \mathbb{P}(X \in A) = \frac{|A|}{|S_k(G)|}\,, \quad \text{za neki } A \subseteq S_k(G)\,.$$

Događaj $\{X \in A\}$ interpretiramo kao "*tipično* k-bojanje grafa G ima svojstvo A", a određivanje gornje vjerojatnosti je netrivijalan problem budući da je tipično teško odrediti i $|A|$ i $|S_k(G)|$.

Naivan pristup: Kako bismo dobili jednu konfiguraciju $X \sim \pi$, možemo simulirati uniformnu konfiguraciju na cijelom $[k]^V$ [jednostavno za svaki vrh, nezavisno od ostalih vrhova, uniformno izaberemo boju] sve dok ne dobijemo konfiguraciju koja je k-bojanje. Koji je problem s ovim pristupom ako je $|S_k(G)| \ll |[k]^V|$ (što tipično je slučaj)?

MCMC pristup: Generiramo ML $(X_n)_{n\geqslant 0}$ na $S_k(G)$ na sljedeći način – ako je $X_n = x \in S_k(G)$,

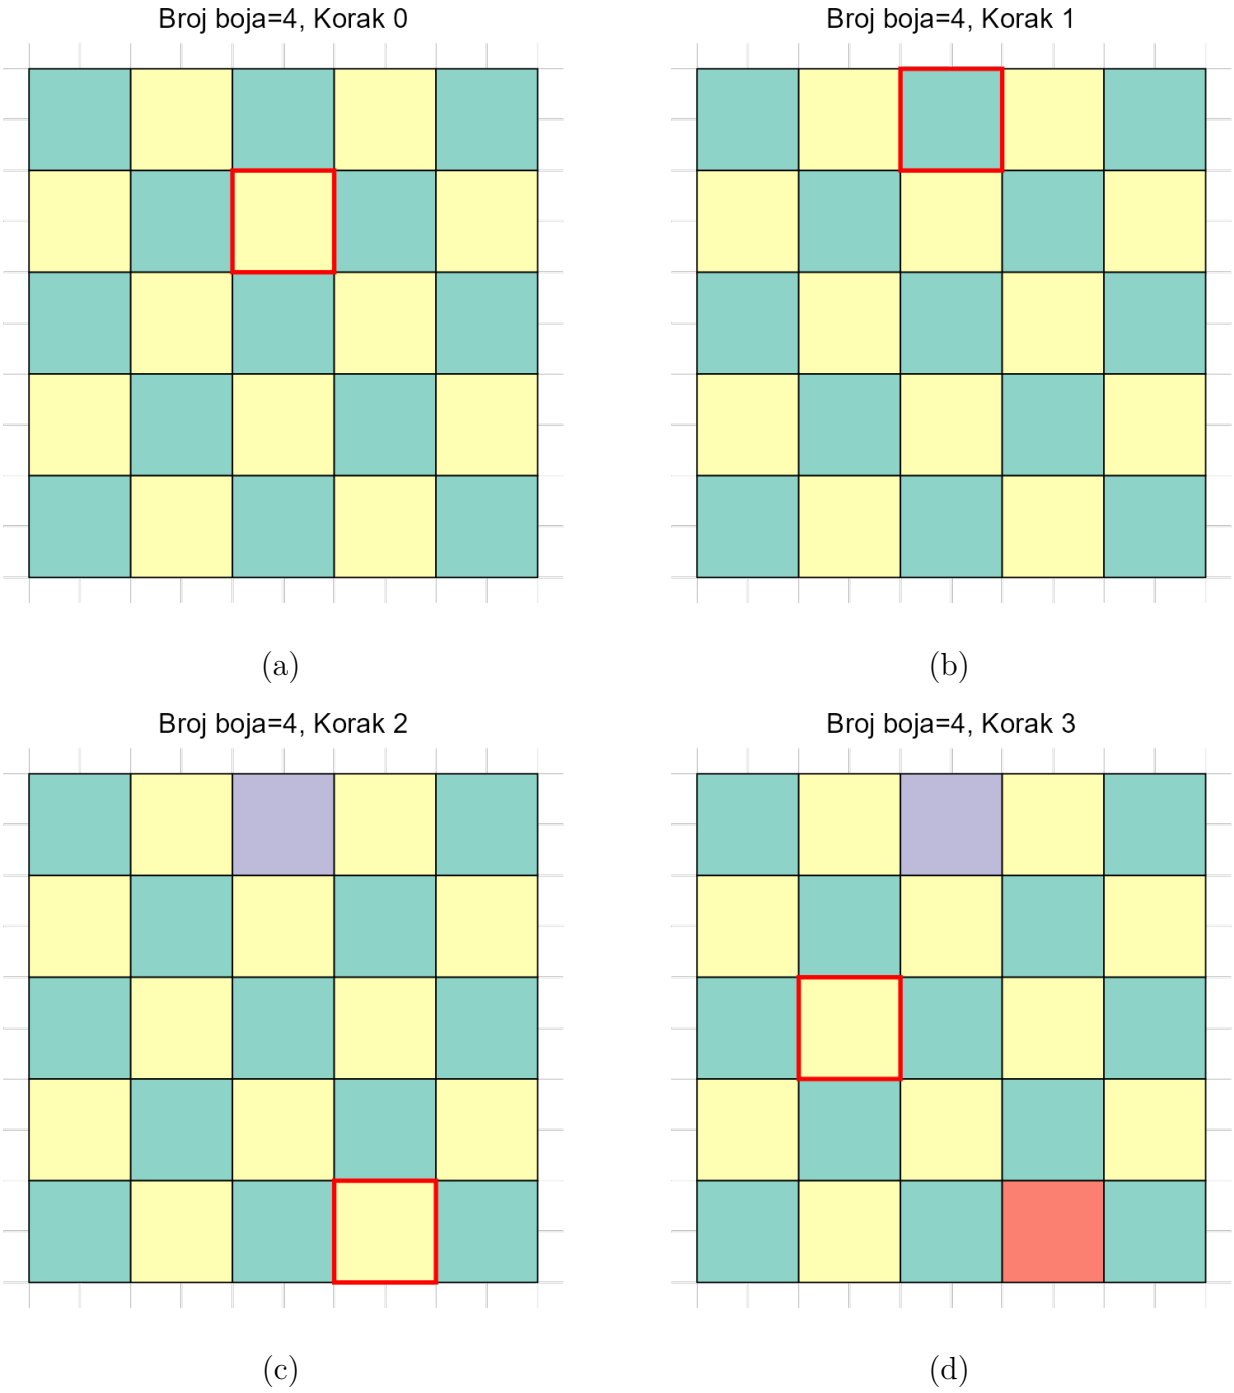
- izaberi vrh $v \in V$ uniformno;

- izaberi uniformno boju j iz skupa *dopustivih* boja [za x u vrhu v]

$$A_v(x) := \{i \in [k] : x(w) \neq i\,,\ \forall w \in V \text{t.d.} (v,w) \in E\}$$

  [uočimo da je uvijek trenutna boja $x(v)$ u $A_v(x)$]
- stavi $y(v) := j$, $y(w) := x(w)$, za sve $w \neq v$, te $X_{n+1} := y$.

Vidi Sliku 6 za ilustraciju gornjeg algoritma.



Slika 6. Početno bojanje i tri iteracije MCMC algoritma za 4-bojanja na rešetci $\{1,2,\ldots,5\}^2$ (dva vrha su susjedi ako im se točno jedna koordinata razlikuje za točno 1). Vrh ()

Slučajni proces $(X_n)_{n\geqslant 0}$ je ML čija je stacionarna distribucija upravo π jer je π u detaljnoj ravnoteži s P. Zaista,

- ako su $x, y \in S_k(G)$ takvi da je $x(v) \neq y(v)$ za barem dva vrha $v \in V$, vrijedi
$$p_{x,y} = 0 = p_{y,x}\,.$$
- ako je za neki $v \in V$, $x(v) \neq y(v)$ i $x(w) = y(w)$, $\forall w \neq v$, budući da je $A_v(x) = A_v(y)$, vrijedi
$$p_{x,y} = \frac{1}{|V|}\cdot\frac{1}{|A_v(x)|} = \frac{1}{|V|}\cdot\frac{1}{|A_v(y)|} = p_{y,x}\,,$$
pa iz $\pi_x = \pi_y$ slijedi $\pi_x p_{x,y} = \pi_y p_{y,x}$.

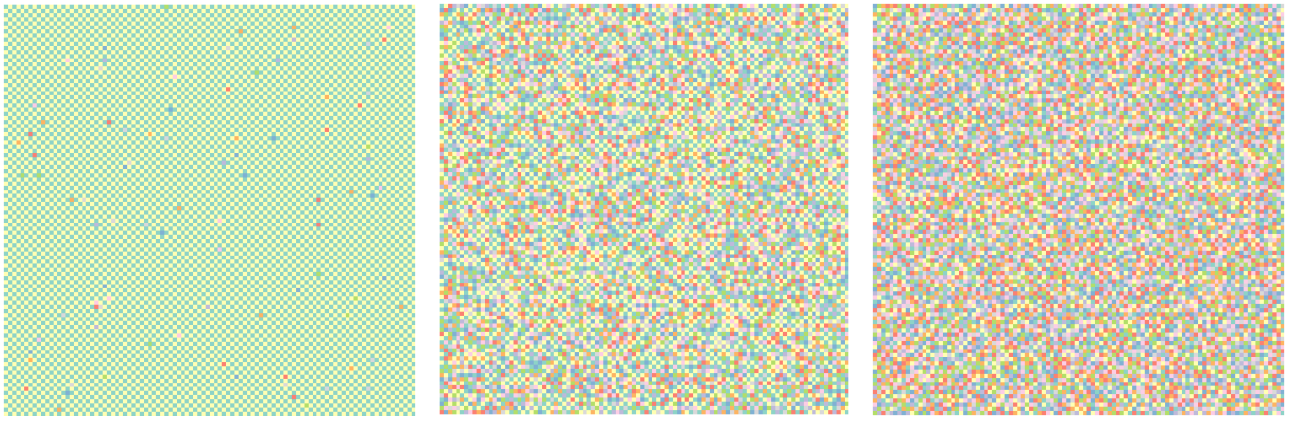
[Uočimo da je generiranje trajektorije lanca $(X_n)_{n\geqslant 0}$ vrlo jednostavno – za izabrani vrh dovoljno je pogledati samo boje njegovih susjeda. Dakle, nije potrebno npr. znati $|S_k(G)|$!]

Lanac $(X_n)_{n\geqslant 0}$ *nije nužno* ireducibilan ako je $k \leqslant \Lambda(G)+1$ [a DZ nađite primjer grafa], ali nije teško za pokazati da to jest slučaj ako je $k \geqslant \Lambda(G)+2$ (DZ). [Ako je $k \geqslant \Lambda(G)+2$, $\forall x, \forall v$, postoji dopustiva boja $j \in A_v(x)$ takva da je $x(v) \neq j$.] Ukoliko je lanac ireducibilan, Ergodski teorem nam daje da $\pi(A)$ možemo procijeniti s $\frac{1}{n}\sum_{k=0}^{n-1} \mathbb{1}_{\{X_k \in A\}}$ za veliki n.

Uočimo da je lanac $(X_n)_{n\geqslant 0}$ uvijek aperiodičan jer je $p_{x,x} > 0$ za proizvoljan $x \in S_k(G)$ – dakle, ako je $k \geqslant \Lambda(G)+2$, π je i granična razdioba ovog lanca.

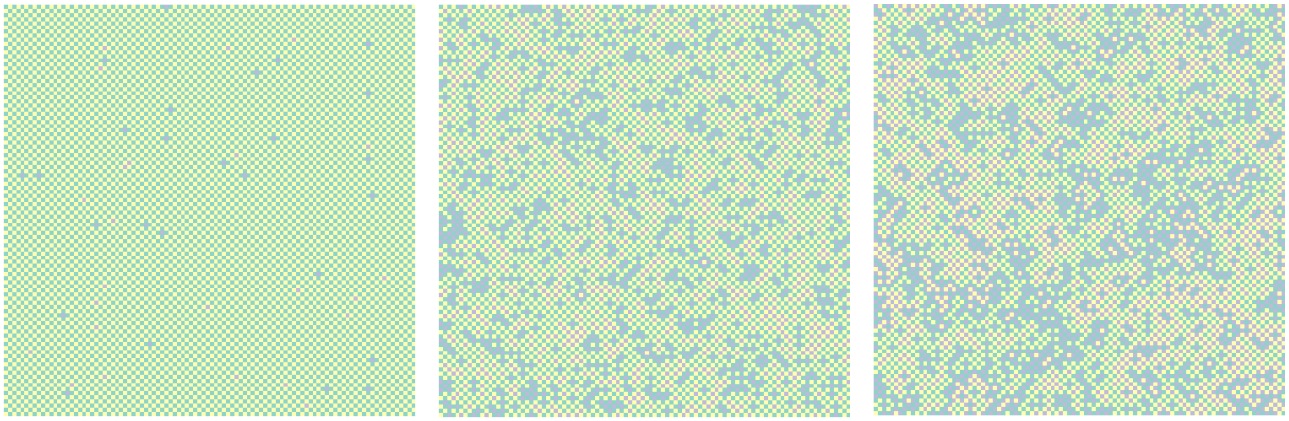
[Također, moguće je iz $X_0, \ldots, X_n$ s veliko vjerojatnosti procijeniti $|S_k(G)|$ do na proizvoljno malu grešku ϵ – za detalje vidjeti [**LP17**, Poglavlje 14.4]]

Za ilustraciju konvergencije vidjeti Slike 7 i 8.



(a) (b) (c)

Slika 7. Gore su prikazane realizacije lanca $(X_n)_n$ za za 9-bojanja na rešetci $\{1, 2, \ldots, 100\}^2$ nakon (a) 10^2, (b) 10^4, i (c) 10^6 koraka. Početno bojanje je bojanje u stilu šahovske ploče sa zelenom i žutom bojom. U ovom slučaju je poznato da lanac $(X_n)_n$ *brzo* konvergira prema stacionarnoj razdiobi.



(a) (b) (c)

SLIKA 8. Gore su prikazane realizacije lanca $(X_n)_n$ za 3-bojanja na rešetci $\{1, 2, \ldots, 100\}^2$ nakon (a) 10^2, (b) 10^4, i (c) 10^6 koraka. Početno bojanje je bojanje u stilu šahovske ploče sa zelenom i žutom bojom. U ovom slučaju lanac $(X_n)_n$ nije ireducibilna te zapravo konvergira prema uniformnoj razdiobi na klasi komuniciranja koja sadrži početnu konfiguraciju. Brzina konvergencije je značjano sporija nego u slučaju 9-bojanja.

10.2. Glauberova dinamika

[engl. *Glauber dynamics*, ili *Gibbs sampler*]

Neka je

- V konačan skup, $k \geqslant 1$;
- $S \subseteq [k]^V$, te π neka vjerojatnosna distribucija na S.
  [Kod problema k-bojanja imali smo $S = S_k(G)$, $\pi_x = 1/|S_k(G)|$, $\forall x \in S_k(G)$.]

Za fiksne $x \in S$, $v \in V$, definiramo distribuciju $\pi^{x,v} = (\pi^{x,v}(i) : i \in [k])$ na $[k]$ sa

$$\pi^{x,v}(i) := \mathbb{P}(X(v) = i \mid X(w) = x(w)\,, \forall w \neq v)\,, \quad i \in [k]\,,$$

pri čemu je $X \sim \pi$.

Glauberova dinamika je ML $(X_n)_{n\geqslant 0}$ na S generiran na sljedeći način: ako je $X_n = x \in S$,

- izaberi vrh $v \in V$ uniformno;
- stavi $X_{n+1}(w) := X_n(w)$, za sve $w \neq v$;
- izaberi boju $i \in [k]$ iz distribucije $\pi^{x,v}$, te stavi $X_{n+1}(v) := i$.

PROPOZICIJA 10.1. *Distribucija π je u detaljnoj ravnoteži s ML $(X_n)_{n\geqslant 0}$ generiranim gornjim algoritmom. Specijalno, π je stacionarna distribucija za $(X_n)_{n\geqslant 0}$.*

[Kako bismo dokazali gornji rezultat, potrebno je odrediti prijelazne vjerojatnosti ML-a $(X_n)_n$.]

Za $x \in S$, $v \in V$, označimo

$$S(x, v) := \{y \in S : y(w) = x(w)\,,\ \forall w \neq v\}\,.$$

[Dakle, $S(x,v)$ je skup svih konfiguracija koje se sa x podudaraju svugdje osim eventualno u vrhu v. Specijalno $1 \leqslant |S(x,v)| \leqslant k$ i $x \in S(x,v)$.]

Iz konstrukcije slijedi da je Glauberova dinamika $(X_n)_{n\geqslant 0}$ ML na S s prijelaznim vjerojatnostima

- $p_{x,y} = 0$ ako ne postoji $v \in V$ t.d. je $y \in S(x,v)$, te
- $p_{x,y} = \frac{1}{|V|}\pi^{x,v}(y(v))$, ako je za neki $v \in V$, $y \in S(x,v)$.

LEMA 10.2. *Za $x \in S$, $v \in V$, vrijedi*

$$\pi^{x,v}(i) = \frac{\pi_{y^i}}{\pi(S(x,v))}\,, \quad i \in [k]\,,$$

pri čemu je $y^i \in S(x,v)$ takva da je $y^i(v) = i$. [Ukoliko $y^i \notin S$, podrazumijevamo da je $\pi_{y^i} := 0$.]

DOKAZ. Ako je $X \sim \pi$, imamo

$$\begin{aligned}\pi^{x,v}(i) &= \frac{\mathbb{P}(X(v) = i,\, X(w) = x(w)\,,\, \forall w \neq v)}{\mathbb{P}(X(w) = x(w)\,,\, \forall w \neq v)} \\ &= \frac{\mathbb{P}(X = y^i)}{\sum_{j\in[k]} \mathbb{P}(\underbrace{X(v) = i,\, X(w) = x(w)\,,\, \forall w \neq v}_{\{X = y^j\}})} = \frac{\pi_{y^i}}{\sum_{j\in[k]}\pi_{y^j}} = \frac{\pi_{y^i}}{\sum_{y\in S(x,v)}\pi_y}\,.\end{aligned}$$

□

DOKAZ PROPOZICIJE 10.1. Neka su $x \neq y \in S$ proizvoljni. Ako ne postoji $v \in V$ t.d. je $y \in S(x,v)$, očito je $p_{x,y} = 0 = p_{y,x}$. S druge strane, ako za neki $v \in V$ vrijedi $y \in S(x,v)$, budući da je $S(x,v) = S(y,v)$ i $x \in S(y,v)$, imamo

$$\pi_x p_{x,y} = \pi_x \cdot \frac{1}{|V|}\frac{\pi_y}{\pi(S(x,v))} = \pi_y \cdot \frac{1}{|V|}\frac{\pi_x}{\pi(S(y,v))} = \pi_y p_{y,x}\,.$$

□

PRIMJER 10.3 (**k-bojanja grafa**). Neka je $S = S_k(G)$ skup svih k-bojanja grafa G i $\pi = \mathrm{Unif}(S_k(G))$. Imamo da je $|S(x,v)|$ jednak broju svih dopustivih boja za x u v (oznaka za taj skup bila je $A_v(x)$), pa je za sve $i \in A_v(x)$,

$$\pi^{x,v}(i) = \frac{\pi_{y^i}}{\pi(S(x,v))} = \frac{1/|S_k(G)|}{|A_v(x)|/|S_k(G)|} = \frac{1}{|A_v(x)|}\,.$$

Drugim riječima, $\pi^{x,v}$ je upravo uniformna razdioba na $A_v(x)$ – dakle, lanac koji smo promatrali u potpoglavlju 10.1 je točno Glauberova dinamika za k-bojanja.

NAPOMENA 10.4. Ako je $\pi_x = \frac{w_x}{c}$, $x \in S$, pri čemu je konstanta c potencijalno nepoznata, za $y \in S(x,v)$ i $i := y(v)$ imamo

$$\pi^{x,v}(i) := \frac{\pi_y}{\pi(S(x,v))} = \frac{w_y}{\sum_{z\in S(x,v)} w_z}\,,$$

što dakle *ne ovisi* o c! [Ipak, kako bi algoritamo bilo moguće praktično provesti $\pi^{x,v}$ ne smije biti prekomplicirano za odrediti. Primjerice, često $\pi^{x,v}$ ovisi samo o vrijednostima od x u susjedima od v, kao što je to bio slučaj kod k-bojanja.]

10.3. Metropolis-Hastingsov algoritam

Glauberova dinamika ograničena je na distribucije na prostorima oblika $S = [k]^V$. U ovom poglavlju promatramo najpoznaitiji MCMC algoritam za simuliranje iz proizvoljne razdiobe na proizvoljnom (diskretnom) prostoru S.

[Ideja osnovnog Metropolisovog algoritma je krenuti s lancem čija je stacionarna distribucija uniformna te modificirati korake tog lanca tako da se češće posjećuju stanja na koje ciljana razdioba stavlja veću masu.]

Metropolisov algoritam.[2] Za danu distribuciju π i simetričnu prijelaznu matricu P na S, te početnu razdiobu λ:

1. Stavi $X_0 \sim \lambda$ te neka je $n := 0$.
2. Ako je $X_n = i$, za iduće stanje lanca "predlažemo" stanje $j \in S$ s vjerojatnošću p_{ij}.
3. Računamo
$$\alpha_{ij} = \min\left\{1, \frac{\pi_j}{\pi_i}\right\}$$
te stavljamo $X_{n+1} := j$ s vjerojatnošću α_{ij}, odnosno $X_{n+1} := i = X_n$ s vjerojatnošću $1 - \alpha_{ij}$.
4. Stavi $n := n + 1$ i vrati se na korak 2.

Napomena.

(a) Ukoliko je $\pi_j = 0$, stavljamo $\alpha_{ij} := 0$ za sve $i \in S$ (bez obzira je li $\pi_i = 0$ ili $\pi_i > 0$). [Drugim riječima, lanac $(X_n)_n$ nikad ne prelazi u stanje $j \in S$ na koje π ne stavlja nikakvu masu.]

(b) Uočimo da

- $\pi_j \geqslant \pi_i$ povlači $\alpha_{ij} = 1$, a s druge strane
- $\pi_j < \pi_i$ povlači $\alpha_{ij} < 1$.

[Dakle, u odnosu na originalni lanac, uvijek prihvaćamo prelazak u stanje kojemu π stavlja veću masu od trenutnog stanja, a nekad odbacujemo prelazak u stanje kojemu π stavlja manju masu.]

□

Rezultirajući proces $(X_n)_{n\geqslant 0}$ je (λ, Q)-ML pri čemu su prijelazne vjerojatnosti

$$q_{ij} = \begin{cases} p_{ij}a_{ij}\,, & \text{ako je } i \neq j, \\ 1 - \sum_{l:l\neq i} p_{il}a_{il}\,, & \text{ako je } i = j. \end{cases}$$

[Formalno, $(X_n)_n$ je ML jer se može konstruirati kao $X_{n+1} = f(X_n, (U_{n+1}, W_{n+1}))$ za neku funkciju f pri čemu su npr. U_{n+1} i W_{n+1} dvije nezavisne uniformne slučajne varijable na $[0, 1]$ pri čemu (1) koristeći U_{n+1} "predlažemo" sljedeće stanje j, a (2) koristeći W_{n+1} konstruiramo

[2] Metropolis et al. (1953)

Bernoullijevu slučajnu varijablu s vjerojatnosti uspjeha a_{ij}, te je dodatno (U_n, W_n), $n \geqslant 1$, niz njd slučajnih vektora. Probajte detalje razraditi sami.]

PROPOZICIJA 10.5. *Uz gornje pretpostavke, π i Q su u detaljnoj ravnoteži. Specijalno, π je stacionarna distribucija lanca $(X_n)_n$.*

DOKAZ. Gledamo proizvoljne $i \neq j$, $i, j \in S$.

1. Ako je $\pi_j = 0$, po našoj konvenciji odmah slijedi da je i $\alpha_{ij} = 0$ te $q_{ij} = 0$, pa specijalno imamo $\pi_i q_{ij} = 0 = \pi_j q_{ji}$. Zbog simetrije, isti zaključak imamo i u slučaju $\pi_i = 0$.
2. Ako je $\pi_i > 0$ i $\pi_j > 0$,

$$\pi_i q_{ij} = \pi_i p_{ij} \min\left\{1, \frac{\pi_j}{\pi_i}\right\} = p_{ij} \min\{\pi_i, \pi_j\} = [p_{ij} = p_{ji}] = \pi_j p_{ji} \min\left\{\frac{\pi_i}{\pi_j}, 1\right\} = \pi_j q_{ji}\,.$$

□

[U gornjem rezultatu Q nije nužno ireducibilna pa π ne mora biti jedinstvena stacionarna distribucija lanca, niti možemo direktno primijeniti ergodski teorem ili teorem o graničnoj distribuciji.]

Za $\widetilde{S} := \{i \in S : \pi_i > 0\}$ [tj. skup na kojem "živi" razdioba π], ako je $\mathbb{P}(X_0 \in \widetilde{S}) = 1$ i Q je ireducibilna na $\widetilde{S}$, π restringirana na $\widetilde{S}$ je jedinstvena stacionarna distribucija za lanac $(X_n)_n$ (na $\widetilde{S}$) te vrijedi Ergodski teorem.

PRIMJER 10.6 (**Umjetan primjer**). Želimo simulirati slučajnu varijablu iz razdiobe $\pi = \frac{1}{10}(1, 2, 3, 4)$ na $S = \{1, 2, 3, 4\}$ [za to nam svakako nije potreban MCMC algoritam, ali nije loše vidjeti na što se svodi Metropolisov algoritam u ovako jednostavnom slučaju]. Za (simetričnu) predlagajuću prijelaznu matricu možemo uzeti

$$P = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{bmatrix}$$

[Drugim riječima, u svakom koraku predlažemo uniformno stanje iz S.]

Prijelazna matrica Metropolisovog lanca je

$$Q = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{8} & \frac{3}{8} & \frac{1}{4} & \frac{1}{4} \\ \frac{1}{12} & \frac{2}{12} & \frac{6}{12} & \frac{1}{4} \\ \frac{1}{16} & \frac{2}{16} & \frac{3}{16} & \frac{10}{16} \end{bmatrix}$$

Matrica Q je očito ireducibilna i aperiodična na S, pa za Metropolisov lanac $(X_n)_n$ vrijedi $X_n \overset{d}{=} \pi$ za velike n. □

PRIMJER 10.7 (**Uniformna razdioba na podskupu**). Neka je S konačan skup, a želimo simulirati iz razdiobe $\pi = \text{Unif}(\widetilde{S})$ za $\widetilde{S} \subseteq S$ [tj. $\pi_i := \frac{1}{|\widetilde{S}|}$, $i \in \widetilde{S}$, te $\pi_i := 0$, $i \in S \setminus \widetilde{S}$].

Za Metropolisov lanac baziran na proizvoljnoj (simetričnoj) prijelaznoj matrici P na S, za sve $i \in S$ vrijedi

$$\alpha_{ij} = \begin{cases} 1\,, & \text{ako je } j \in \widetilde{S}\,, \\ 0\,, & \text{ako je } j \in S \setminus \widetilde{S}\,. \end{cases}$$

[Riječima, prihvaćamo prijelaz u stanje j akko je $j \in \widetilde{S}$.]

[Slučaj iz prethodnog primjera možemo primijeniti na problem simuliranja *tipičnog* k-bojanja grafa.]

Primjer 10.8 (**k-bojanja grafa**). Ako je π uniformna razdioba na $S_k(G) \subseteq [k]^V$ (vidi Potpoglavlje 10.1), te za predlagajući ML uzmemo sljedeći lanac na $[k]^V$: u svakom koraku uniformno biramo vrh $v \in V$ te taj vrh obojimo s uniformno odabranom bojom iz $[k]$ [uvjerite se da je pripadna prijelazna matrica P na $[k]^V$ simetrična].

[Dakle, u Metropolisovom lancu, ako je trenutna konfiguracija $x \in [k]^V$ k-bojanje grafa, predložena promjena $x(v) \mapsto i$ za $i \in [k]$ će se prihvatiti ako i dalje dobivamo k-bojanje, a u suprotnom odbiti.]

Uočimo da je ovaj lanac sličan, ali ne potpuno isti kao i Glauberova dinamika za π – ako za vrh v postoji a dopustivih boja, te je taj vrh izabran promjenu, vjerojatnost da ćemo u idućem koraku ostati u istoj konfiguraciji (tj. da se boja u v neće promijeniti),

- jednaka je $\frac{1}{a}$ za Glauberovu dinamiku, a
- $\frac{1+(k-a)}{k}$ za Metropolisov lanac [ako izaberemo istu boju ili neku od preostalih $k-a$ nedopuštenih boja].

□

Ako predlagajuća matrica P *nije simetrična*, u Metropolisovom algoritmu možemo korigirati vjerojatnosti prihvaćanja tako da stavimo

$$\alpha_{ij} := \min\left\{1, \frac{\pi_j p_{ji}}{\pi_i p_{ij}}\right\}\,,$$

uz konvenciju $\alpha_{ij} := 0$ ukoliko je $\pi_j p_{ji} = 0$. Rezultirajući algoritam naziva se **Metropolis-Hastingsov** algoritam. [3]

[Za DZ pokažite da i dalje vrijedi da je rezultirajuća prijelzna matrica Q u detaljnoj ravnoteži s π.]

Napomena 10.9. Kao i kod Glauberove dinamike, ako je $\pi_i = \frac{w_i}{c}$, $i \in S$, imamo da je

$$\frac{\pi_j p_{ji}}{\pi_i p_{ij}} = \frac{w_j p_{ji}}{w_i p_{ij}}\,,$$

tj. α_{ij} (pa onda i cijeli MH algoritam) ne ovisi o c.

[3] Hastings (1970).

10.4. Isingov model

Na prostoru konfiguracija $S = [k]^V$ često se javlja tzv. **Gibbsova** ili **Boltzmannova** razdioba

$$\pi(x) = \frac{1}{Z(T)} \exp\left\{-\frac{1}{T} H(x)\right\}$$

gdje je $T > 0$ nazivamo *temperatura*, $H(x) \in \mathbb{R}$ *energija* konfiguracije x, te

$$Z(T) = \sum_{x \in S} \exp\left\{-\frac{1}{T} H(x)\right\}$$

normalizacijska konstanta.

[Povijesno, ovi nazivi za parametre dolaze iz područja *statističke fizike*. Uočimo, ova razdioba stavlja (eksponencijalno) veliku masu na konfiguracije jako male energije, a malu masu na konfiguracije velike energije. Temperatura T kontrolira utjecaj energije H – kada $T \nearrow +\infty$, utjecaj energije se smanjuje te π konvergira prema uniformnoj razdiobi na S. Zapravo, ako dopustimo da $H(x)$ poprima vrijednost $+\infty$, svaku razdiobu π na S možemo zapisati u ovom obliku – jednostavno uzmemo $T = 1$ i $H(x) := \log(1/\pi(x))$ ($Z(1) = 1$). Ipak, nas će zanimati slučajevi gdje se ova razdioba javlja prirodno. Napomenimo da je konstantnu $Z(T)$ uglavnom preteško za izračunati numerički.]

Najpoznatiji primjer ovakve razdiobe je tzv. **Isingov model** – to je razdioba na $S = \{-1, 1\}^V$ [dakle, $k = 2$] gdje su V vrhovi (neusmjerenog, jednostavnog i konačnog) grafa $G = (V, E)$, a funkcija energije dana je s

$$H(x) := -\sum_{v,w \in W : v \sim w} x(v)x(w)\,.$$

[Riječima, energija raste kako raste broj parova $v \sim w$ u kojima x daje različite vrijednosti (tzv. *spinove*). Dakle, Gibbsova razdioba u ovom slučaju stavlja veću masu na konfiguracije u kojima puno parova susjednih vrhova imaju istu vrijednost *spina*.]

[Svojstva Isingovog modela nije jednostavno za razumjeti (zbog toga je korisno imati metodu za simuliranje iz Isingovog modela). Prije svega, $|S| = 2^{|V|}$ pa dakle broj konfiguracija raste eksponencijalno s brojem vrhova. Vezano s tim, iako π najveću masu stavlja na konfiguracije koje se uglavnom sastoje od istih spinova (tj. skoro svi spinovi su $+1$ ili skoro svi spinovi su -1), broj takvih konfiguracija je tipično jako malen u odnosu na broj svih konfiguracija. Zbog toga, ne mora značiti da će se $X \sim \pi$ s velikom vjerojatnosti imati uglavnom iste spinove. To će biti slučaj ukoliko je temperatura T dovoljno mala. Ono što je zanimljivo je da u ovom (i raznim drugim sličnim modelima) postoji *fazni prijelaz* – postoji *kritična temperatura* $T_c > 0$ takva da za $T < T_c$ (*niske temperature*) tipična konfiguracija Isingovog modela se sastoji od velikog broja istih spinova, a ako je $T > T_c$ (*visoka temperatura*) broj pozitivnih i negativnih spinova je *približno* jednak. Najzanimljivi je (u ovom, ali tako i u drugim modelima) kritični slučaj $T = T_c$. Za više detalja i preciznije tvrdnje, vidjeti primjerice [**FV17**].]

[Glauberova dinamika za π u svakom koraku uniformno bira vrh $v \in V$, te generira vrijednost *spina* u v iz uvjetne razdiobe $\pi^{x,v}$, pri čemu je x trenutna konfiguracija. U sljedećem rezultatu pokazujemo da ta uvjetna razdioba ovisi *samo* o susjednim spinovima od x, što omogućava vrlo jednostavnu implementaciju Glauberove dinamike.]

PROPOZICIJA 10.10. *Za sve $x \in S$ i sve $v \in V$ vrijedi*

$$\pi^{x,v}(i) = \frac{1}{1 + e^{-\frac{2}{T}\sum_{w:v\sim w} x(w)}}\,.$$

[Funkcija $x \mapsto \frac{1}{1+e^{-x}}$, za $x \in \mathbb{R}$ se ovisno o kontekstu nazvia različitim imenima, npr. logistička, expit ili softmax funkcija. Ta funkcija je strogo rastuća i neprekidna bijekcija sa $\mathbb{R}$ u interval $(0,1)$. Dakle, gornja vjerojatnost raste kako se povećava broj susjeda od v čiji spin ima vrijednost 1, što je u skladu s intuicijom.]

DOKAZ. Označimo sa $S(x,v) = \{x^+, x^-\}$ pri čemu je $x^+(v) = 1$ i $x^-(v) = -1$. Tada imamo

$$\pi^{x,v}(1) = \frac{\pi_{x^+}}{\pi_{x^-} + \pi_{x^+}} = \frac{e^{-\frac{1}{T}H(x^+)}}{e^{-\frac{1}{T}H(x^-)} + e^{-\frac{1}{T}H(x^+)}}\,.$$

Ako označimo $s := \sum_{w,w'\in V\setminus\{v\}:w\sim w'} x(w)x(w')$, imamo

$$-H(x^+) = 1 \cdot \sum_{w:w\sim v} x(w) + s\,, \quad -H(x^+) = (-1)\cdot \sum_{w:w\sim v} x(w) + s\,.$$

Dakle,

$$\pi^{x,v}(1) = \frac{e^{\frac{1}{T}\sum_{w:w\sim v} x(w)}}{e^{-\frac{1}{T}\sum_{w:w\sim v} x(w)} + e^{\frac{1}{T}\sum_{w:w\sim v} x(w)}} = \frac{1}{e^{-\frac{2}{T}\sum_{w:w\sim v} x(w)} + 1}\,.$$

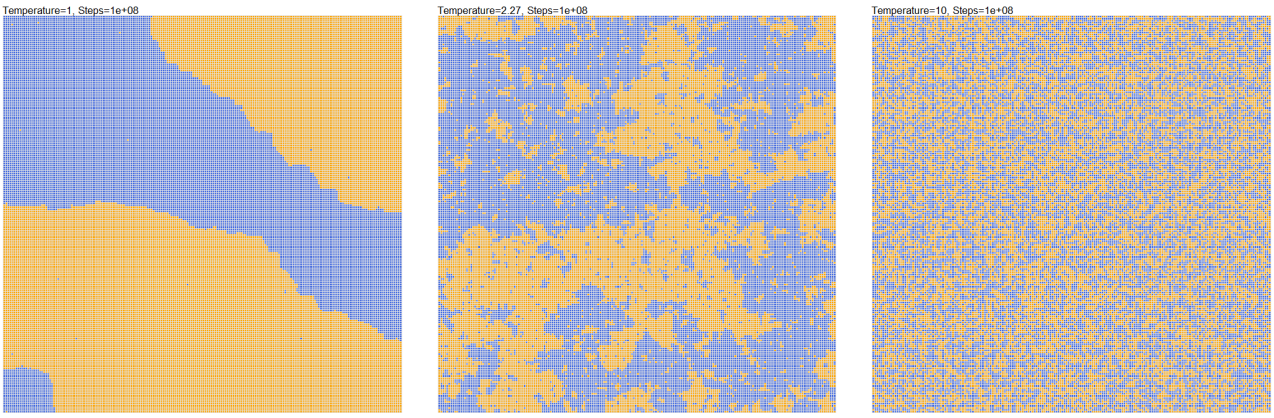
□

Nekoliko realizacija Glauberove dinamike za Isingov model na konačnoj rešetci prikazano je na Slici 9.

ZA VJEŽBU: ODREDITI METROPOLISOV ALGORITAM ZA ISINGOV MODEL U SLUČAJU KADA PREDLAGAJUĆI LANAC U SVAKOM KORAKU MIJENJA SPIN UNIFORMNO ODABRANOG VRHA.

[**Završne napomene.** (a) Općenito, jako je bitno da $(X_n)_{n\geqslant 0}$ iz odabranog MCMC *što brže* konvergira prema π. Analiza brzine konvergencije MCMC algoritama izlazi van okvira ovog kolegija – za više detalja pogledati [**LP17**].

(b) Jedna od glavnih primjena MCMC metode je u tzv. *Bayesovskoj statistici* i strojnom učenju gdje se koristi za simuliranje iz tzv. *aposteriorne* razdiobe koju uglavnom znamo samo do na normalizirajuću konstantu. Za to se koriste ML na općenitom skupu stanja (npr. na $\mathbb{R}^d$) što također izlazi van okvira ovog kolegija. Ipak, osnovne ideje Metropolisovog i Gibbsovog algoritma ostaju iste.]



(a) (b) (c)

SLIKA 9. Gore su prikazane realizacije Glauberove dinamike $(X_n)_n$ za Isingov model na rešetci $\{1, 2, \ldots, 200\}^2$ nakon 10^8 koraka u tri slučaja: (a) niska temperatura, (b) kritična temperatura, te (c) visoka temperatura. U sva tri slučaja krenuli smo iz (iste) uniformno odabrane konfiguracije – jednostavno smo za svaki v uniformno (i nezavisno od drugih vrhova) odabrali $X_0(v)$ iz skupa $\{-1, 1\}$. Važno je ovdje napomenuti da bez dodatnih teorijskih rezultata, mi nemamo garanciju da je distribucija od X_n za $n = 10^8$ približno jednaka distribuciji Isingovog modela. [S obzirom na početnu konfiguraciju, za koji biste od ova tri slučaja rekli da to ipak vrijedi?]

Bibliografija

[AGK19] Richard Arratia, Larry Goldstein i Fred Kochman: *Size bias for one and all*. 2019.

[BD92] Dave Bayer i Persi Diaconis: *Trailing the dovetail shuffle to its lair*. The Annals of Applied Probability, stranice 294–313, 1992.

[Bre17] Tim Brereton: *Stochastic Simulation (lecture notes)*, 2017. https://www.uni-ulm.de/fileadmin/website_uni_ulm/mawi.inst.110/lehre/ss17/Stochastic_Simulation/Lecture_Notes_01.pdf?utm_source=chatgpt.com.

[FV17] Sacha Friedli i Yvan Velenik: *Statistical mechanics of lattice systems: a concrete mathematical introduction*. Cambridge University Press, 2017.

[Kon] Takis Konstantopoulos: *Markov chains and random walks (lecture notes)*. https://mcube.lab.nycu.edu.tw/~cfung/docs/books/konstantopoulous2009_mcrw.pdf.

[LP17] David A. Levin i Yuval Peres: *Markov chains and mixing times*, svezak 107. American Mathematical Soc., 2017. https://pages.uoregon.edu/dlevin/MARKOV.

[Nor98] James R Norris: *Markov chains*. Broj 2. Cambridge university press, 1998. https://www.statslab.cam.ac.uk/~james/Markov/.

[Von] Zoran Vondraček: *Markovljevi lanci (skripta)*. https://web.math.pmf.unizg.hr/~vondra/ml12-predavanja.html.

[Web] Richard Weber: *Markov chains (lecture notes, Cambridge)*. https://www.statslab.cam.ac.uk/~rrw1/markov/M.pdf.

DODATAK A

Nezavisnost

U nastavku formalno definiramo nezavisnost slučajnih varijabli, vektora i procesa (u diskretnom slučaju).

Događaji

Neka je $(\Omega, \mathcal{F}, \mathbb{P})$ vjerojatnosni prostor. Događaji $A, B \in \mathcal{F}$ su nezavisni ako vrijedi $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ što je, u slučaju da je $\mathbb{P}(B) > 0$, ekvivalentno s $\mathbb{P}(A \mid B) = \mathbb{P}(A)$ (ukoliko je $\mathbb{P}(B) = 0$, A i B su po definiciji nezavisni za sve $A \in \mathbb{F}$).

Za proizvoljan skup J, familija događaja $\{A_j : j \in J\}$ je nezavisna ako za sve $n \geqslant 1$ i sve $j_1, \ldots, j_n \in J$ vrijedi

$$\mathbb{P}(\cap_{k=1}^{n} A_{j_k}) = \prod_{k=1}^{n} \mathbb{P}(A_{j_k}) \,.$$

Slučajni elementi

Neka je S (najviše) prebrojiv skup, tj. S je konačan ili prebojiv. [1]

Definicija A.1. Slučajni element s vrijednostima u S (ili jednostavno, u S) je funkcija $X : \Omega \to S$ takva da je $\{X = i\} \in \mathcal{F}$ za sve $i \in S$ (tj. X je izmjeriva funkcija).

Ako su $S_1, \ldots, S_n$, prebrojivi skupovi te $X_1, \ldots, X_n$ slučajni elementi u $S_1, \ldots, S_n$, redom, kažemo da su $X_1, \ldots, X_n$ nezavisni ako vrijedi

$$\mathbb{P}(X_1 = i_1, \ldots, X_n = i_n) = \prod_{k=1}^{n} \mathbb{P}(X_k = i_k) \,,$$

za sve $i_1, \ldots, i_n$ takve da je $i_k \in S_k$, za sve $k = 1, \ldots, n$.

Korištenjem σ-aditivnosti od $\mathbb{P}$ i prebrojivosti skupova $S_1, \ldots, S_n$, lako se pokaže da je gornja definicija ekvivalentna s

$$\mathbb{P}(X_1 \in A_1, \ldots, X_n \in A_n) = \prod_{k=1}^{n} \mathbb{P}(X_k \in A_k) \,, \tag{A.1}$$

za sve $A_1, \ldots, A_n$ takve da je $A_k \subseteq S_k$, $k = 1, \ldots, n$. Pogledajmo dva specijalna slučaja ove definicije:

- Ako su $X_1, \ldots, X_n$ su slučajni elementi ("varijable") u S, jednostavno stavimo $S_k = S$ za sve $k = 1, \ldots, n$.

[1] Prebrojivost znači da elemente od S možemo poredati u niz, tj. da postoji funkcija $\pi : \mathbb{N} \to S$ koja je bijekcija.

- Ako su $Y = (Y_1, \ldots, Y_m)$ i $Z = (Z_1, \ldots, Z_k)$ slučajni elementi ("vektori") u S^m i S^k, jednostavno stavimo $X_1 = Y, X_2 = Z$ te $S_1 = S^m, S_2 = S^k$; npr. elementi od S_1 su sada uređene m-torke.

Slučajni procesi

Definicija A.2. *Slučajni proces* u S je niz slučajnih elemenata $(X_n)_{n\geqslant 0}$ u S.

Za slučajni proces $(X_n)_{n\geqslant 0}$ u S kažemo da je nezavisan od

(i) slučajnog vektora $(Y_1, \ldots, Y_k)$ u S^k ako je za sve $n \geqslant 0$, slučajni vektor $(X_0, \ldots, X_n)$ (u S^{n+1}) nezavisan od $(Y_1, \ldots, Y_k)$;

(ii) drugog slučajnog procesa $(Y_n)_{n\geqslant 0}$ u S ako je za sve $n, m \geqslant 0$, slučajni vektor $(X_0, \ldots, X_n)$ nezavisan od vektora $(Y_0, \ldots, Y_n)$.

A.1. Uvjetna nezavisnost

Uvjetna nezavisnost (događaja, slučajnih elemenata i slučajnih procesa) uz dano $A \in \mathbb{F}$ (takav da $\mathbb{P}(A) > 0$) definira se kao nezavisnost s obzirom na vjerojatnost $\mathbb{P}_A$ na $(\Omega, \mathcal{F}, \mathbb{P})$ definiranu s $\mathbb{P}_A(B) := \mathbb{P}(B \mid A)$ za sve $B \in \mathbb{F}$.

Lema A.3. *Neka su $A, B, C \in \mathbb{F}$ takvi da je $\mathbb{P}(A) > 0$. Ako je $\mathbb{P}(A \cap C) > 0$, B i C su uvjetno nezavisni uz dano A, tj. $\mathbb{P}(B \cap C \mid A) = \mathbb{P}(B \mid A)\mathbb{P}(C \mid A)$, ako i samo ako vrijedi*

$$\mathbb{P}(B \mid A \cap C) = \mathbb{P}(B \mid A)\,.$$

Ako je $\mathbb{P}(A \cap C) = 0$, B i C su uvjetno nezavisni uz dano A za sve $B \in \mathbb{F}$.

Dokaz. Prva tvrdnja slijedi direktno iz karakterizacije (obične) nezavisnosti preko uvjetne vjerojatnosti jer je $\mathbb{P}_A(C) > 0$ te vrijedi

$$\mathbb{P}_A(B \mid C) = \mathbb{P}(B \mid A \cap C)\,,$$

a druga tvrdnja slijedi odmah jer je u tom slučaju $\mathbb{P}_A(C) = 0$. □

DODATAK B

Teoremi o zamjeni limesa, sume i očekivanja

Nizovi

- **(Fubinijev teorem)** Neka je $(a_{n,m})_{n,m\geqslant 1}$ dvostruki niz realnih brojeva. Ako je $a_{n,m} \geqslant 0$, za sve n, m, uvijek vrijedi

$$\sum_{n=1}^{\infty}\sum_{m=1}^{\infty} a_{n,m} = \sum_{m=1}^{\infty}\sum_{n=1}^{\infty} a_{n,m}\,, \tag{B.1}$$

  s tim da obje strane mogu biti $+\infty$. Općenito, vrijedi (B.1) ako je $\sum_{n=1}^{\infty}\sum_{m=1}^{\infty}|a_{n,m}| < \infty$.
- **(Teorem o monotonoj konvergenciji)** Neka je za svaki $n \geqslant 1$, $(a_m^{(n)})_{m\geqslant 1}$ neopadajući niz nenegativnih realnih brojeva. Tada vrijedi

$$\lim_{n\to\infty}\sum_{m=1}^{\infty} a_m^{(n)} = \sum_{m=1}^{\infty}\lim_{n\to\infty} a_m^{(n)} = \sum_{m=1}^{\infty} a_m \in [0,\infty]\,,$$

  za $a_m := \lim_{n\to\infty} a_m^{(n)} \in [0,\infty]$, $m \geqslant 1$.
- **(Teorem o dominiranoj konvergenciji)** Neka je za svaki $n \geqslant 1$, $(a_m^{(n)})_{m\geqslant 1}$ niz realnih brojeva takav da (i) postoji $a_m := \lim_{n\to\infty} a_m^{(n)}$ za sve $m \geqslant 1$, te (ii) vrijedi $|a_m^{(n)}| \leqslant b_m$, za sve n, m, pri čemu je $(b_m)_{m\geqslant 1}$ niz nenegativnih brojeva takav da $\sum_{m=1}^{\infty} b_m < \infty$. Tada vrijedi $\sum_{m=1}^{\infty}|a_m| < \infty$ te

$$\lim_{n\to\infty}\sum_{m=1}^{\infty} a_m^{(n)} = \sum_{m=1}^{\infty}\lim_{n\to\infty} a_m^{(n)} = \sum_{m=1}^{\infty} a_m \in \mathbb{R}\,.$$

Slučajne varijable

- **(Teorem o monotonoj konvergenciji)** Ako je $(X_n)_{n\geqslant 1}$ neopadajući niz nenegativnih slučajnih varijabli (dakle, $X_n : \Omega \to [0,\infty)$, za sve n), vrijedi

$$\lim_{n\to\infty}\mathbb{E}[X_n] = \mathbb{E}[X] \in [0,\infty]\,,$$

  za (proširenu) slučajnu varijablu $X := \lim_{n\to\infty} X_n$. Specijalno, ako teorem primijenimo na niz $(\sum_{n=1}^{k} X_n)_{k\geqslant 1}$ za proizvoljan niz nenegativnih slučajnih varijabli $(X_n)_{n\geqslant 1}$, dobivamo

$$\mathbb{E}\left[\sum_{n=1}^{\infty} X_n\right] = \sum_{n=1}^{\infty}\mathbb{E}\Big[X_n\Big] \in [0,\infty]\,.$$

- **(Teorem o dominiranoj konvergenciji)** Ako je $(X_n)_{n\geqslant 1}$ niz slučajnih varijabli takav da (i) postoji slučajna varijabla X takva da gotovo sigurno $\lim_{n\to\infty} X_n = X$, te (ii) za neku nenegativnu slučajnu varijablu Y takvu da $\mathbb{E}[Y] < \infty$, vrijedi $|X_n| \leqslant Y$, za sve n, tada vrijedi $\mathbb{E}[|X|] < \infty$ te

$$\lim_{n\to\infty}\mathbb{E}[X_n] = \mathbb{E}[X] \in \mathbb{R}\,.$$